



Utilizando Machine Learning em seu ERP

#56

Da sala de reunião à vida real

Embarcadero Conference 2019

Sobre mim

Dion Mai

- Embarcadero MVP
- Gerente de Desenvolvimento
- Engenheiro de Controle e Automação



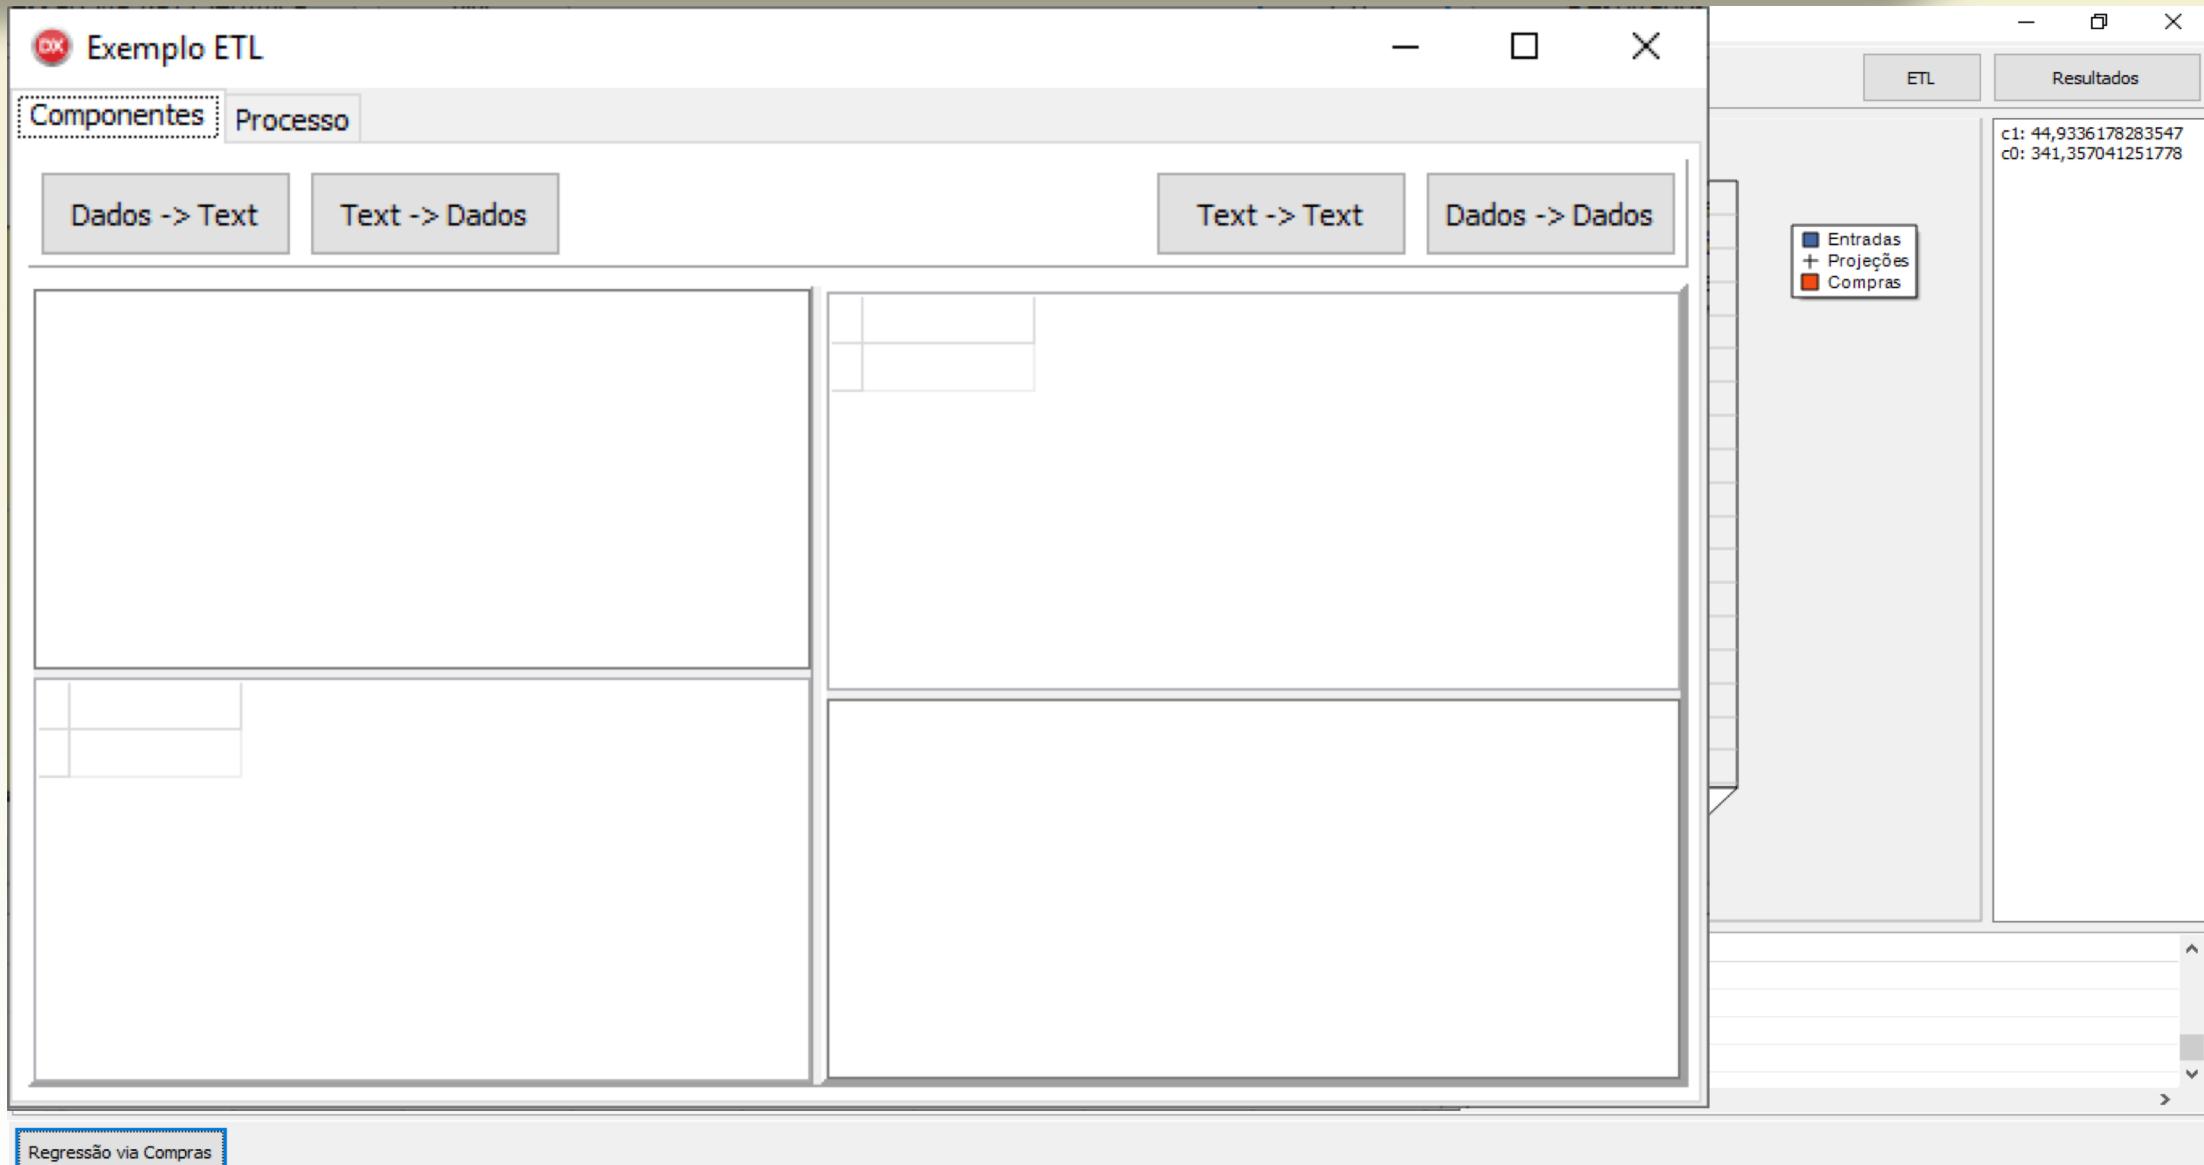
diondcm



Agenda

- O que é Machine Learning?
- Como está sendo aplicada?
- Como podemos aplicar?

O que veremos?

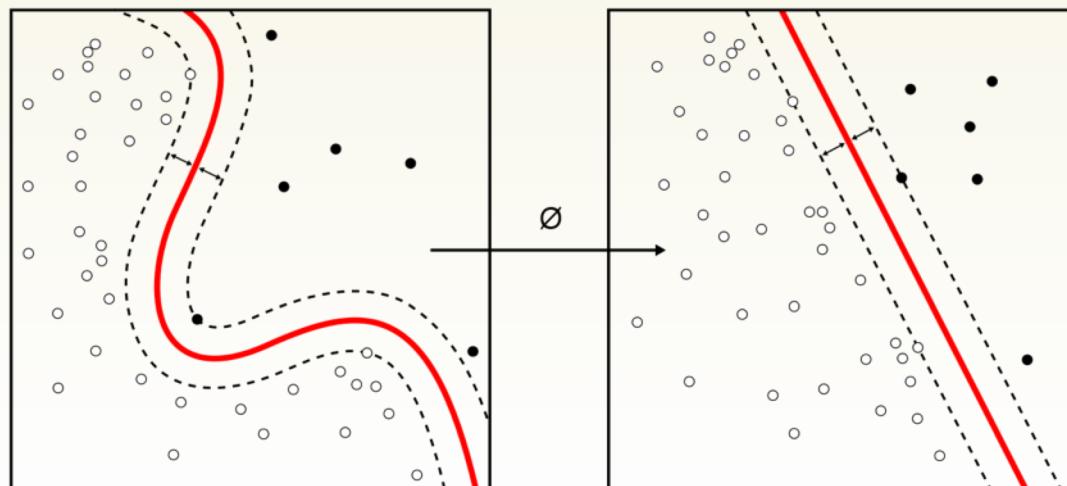


O que é Machine Learning?

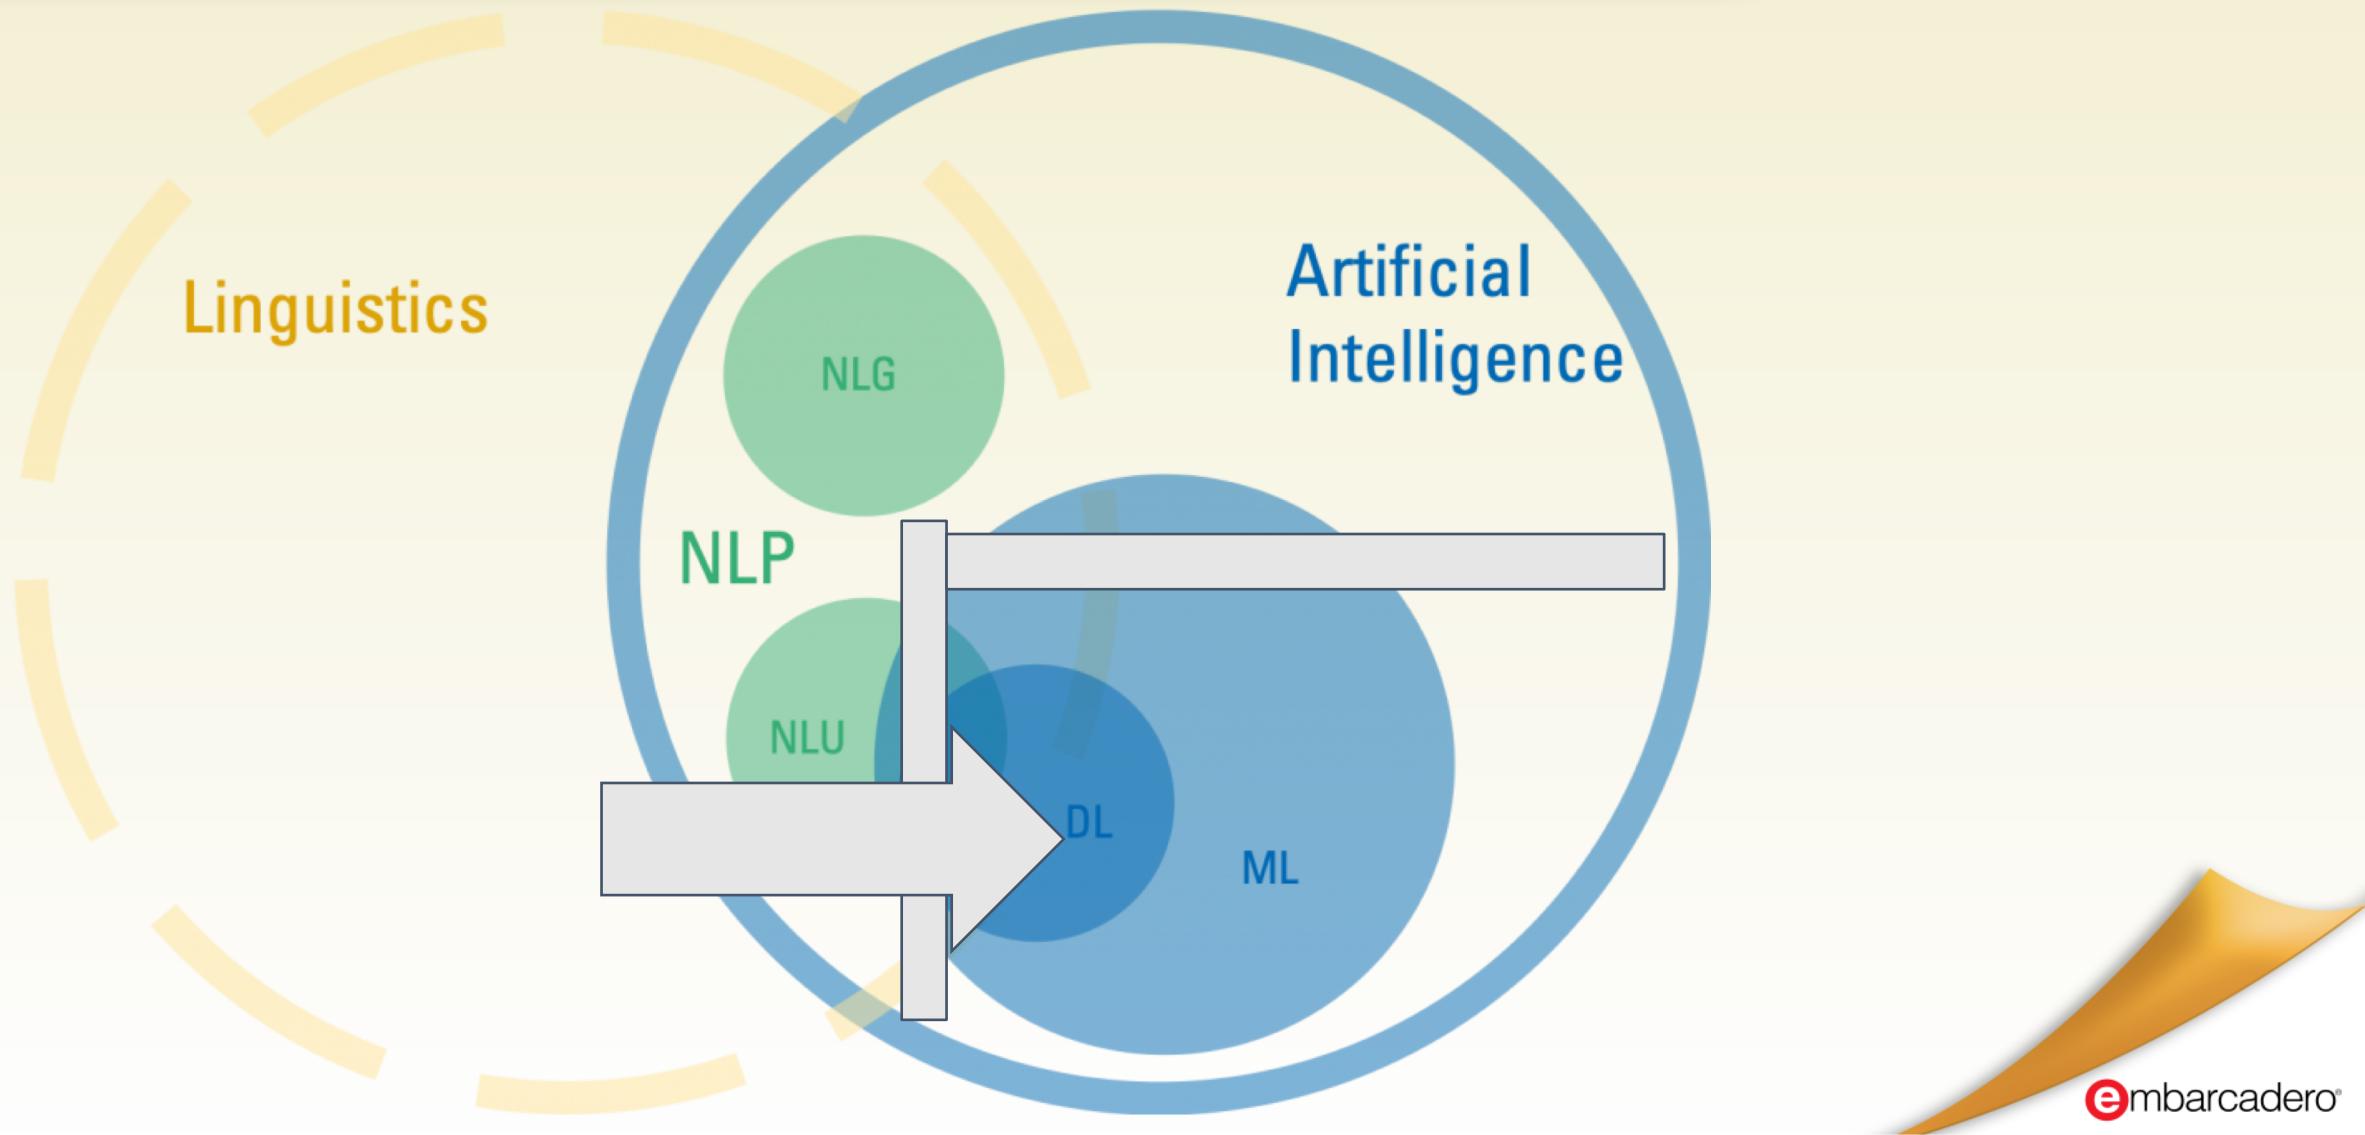
Machine learning (ML) é um estudo científico de algoritmos e modelos estatísticos computacionais utilizados para executar funções específicas, sem terem sido explicitamente programados para tal, mas baseando-se em identificação de padrões e inferência.

É uma sub-área da Inteligência Artificial.

Os algoritmos de Machine learning constroem modelos matemáticos baseados em um conjunto de dados de modo a realizar previsões ou tomar decisões sem terem sido explicitamente programados para realizarem isso.



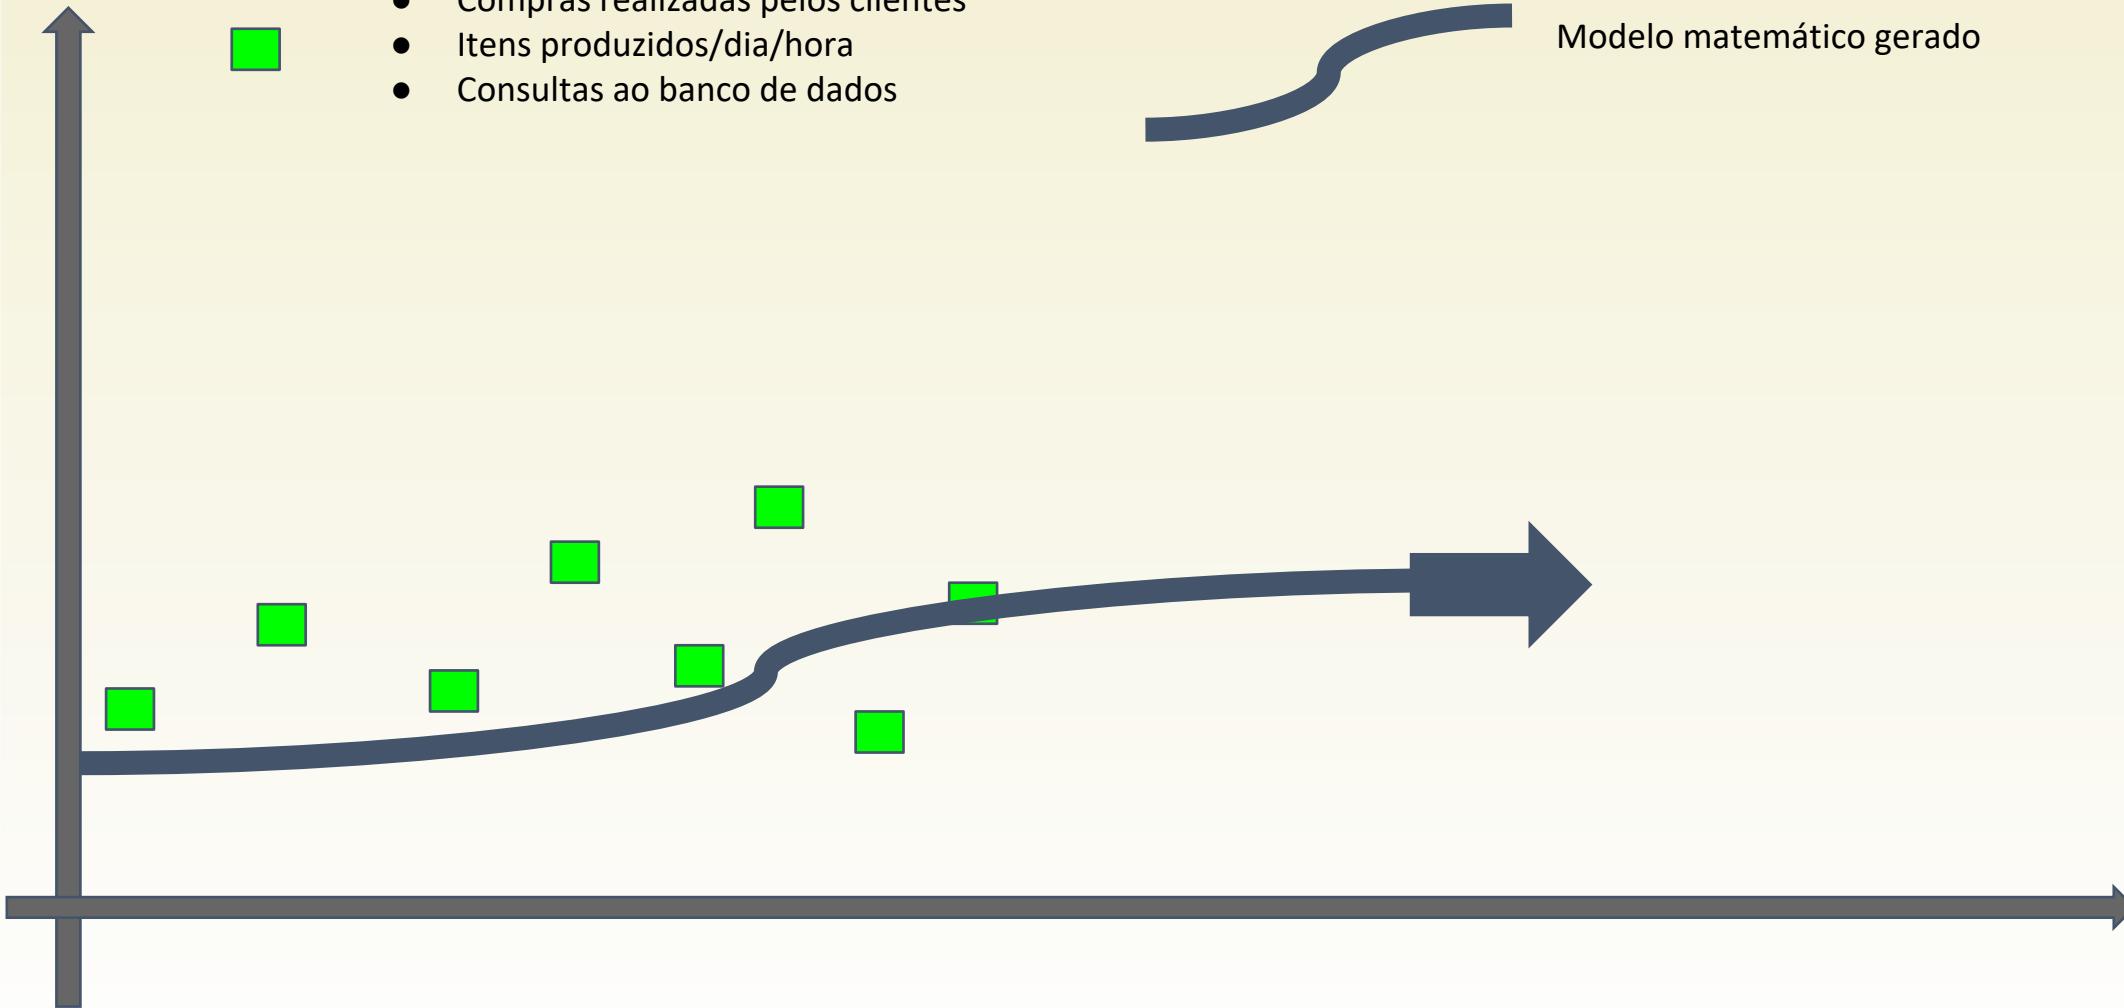
No gráfico



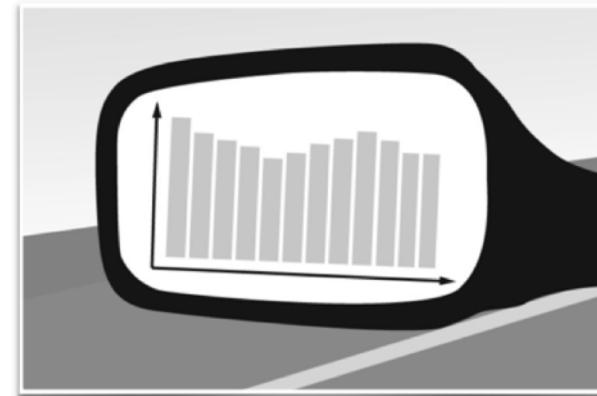
Mas como?

- Compras realizadas pelos clientes
- Itens produzidos/dia/hora
- Consultas ao banco de dados

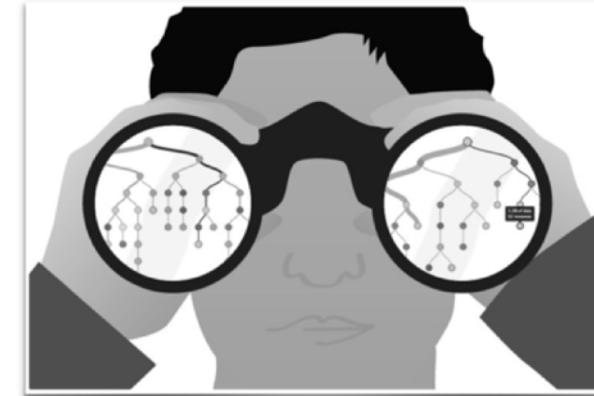
Modelo matemático gerado



Machine Learning Vs Business Intelligence



Descriptive Analytics
Traditional Business Intelligence
Group Tendencies
Dashboards



Predictive Analytics
Machine Learning
Individual Predictions
Predictive Applications



ENGAGEMENT PROCESS

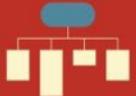
Step 1: Build the Data Model



Step 2: Define The Report



Step 3: Generate SQL commands



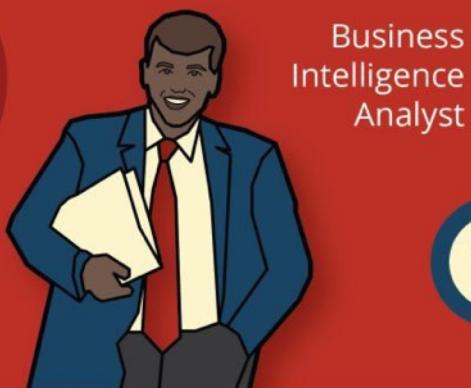
Step 4: Create Report



The data warehouse is a "schema-on-load" approach because the data schema must be defined and built prior to loading data into the data warehouse. Without an underlying data model, the BI tools will not work.

Business Intelligence Questions

What happened?



*Descriptive Analysis
Standard Reporting*

Data Science Questions

*Why? What will happen?
What should I do?*

Data Scientist

ENGAGEMENT PROCESS

Step 1: Define Hypothesis to Test ←



Step 2: Gather Data



Step 3: Build Data Model



repeat

Step 4: Explore the Data



Step 5: Build and Refine Analytic Models



Step 6: Ascertain Goodness of Fit

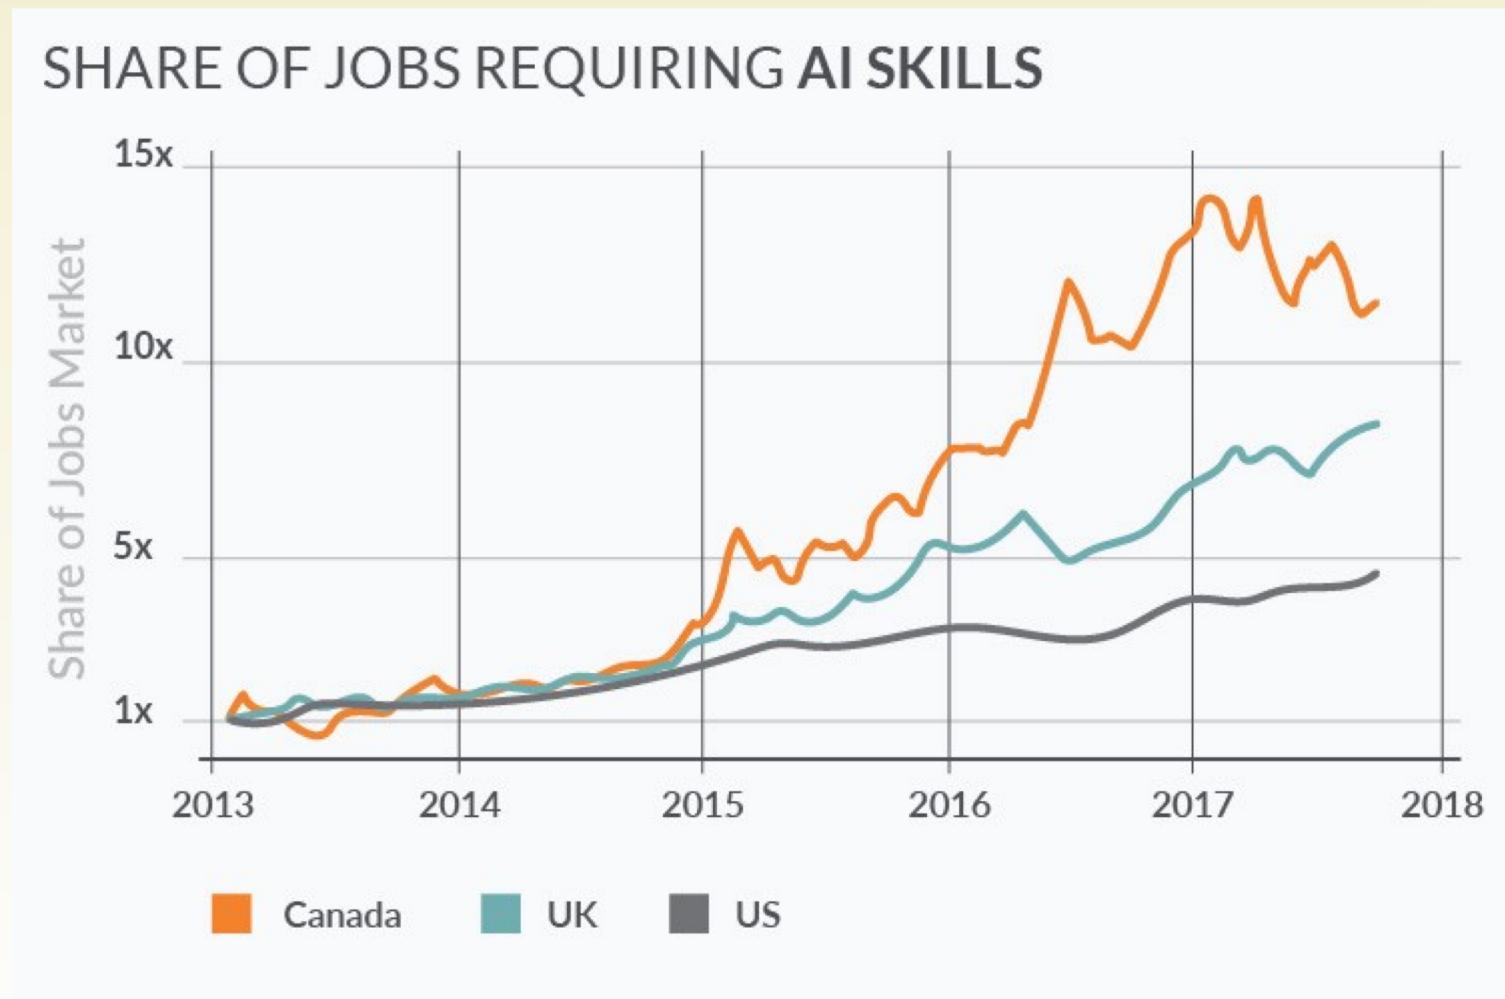


DIFFERENCE BETWEEN BUSINESS INTELLIGENCE AND DATA SCIENCE

CHARACTERISTICS

Focus	Reports, KPIs, trends	Patterns, correlations, models
Process	Static, comparative	Exploratory, experimentation, visual
Data Sources	Pre-planned, added slowly	On the fly, as-needed
Transform	Up front, carefully planned	In-database, on-demand, enrichment
Data quality	Single version of truth	"Good enough," probabilities
Data model	Schema on load	Schema on query
Analytics	Retrospective, Descriptive	Predictive, Prescriptive, Preventative

Como o mercado demanda?



Como o mercado demanda?

160 mil vagas em aberto no Brasil

1. Analista de dados / BI 13%
2. Analista de Mak Digital 10%
3. Cientista de dados 9%
4. Especialista em Customer Experience 9%

Cargos mais buscados	% de empregadores que buscam
1. Analista de dados / BI	13%
2. Analista de Mak Digital	10%
3. Cientista de dados	9%
4. Especialista em Customer Experience	9%
5. UX/UI Designer	8%

Como o mercado demanda?

80 % das operações de trade mundiais são robotizadas.



<https://www.worldfinance.com/markets/technology/robots-are-killing-off-wall-streets-traders>

Quais técnicas?

Machine Learning

Neural Network

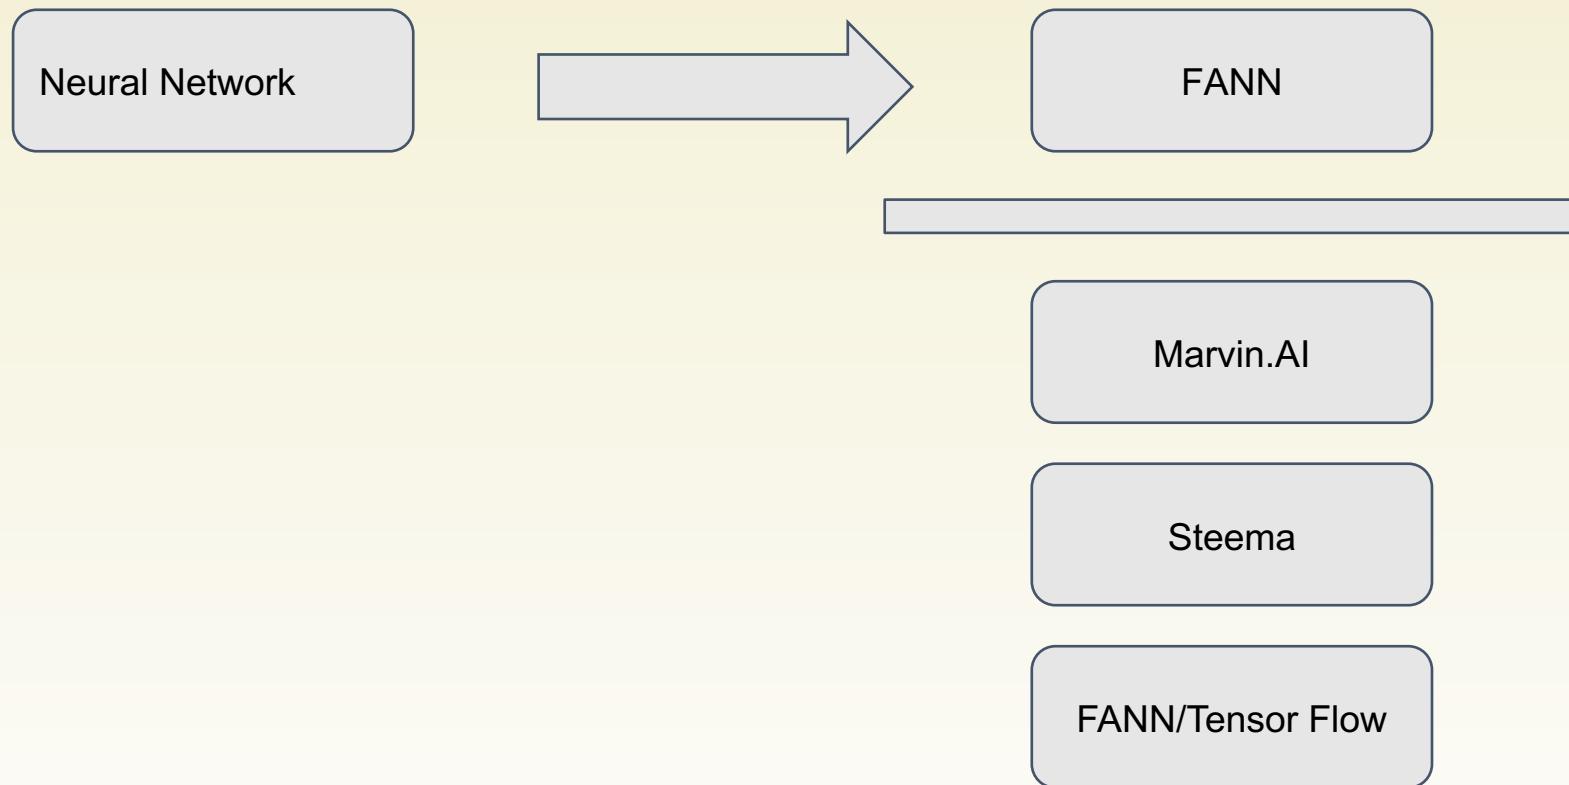
Gaussian Regression

Linear Regression

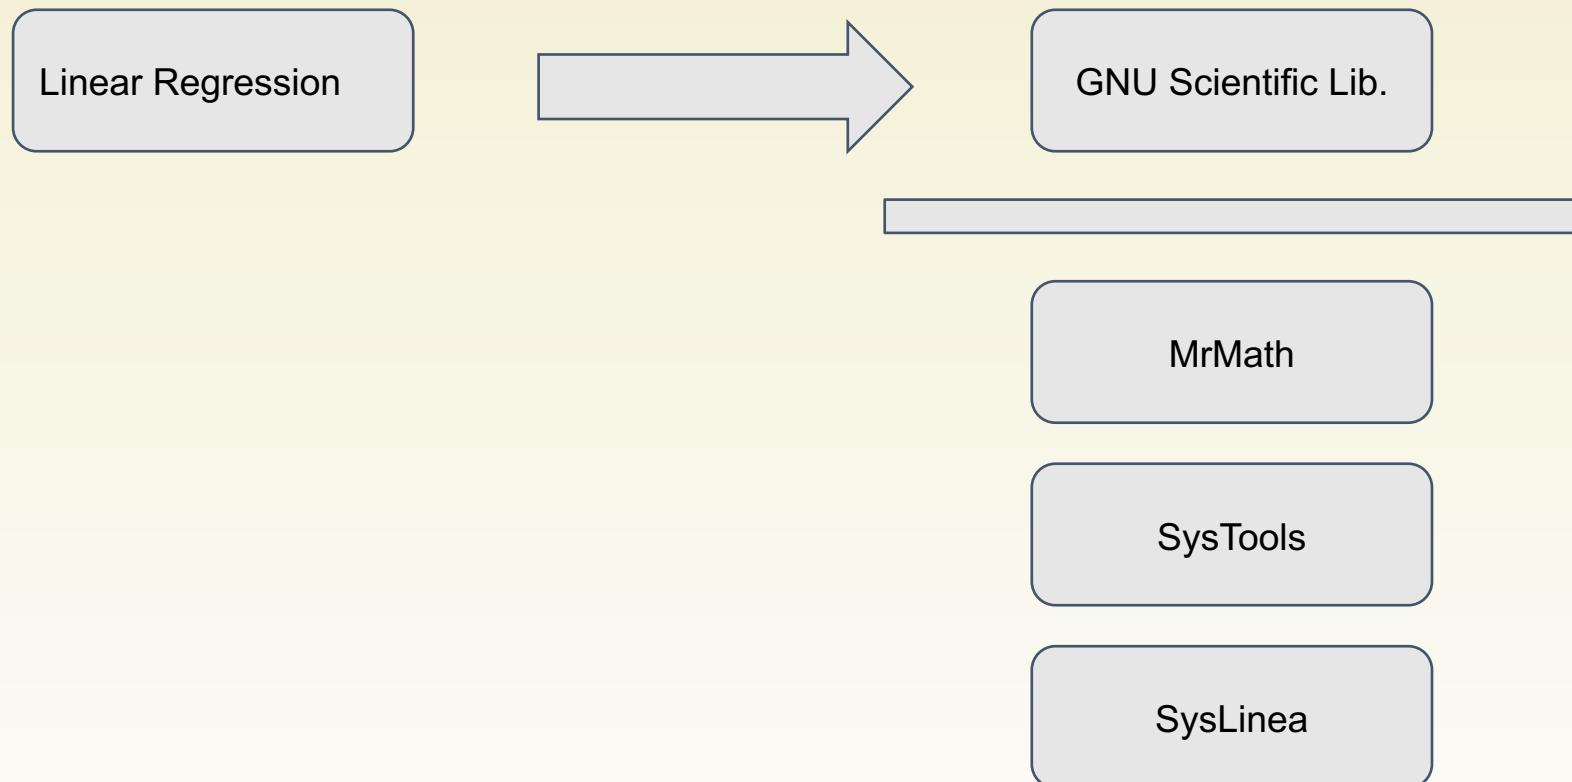
Naive Bayes



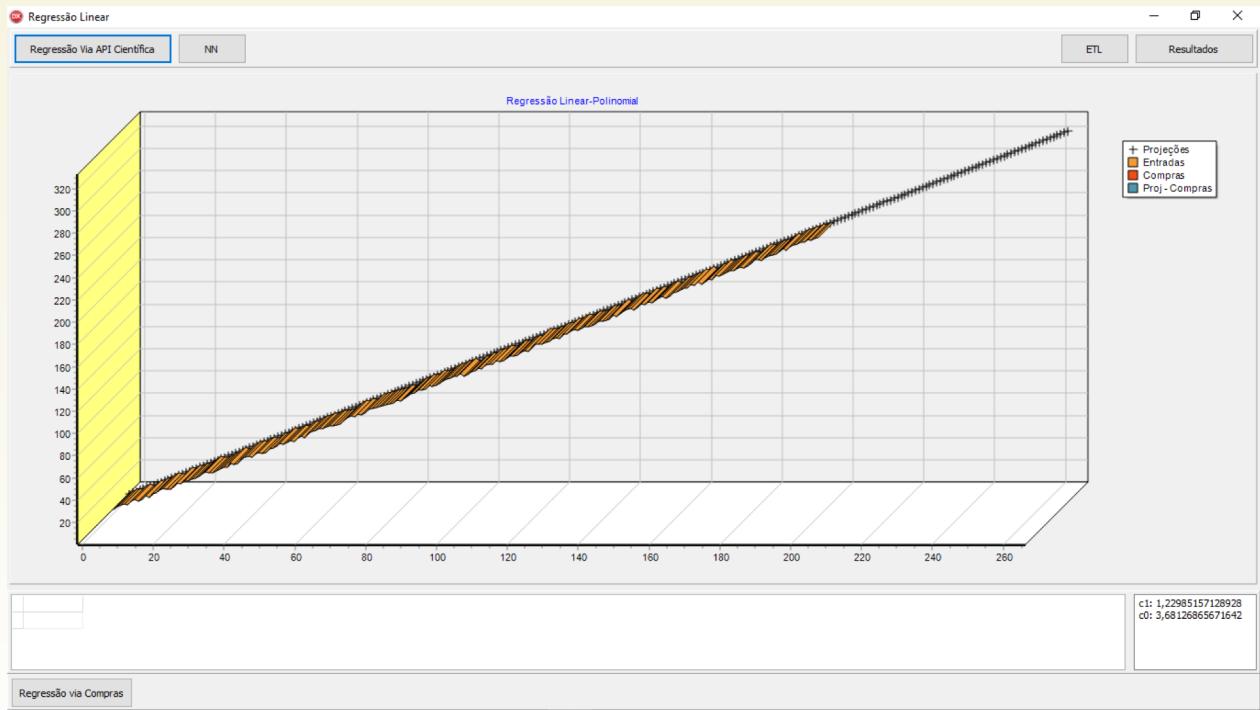
Quais Frameworks? - Neural Network



Quais Frameworks? - Linear Regression



Exemplos...

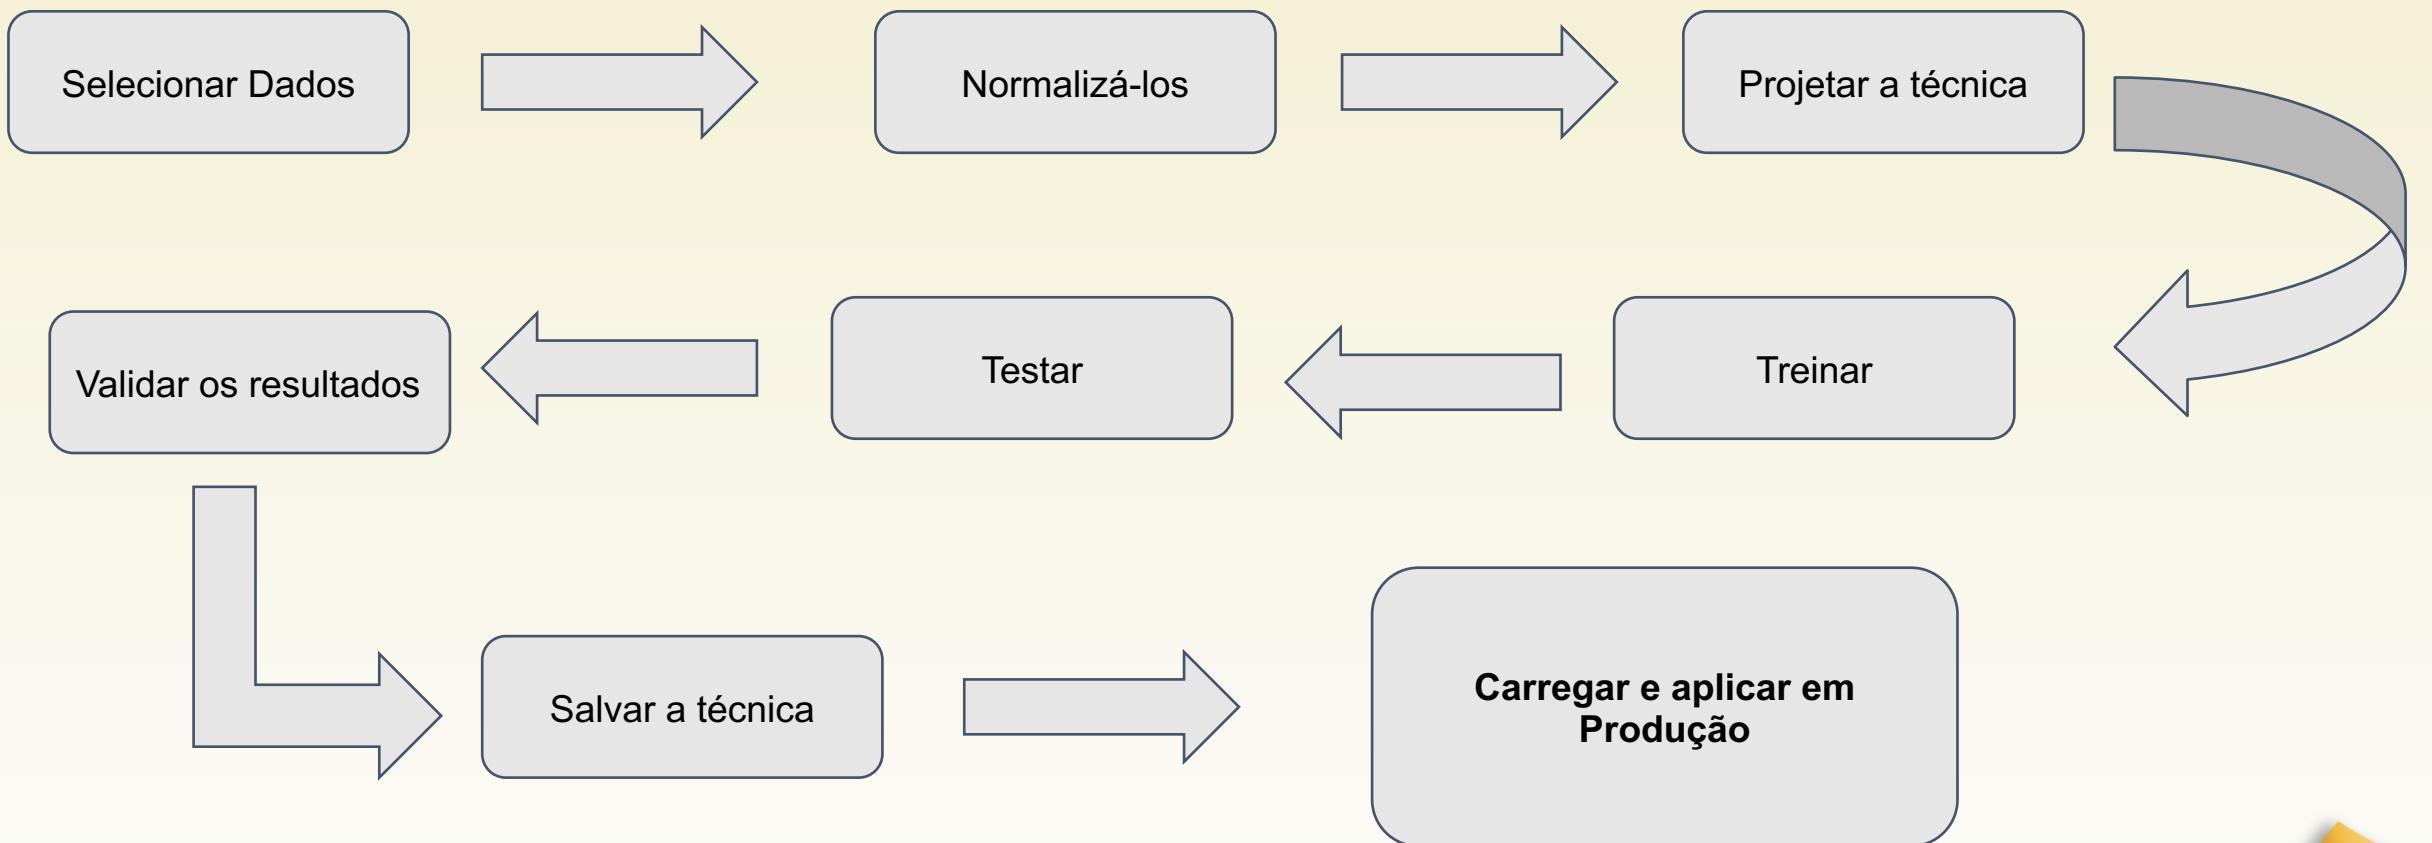


NN Test

Treino e Teste Texto Resultado

Entrada	Saída
150 1 1	100 1 1
0.000 4.240	0.000 -0.988
1.000 3.170	1.000 -1.000
2.000 6.600	2.000 -0.963
3.000 7.330	3.000 -0.955
4.000 6.860	4.000 -0.960
5.000 10.890	5.000 -0.916
6.000 11.520	6.000 -0.909
7.000 10.950	7.000 -0.916
8.000 13.180	8.000 -0.891
9.000 13.510	9.000 -0.888
10.000 15.840	10.000 -0.863
11.000 16.570	11.000 -0.855
12.000 16.900	12.000 -0.851
13.000 20.530	13.000 -0.812
14.000 20.860	14.000 -0.808
15.000 23.590	15.000 -0.779
16.000 23.520	16.000 -0.779
17.000 24.050	17.000 -0.774
18.000 27.080	18.000 -0.741
19.000 27.710	19.000 -0.734
20.000 30.140	20.000 -0.707
21.000 30.470	21.000 -0.704
22.000 32.300	22.000 -0.684
23.000 30.130	23.000 -0.708
24.000 33.260	24.000 -0.674
25.000 34.000	25.000 -0.655

Como aplicar o processo?



No nosso exemplo

Linear Regression

Salvamos os coeficientes que a função gera para aplicar

```
● 80 || gsl_fit_linear(@X[0], 1, @Y[0], 1, Length(y), @c0, @c1,
```

- @X => Dados de Entrada
- @Y => Dados de Saída
- @c0 => constante
- @c1 => índice linear

Exemplo:

$$y(x) = \text{c1} * x + \text{c0}$$

No nosso exemplo

Linear Regression

$$y(x) = \textcolor{blue}{c1} * x + \textcolor{blue}{c0}$$

O que Inferimos:

- @c1 for menor que 0, indica queda
- @c1 “grande” ou “pequeno” => “velocidade” da função
- @c0 “grande” pode indicar erro, pois na ausência de entrada esse valor perdura, o que nem sempre ocorre no mundo real.

• 80 || `gsl_fit_linear(@X[0], 1, @Y[0], 1, Length(y), @c0, @c1,`

No nosso exemplo

```
rawData := DataLoad( PATH_ORIG_DATA );  
  
nrmData := DataNormalize( rawData, -1.0, +1.0 );  
  
for perm:=0 to 5 do  
begin  
  strPerm := '.perm' + i2s(perm);  
  for loop:=1 to LOOP_TIMES do  
  
    DataSave( nrmData, ExtractFilePath(Para...  
  
    fann_create_standard(layers, inputs, outputs);  
  
    fann_read_train_from_file( ... );
```

- Carrega os dados.
- Normaliza os dados.
- Loop para treinar a rede neural.
- A cada “geração”, “iteração”, os dados são reorganizados.
- Cria a rede.
- Treina e testa a rede criada.

No nosso exemplo

```
fann_test_data(pnn, train_data);
```

→ Aplica os dados sobre a rede neural.

```
calc_out:= fann_run(pnn, @inputs[0]);
```

→ Inferência => gera ou classifica valores que não estavam presentes nos dados de teste e treino.

No nosso exemplo

Carrega rede com base em arquivo

```
fann_create_from_file(const configuration_file: PChar): PFann;
```

Salva rede com em arquivo

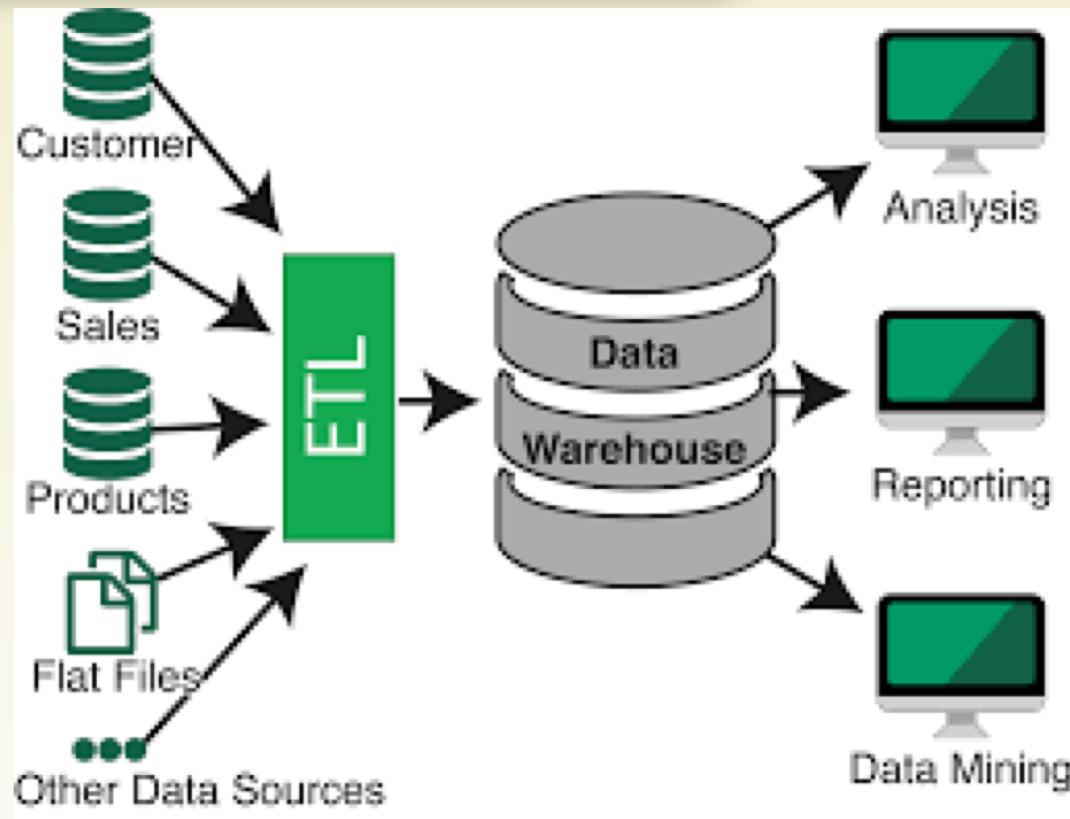
```
fann_save(Ann: PFann; Const Configuration_File: PChar);
```

O que conseguimos?

- Quais as vantagens e desvantagens destes métodos?
- Onde podemos aplicar?
- O que necessitamos para aplicar?

Quais as vantagens para Delphi?

- ETL



ETL em Delphi

Exemplo ETL

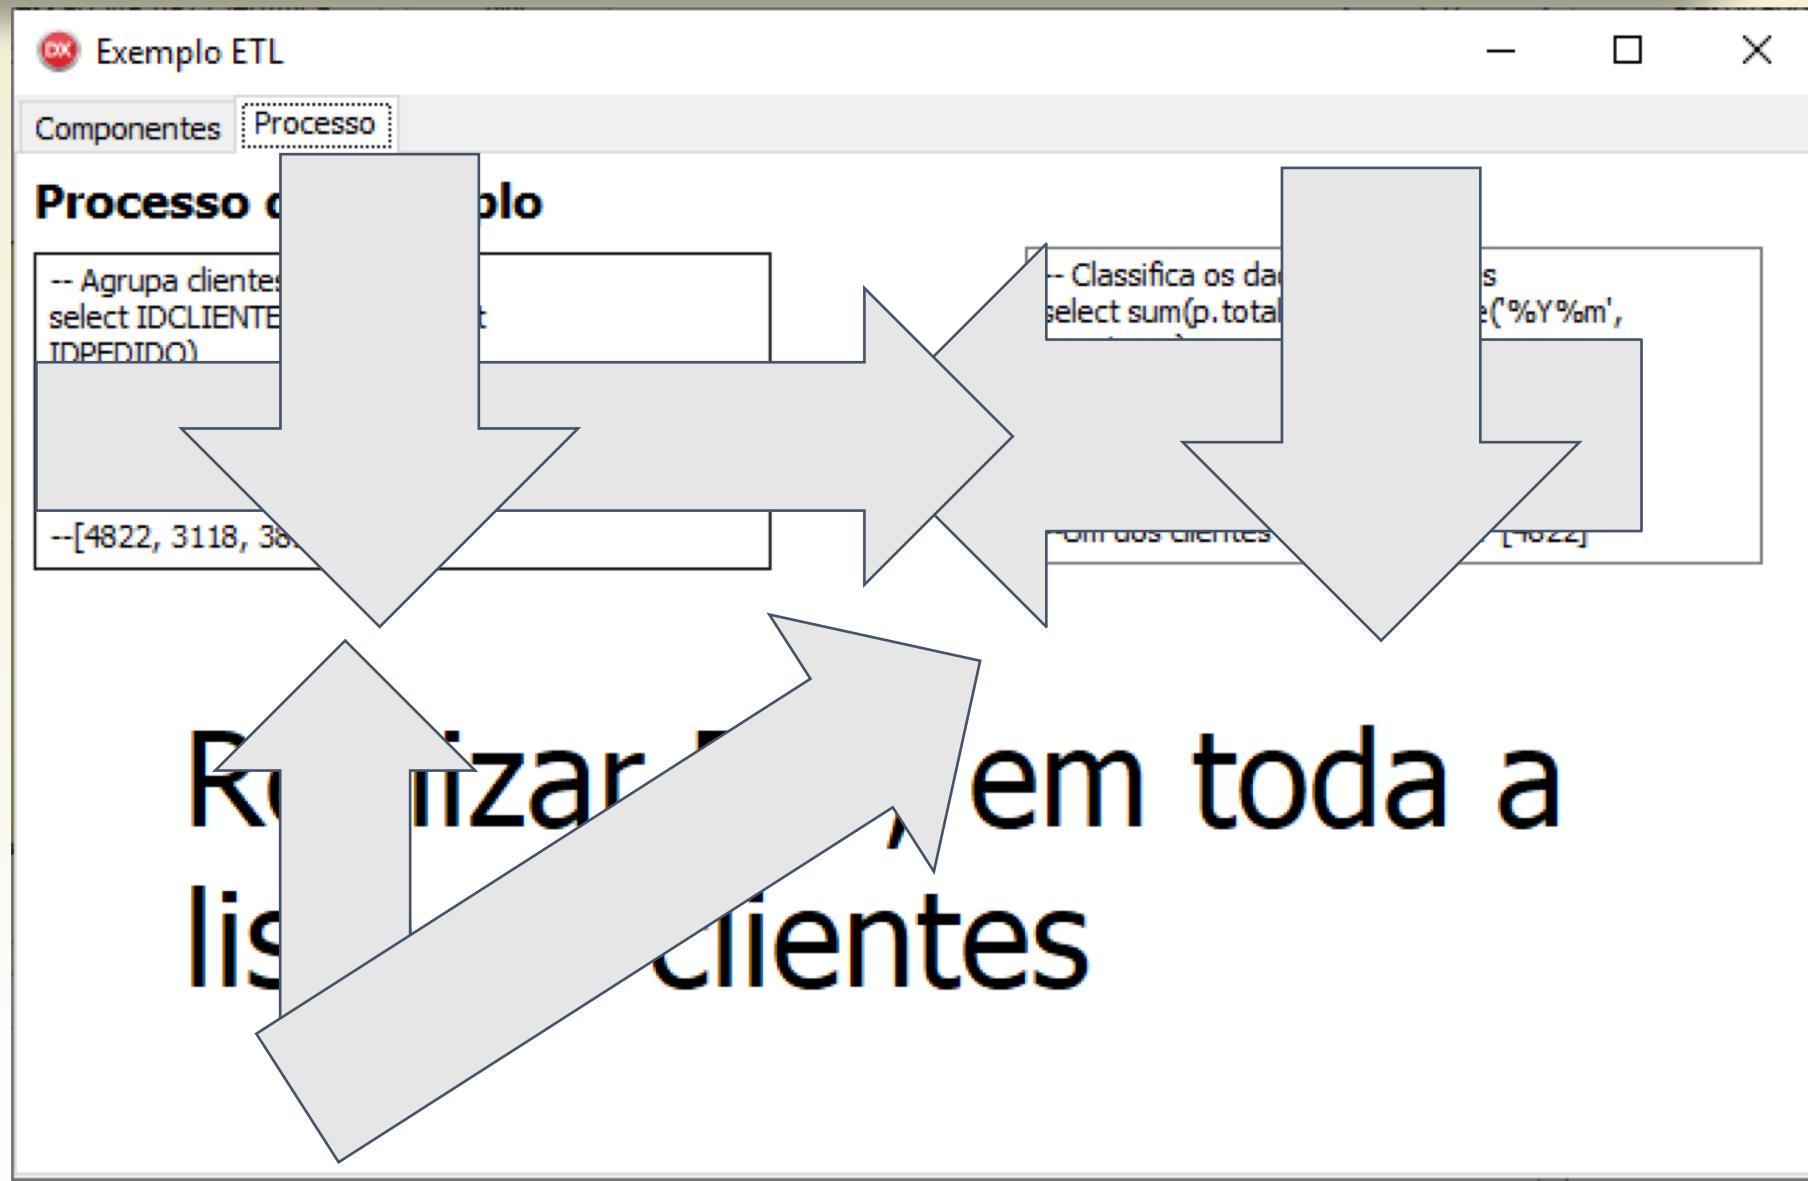
Componentes Processo

Dados -> Text Text -> Dados Text -> Text Dados -> Dados

X;Y
0.000;4.240
1.000;3.170
2.000;6.600
3.000;7.330
4.000;6.860
5.000;10.890
6.000;11.520
7.000;10.950
8.000;13.180
9.000;13.510

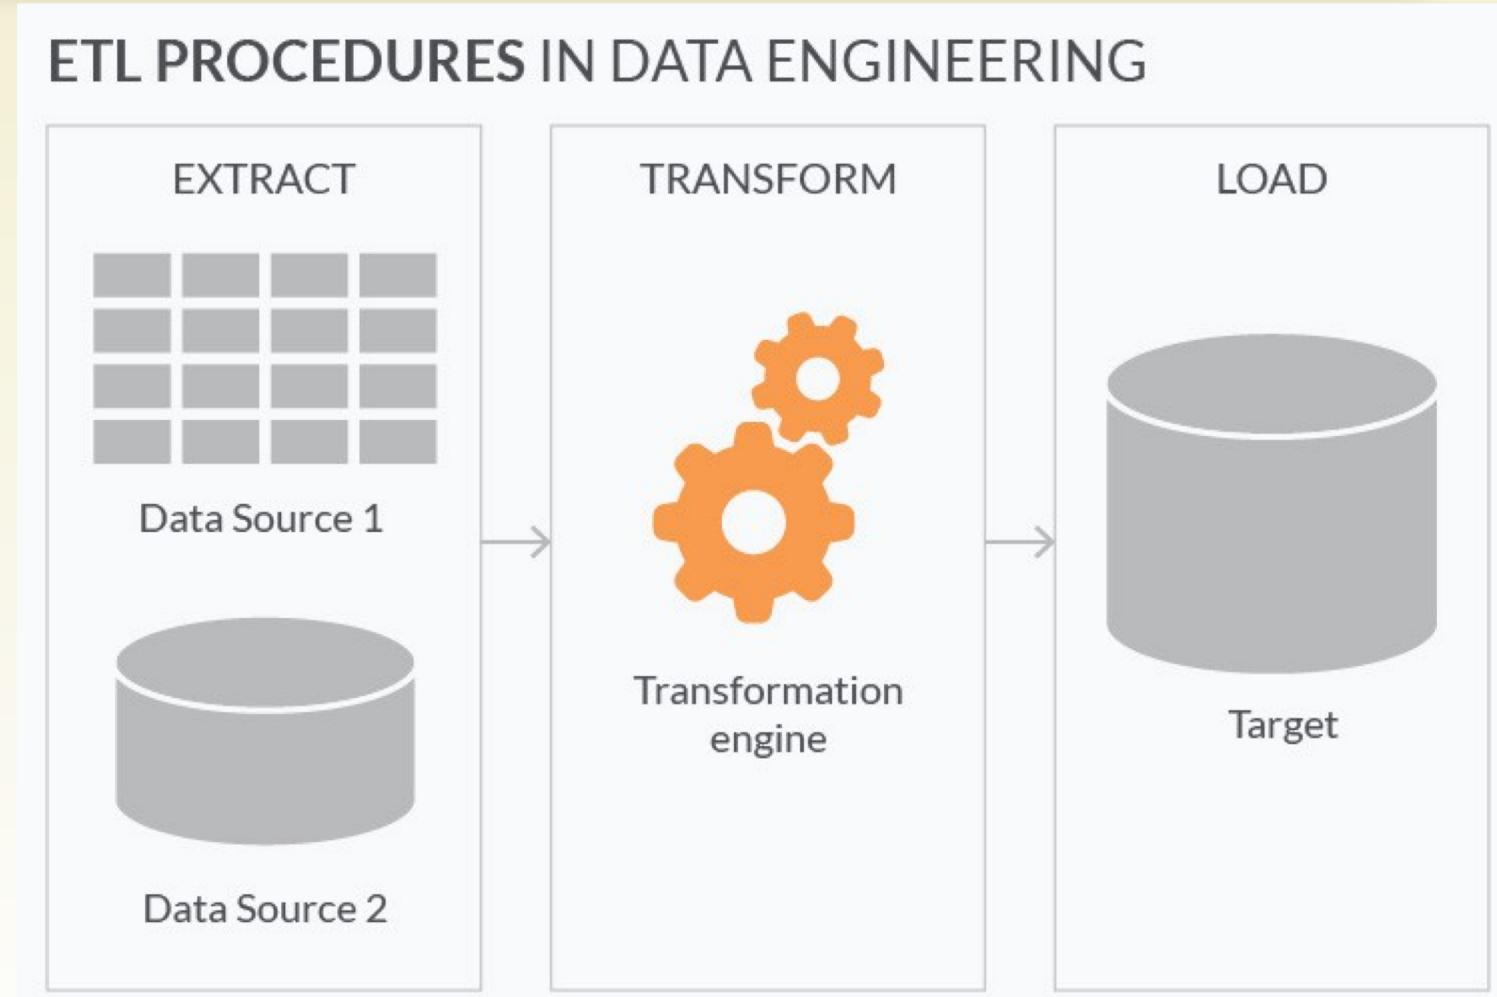
X	Y
0	4240
1000	3170
2000	6600
3000	7330
4000	6860
5000	10890
6000	11520

ETL em Delphi



Quais as vantagens para Delphi?

- ETL



Quais as vantagens para Delphi?

- ETL
- Fácil integração com API's



IdHTTPGetFromAPI

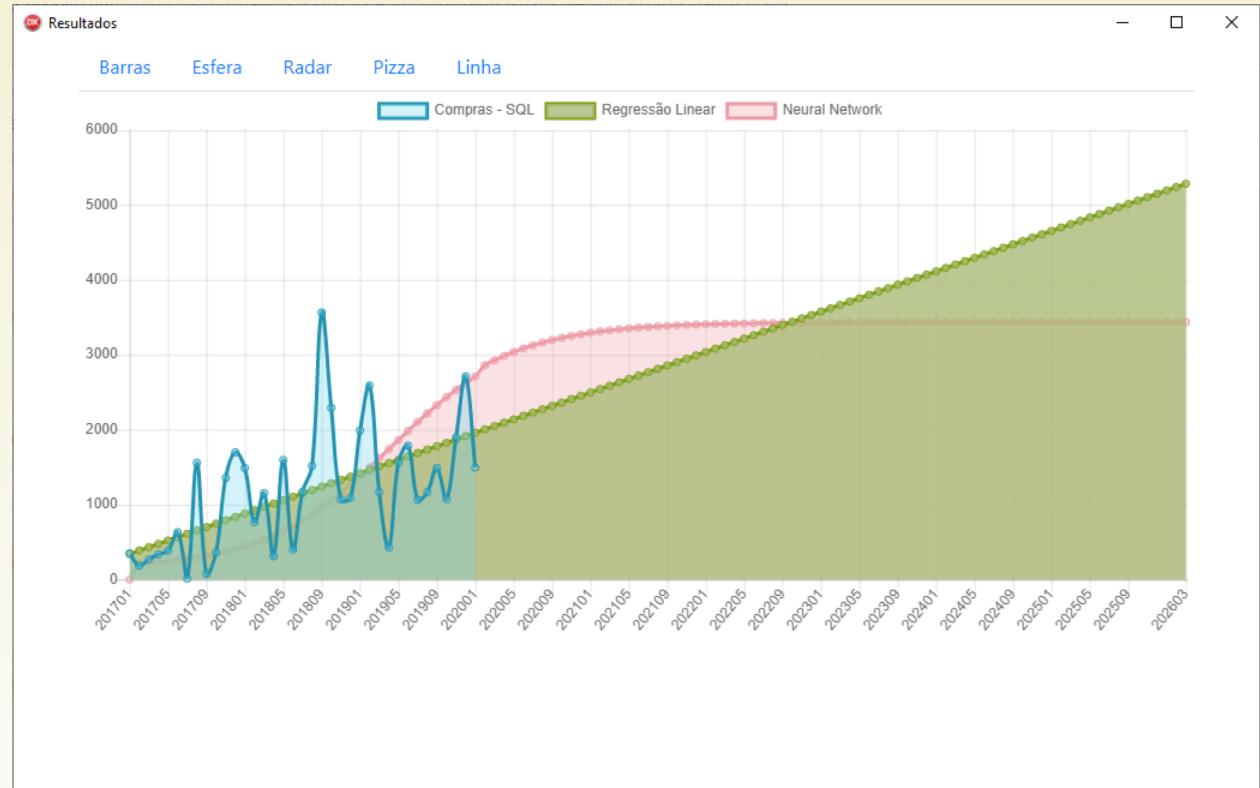


RESTRequestAPI

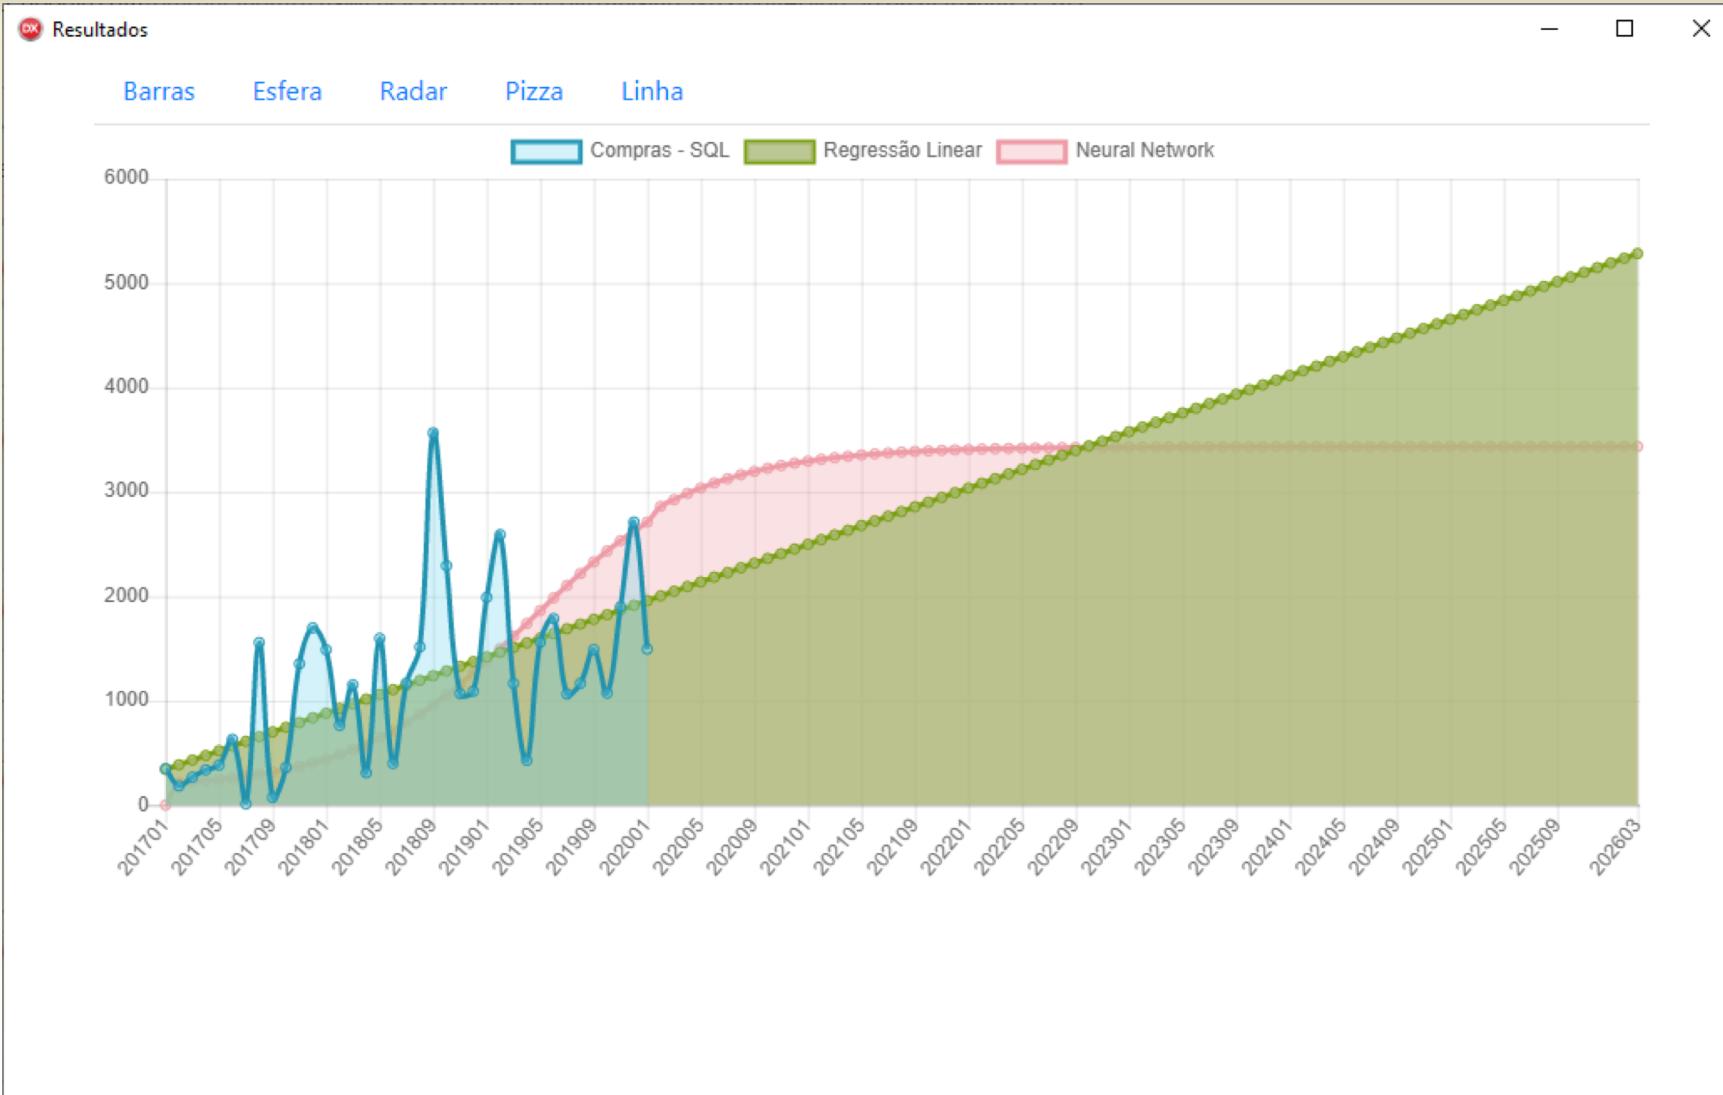
```
function fann_run; external DLL_FILE;
```

Quais as vantagens para Delphi?

- ETL
- Fácil integração com API's
- Fácil compilação de resultados



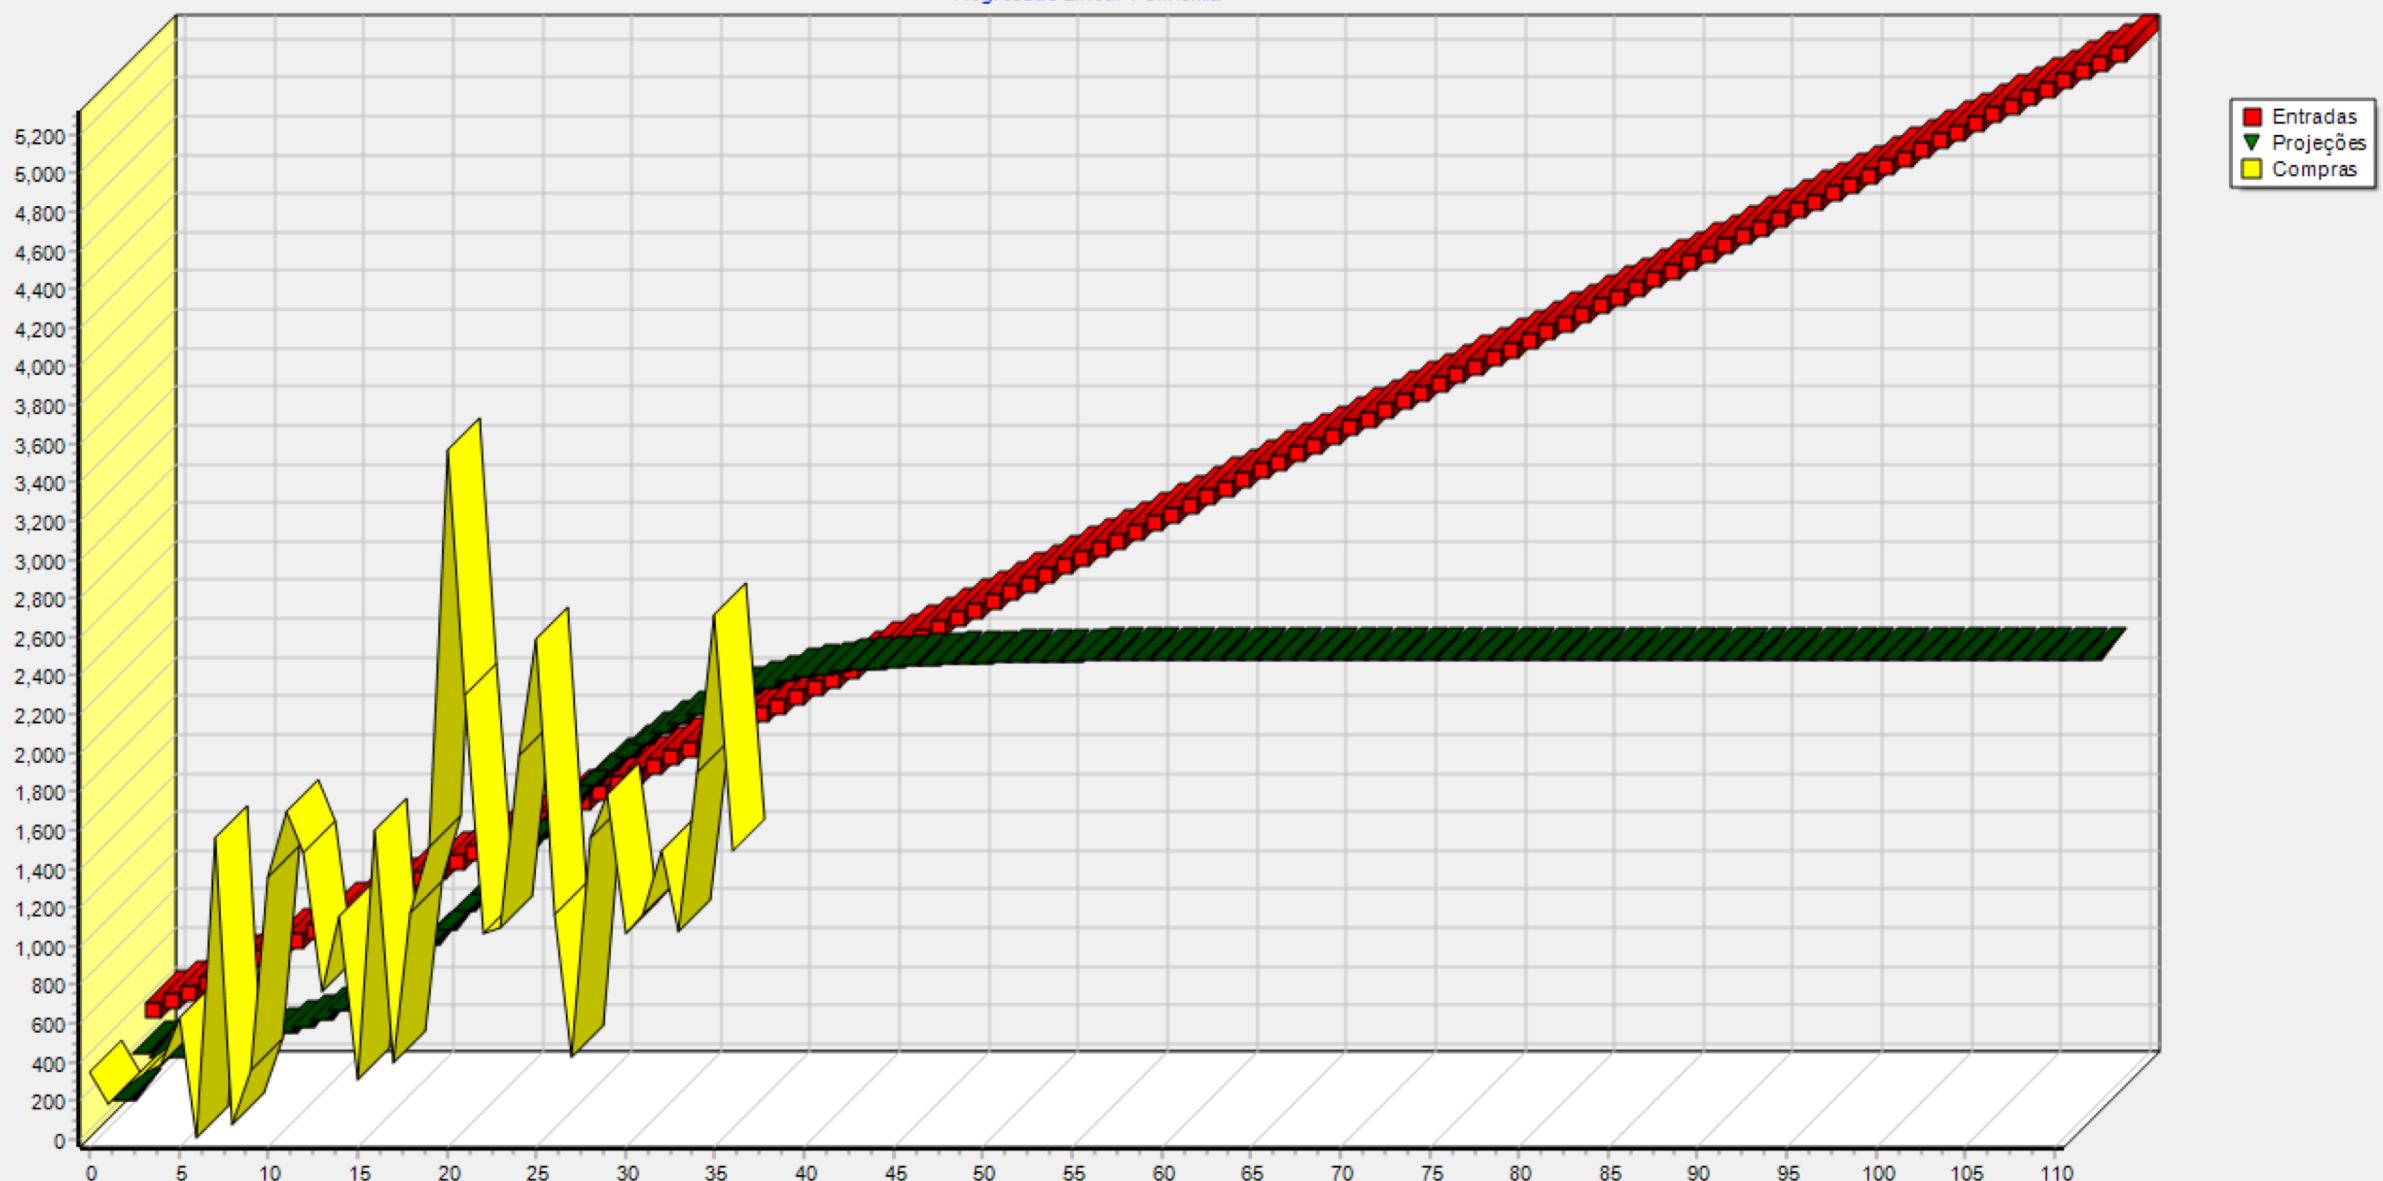
Resultados



O que conseguimos?

- Quais as vantagens e desvantagens destes métodos?
- Onde podemos aplicar?
- O que necessitamos para aplicar?

Regressão Linear-Polinomial



Próximos passos

- Time de Machine Learning
- Data Mining
- IoT & Big Data
- Data Warehouse
- Aprendizado não supervisionado
- Modelos complexos

Proximos passos

MACHINE LEARNING DEVELOPMENT TEAM



Solution Architect



Big Data Architect



Big Data Engineers



Backend developers



Frontend developers



Data Scientists



Machine Learning
Engineers



Business Intelligence
Experts

[Network](#) [Shape](#) [Points](#) [View](#) [Help](#)

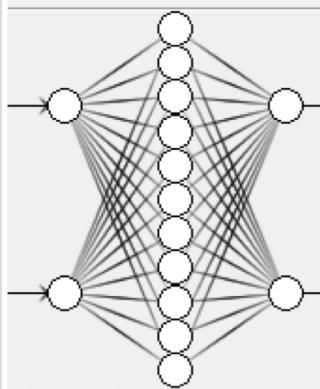
Learn (Hard) ▾ Stop Error: 0.00% (0)
ni: 0.015 Age: 5763 K (14408 Epochs) 144 K/s, 39 s N

[Network](#) [Learn](#) [Draw](#)

400 203 197 Del. Gen. Clear

Network Structure

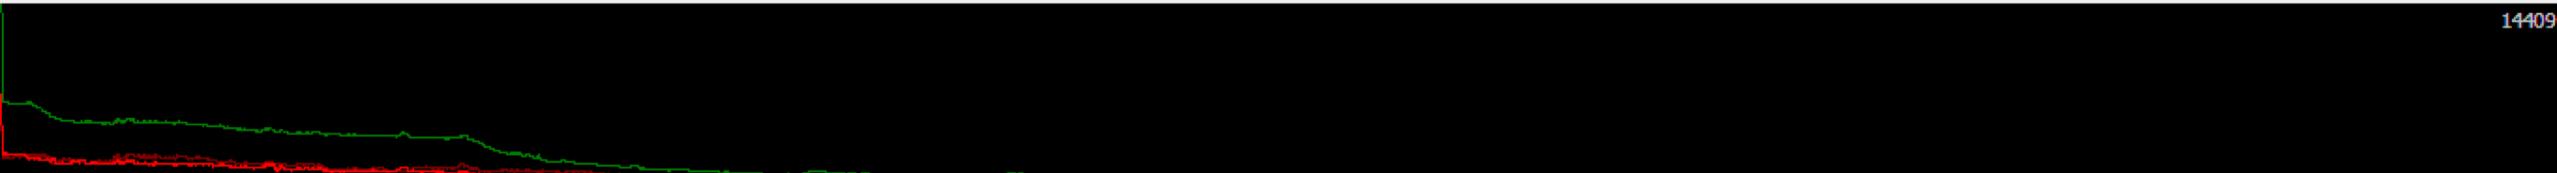
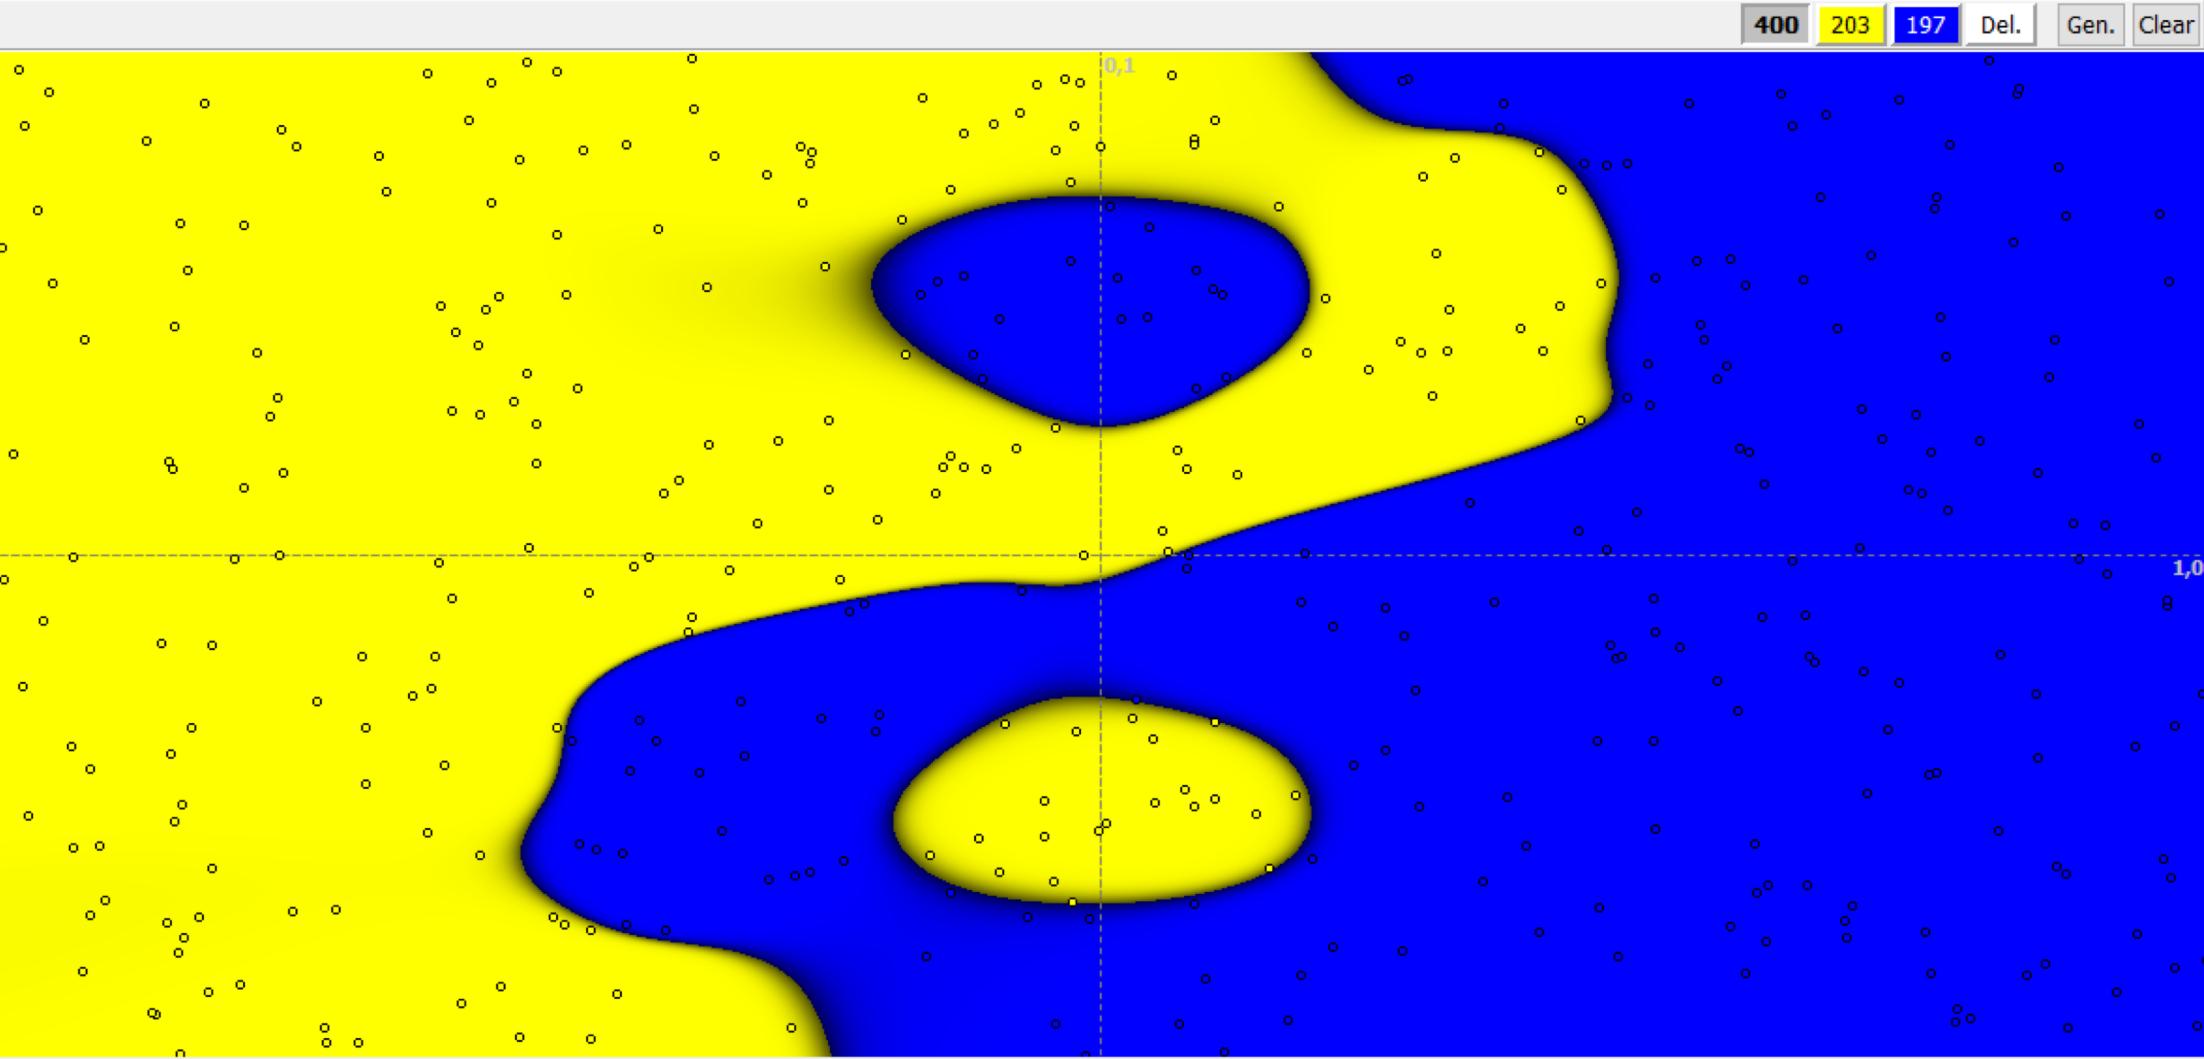
2:11:2

**Abs. Weights**

Max.:	51.58	30.91
Min.:	2.791	5.410
AAM:	22.95	15.49
RMS:	26.96	17.18

Abs. Bias

Max.:	13.79	1.884
Min.:	0.033	1.872
AAM:	5.961	1.878
RMS:	7.532	1.878





Obrigado



dion.mai@aquasoft.com.br



diondcm

#56

Da sala de reunião à vida real

Embarcadero Conference 2019