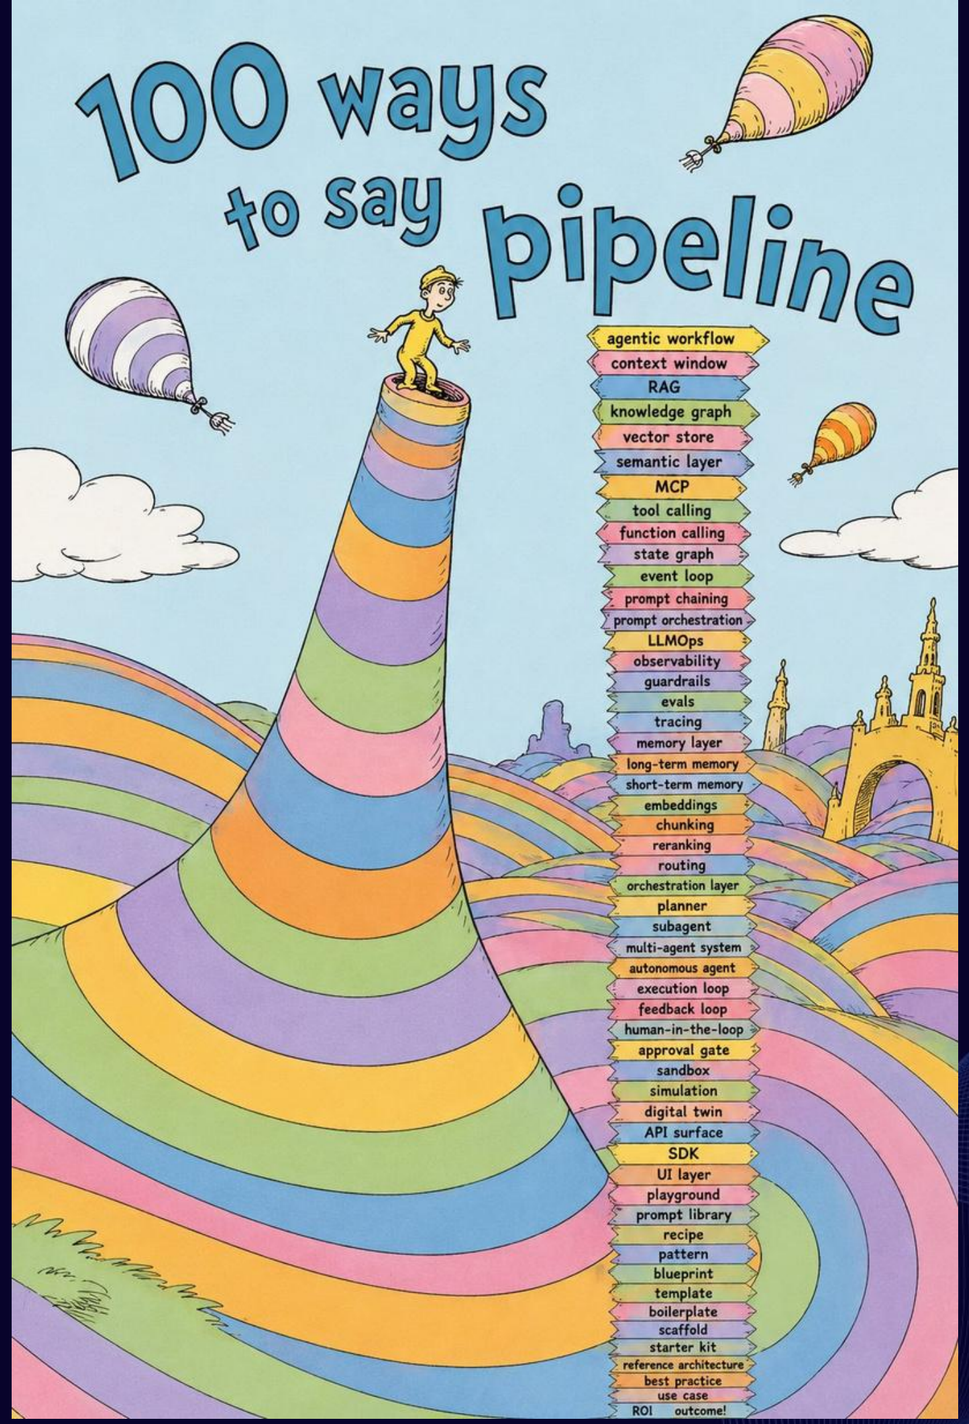
IA ALÉM DOS PROMPTS

MCP - Tool Calling - Subagentes - Skills - Slash Commands - Spec-Driven Development - Harness - e outros

Cada dia um novo termo

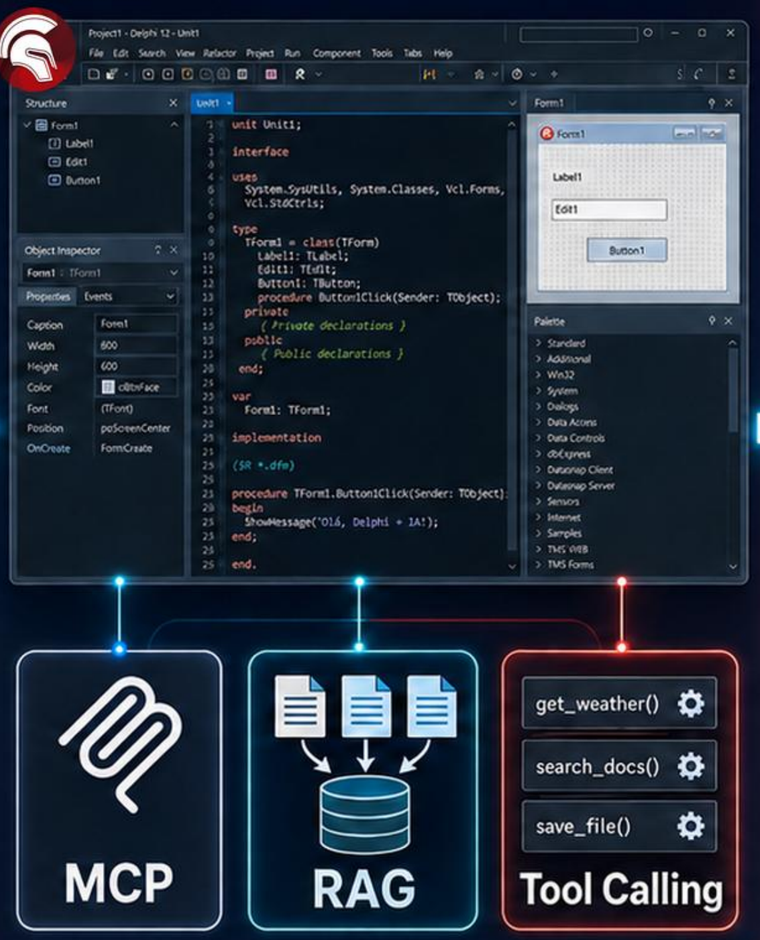


Dinâmica de hoje

01
Apresentação dos termos

Prompts
MCP
RAG
Tool Calling
Janela de contexto
Skills
AGENTS.md
Slash commands
Subagentes
Spec-Driven Development (SDD)
Loop Engineering

02
Demonstrações práticas



03
Surpresa:
Treinamento IA para Devs Delphi



Quem sou eu

- **César Cardoso**
- Graduado em Análise e Desenvolvimento de Sistemas
- Pós-graduado em Desenvolvimento de Sistemas Web
- Desenvolvedor desde 2009
- **Desenvolvedor na Solusys Sistemas**
- **Criador de conteúdo no canal Code4Delphi**
- **Embarcadero MVP**

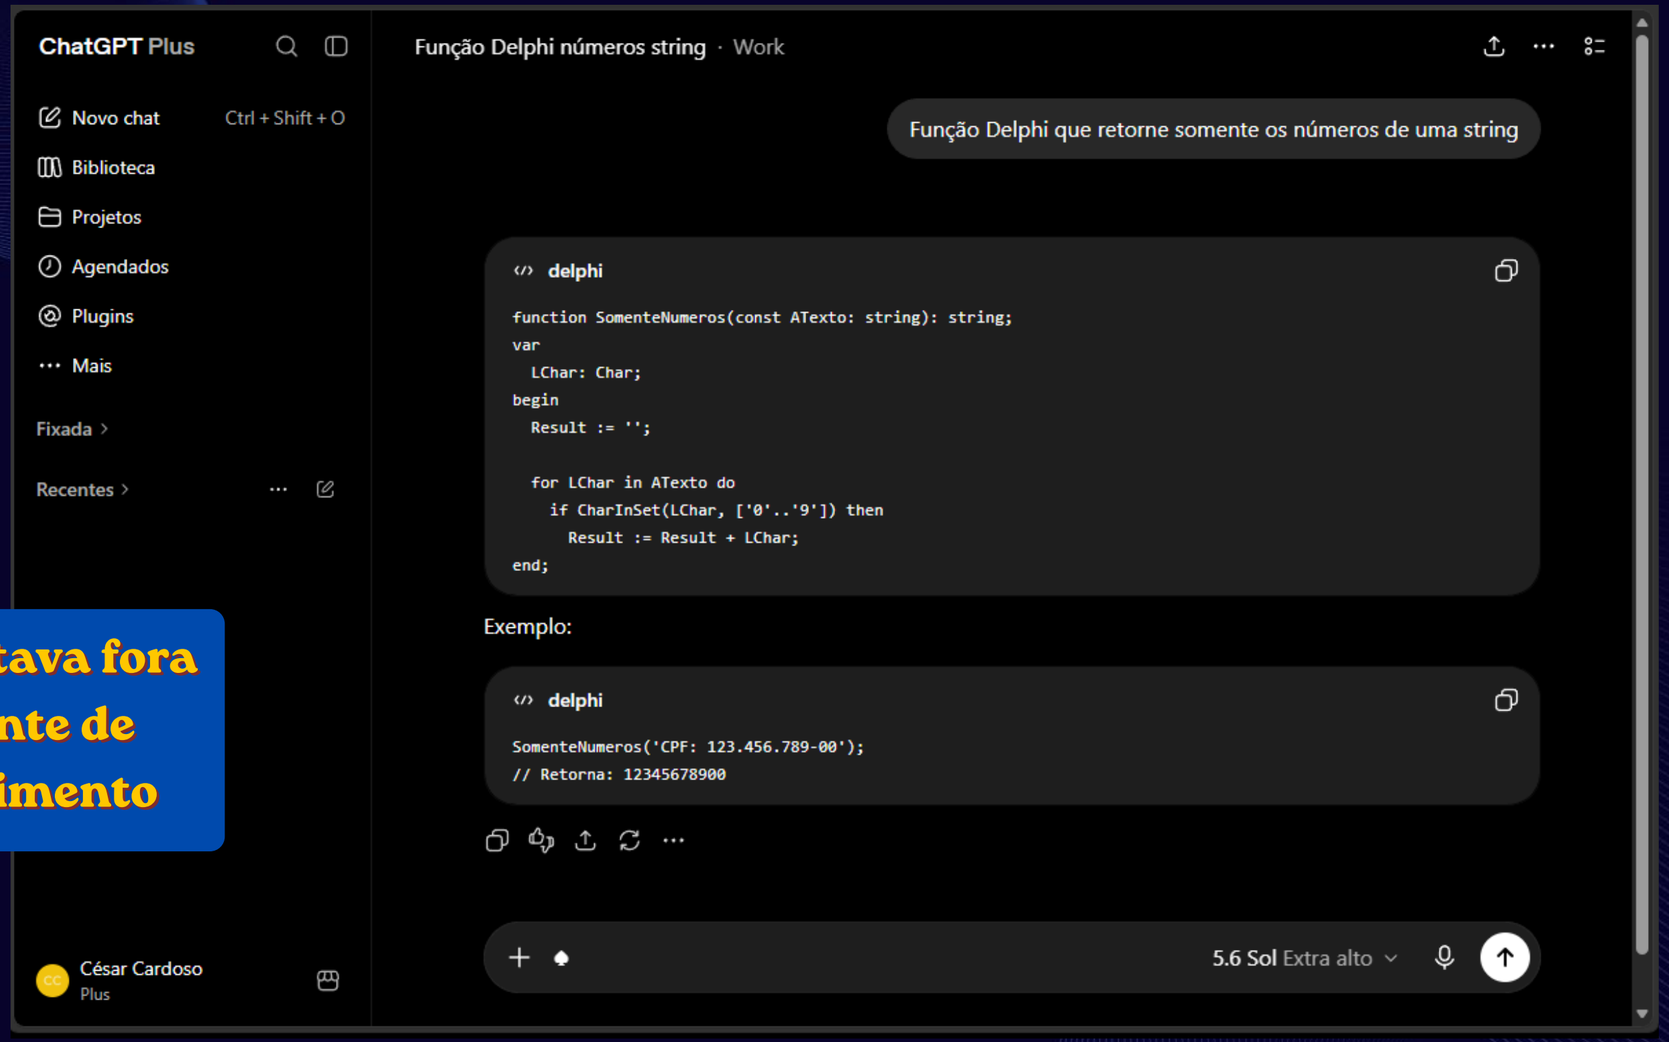
Solusys Soluções em Sistemas

CODE 4 C4D DELPHI

embarcadero® MVP

O início de tudo: Chats

A interação se resumia a copiar e colar código entre a IDE e o chat no navegador



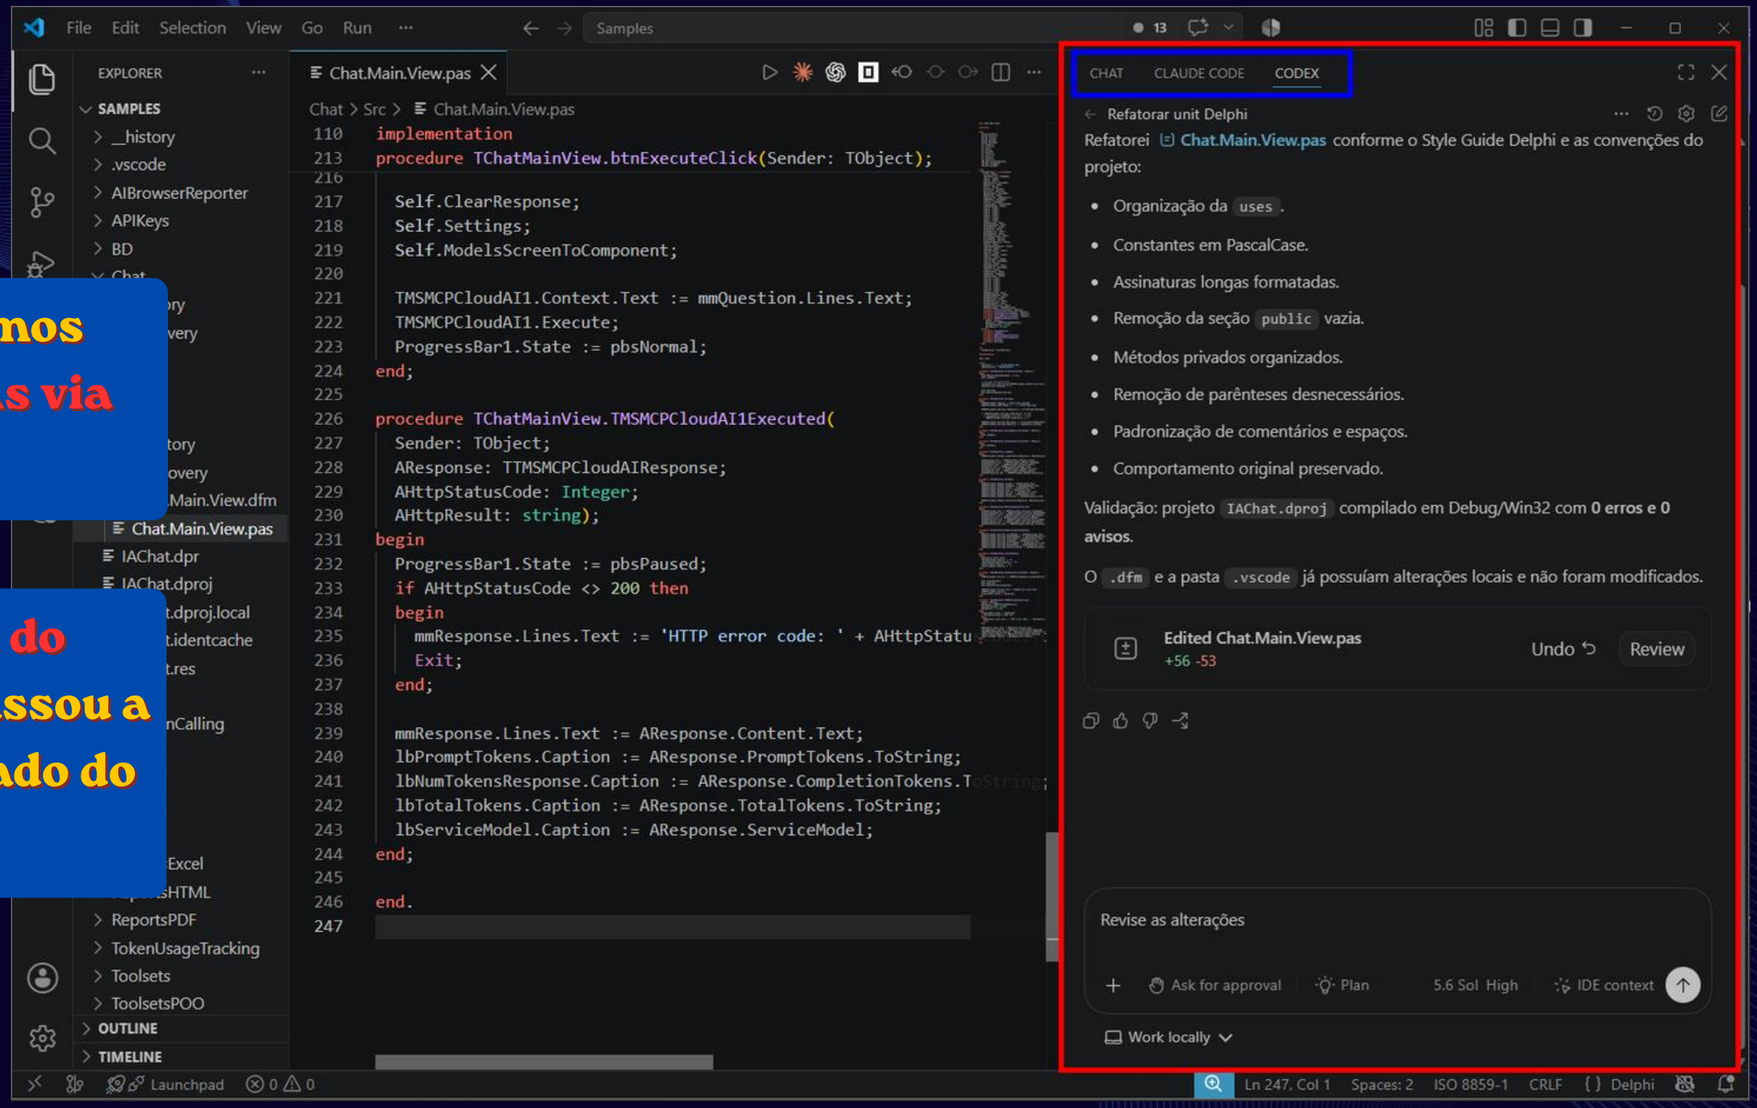
IA ainda estava fora do ambiente de desenvolvimento

Chats dentro da IDE

A IA entrou na IDE: menos copiar e colar, mais contexto e interação

Agora podemos acessar as IAs via API

O chat saiu do navegador e passou a trabalhar ao lado do código

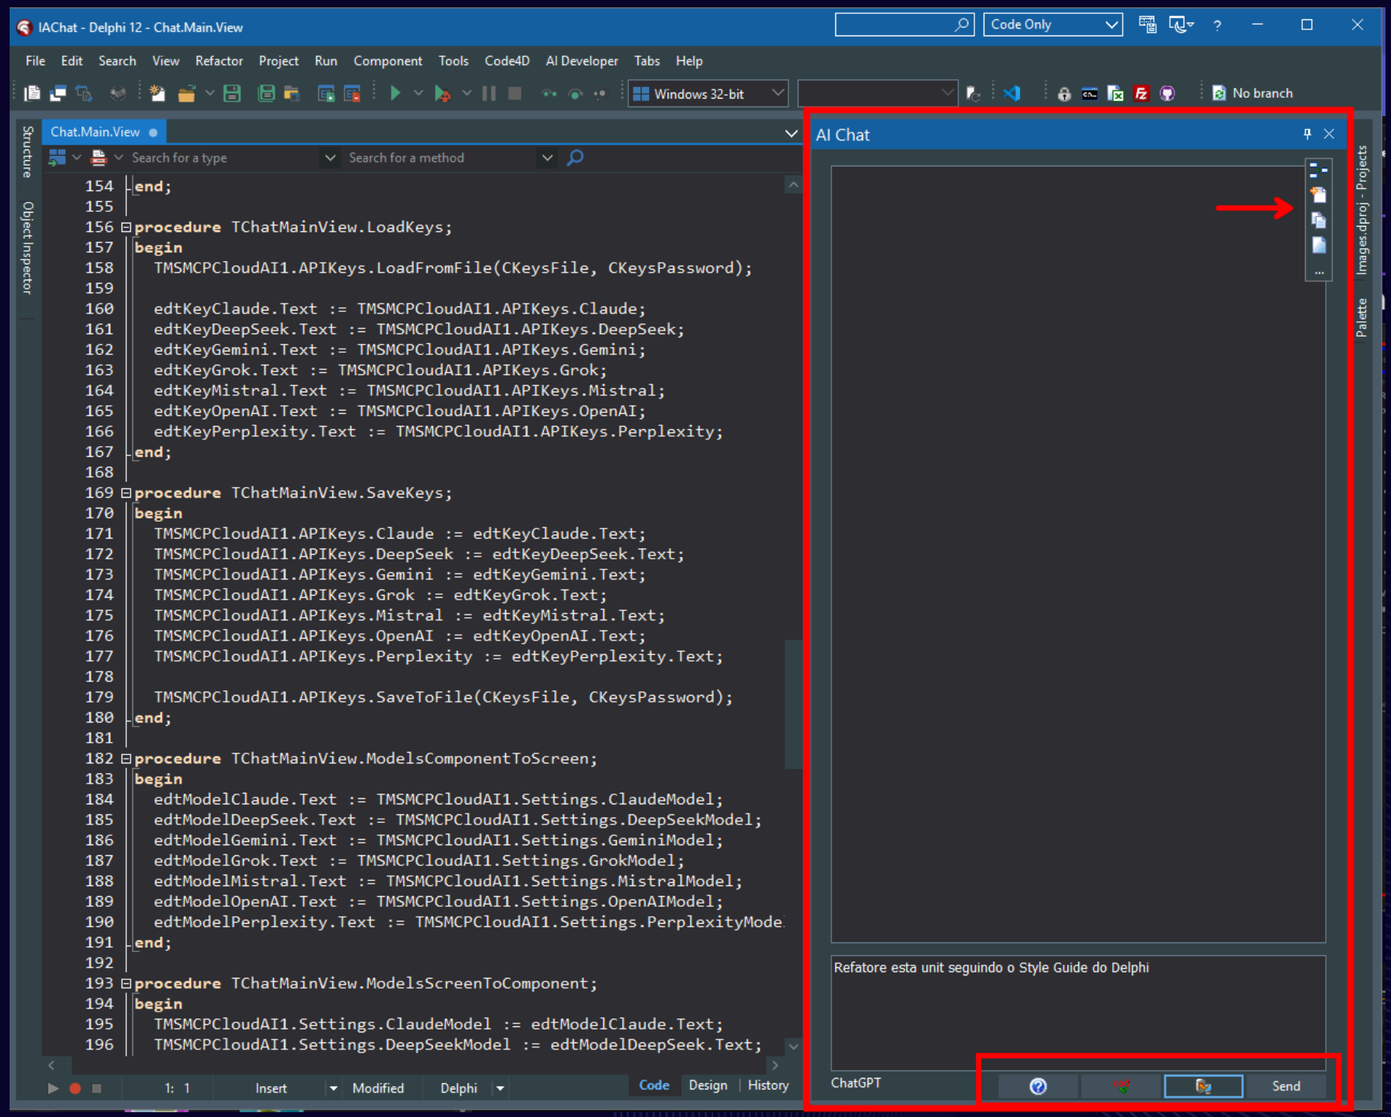


IA dentro do Delphi

A IA passou a fazer parte da própria IDE e do fluxo de desenvolvimento

O Delphi AI Developer foi um dos primeiros plugins a levar IA para dentro do Delphi






```
154 end;
155
156 procedure TChatMainView.LoadKeys;
157 begin
158   TMSMCPCloudAI1.APIKeys.LoadFromFile(CKeysFile, CKeysPassword);
159
160   edtKeyClaude.Text := TMSMCPCloudAI1.APIKeys.Claude;
161   edtKeyDeepSeek.Text := TMSMCPCloudAI1.APIKeys.DeepSeek;
162   edtKeyGemini.Text := TMSMCPCloudAI1.APIKeys.Gemini;
163   edtKeyGrok.Text := TMSMCPCloudAI1.APIKeys.Grok;
164   edtKeyMistral.Text := TMSMCPCloudAI1.APIKeys.Mistral;
165   edtKeyOpenAI.Text := TMSMCPCloudAI1.APIKeys.OpenAI;
166   edtKeyPerplexity.Text := TMSMCPCloudAI1.APIKeys.Perplexity;
167 end;
168
169 procedure TChatMainView.SaveKeys;
170 begin
171   TMSMCPCloudAI1.APIKeys.Claude := edtKeyClaude.Text;
172   TMSMCPCloudAI1.APIKeys.DeepSeek := edtKeyDeepSeek.Text;
173   TMSMCPCloudAI1.APIKeys.Gemini := edtKeyGemini.Text;
174   TMSMCPCloudAI1.APIKeys.Grok := edtKeyGrok.Text;
175   TMSMCPCloudAI1.APIKeys.Mistral := edtKeyMistral.Text;
176   TMSMCPCloudAI1.APIKeys.OpenAI := edtKeyOpenAI.Text;
177   TMSMCPCloudAI1.APIKeys.Perplexity := edtKeyPerplexity.Text;
178
179   TMSMCPCloudAI1.APIKeys.SaveToFile(CKeysFile, CKeysPassword);
180 end;
181
182 procedure TChatMainView.ModelsComponentToScreen;
183 begin
184   edtModelClaude.Text := TMSMCPCloudAI1.Settings.ClaudeModel;
185   edtModelDeepSeek.Text := TMSMCPCloudAI1.Settings.DeepSeekModel;
186   edtModelGemini.Text := TMSMCPCloudAI1.Settings.GeminiModel;
187   edtModelGrok.Text := TMSMCPCloudAI1.Settings.GrokModel;
188   edtModelMistral.Text := TMSMCPCloudAI1.Settings.MistralModel;
189   edtModelOpenAI.Text := TMSMCPCloudAI1.Settings.OpenAIModel;
190   edtModelPerplexity.Text := TMSMCPCloudAI1.Settings.PerplexityMode
191 end;
192
193 procedure TChatMainView.ModelsScreenToComponent;
194 begin
195   TMSMCPCloudAI1.Settings.ClaudeModel := edtModelClaude.Text;
196   TMSMCPCloudAI1.Settings.DeepSeekModel := edtModelDeepSeek.Text;
```

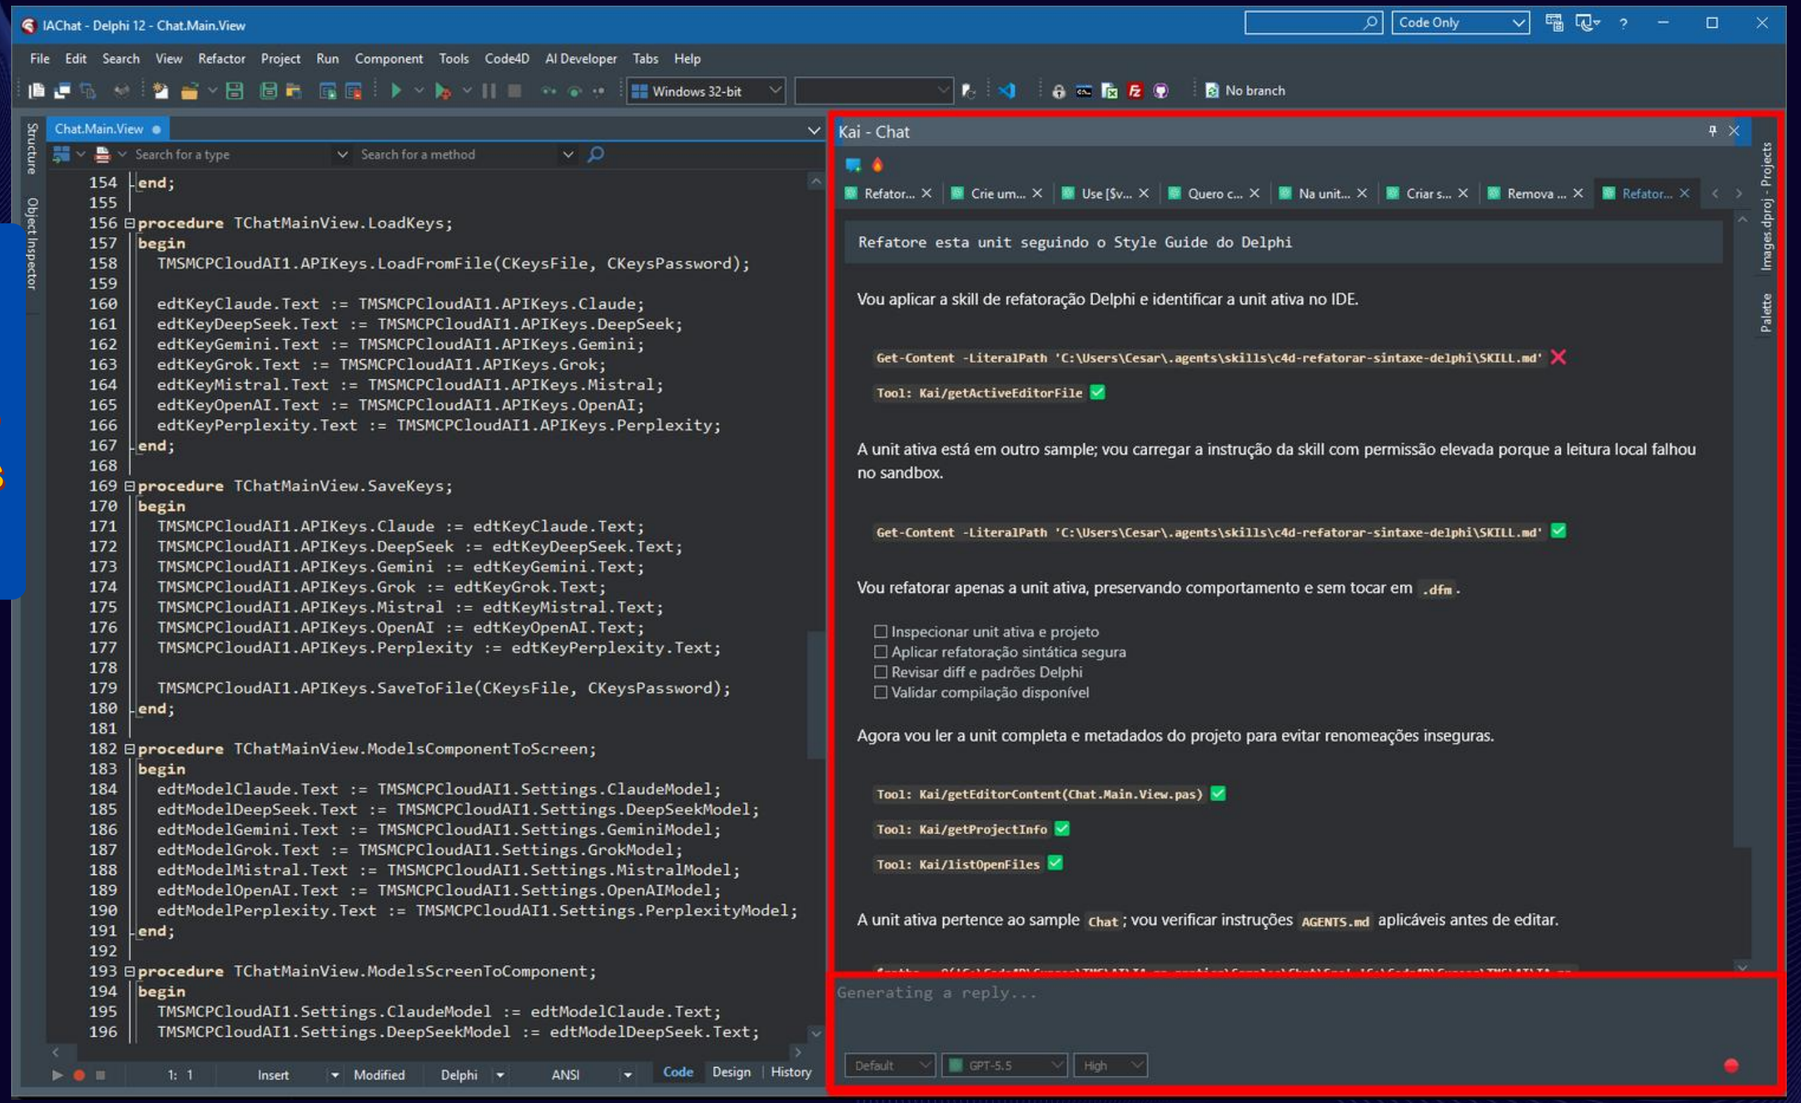
Repositório do plugin

Chats dentro do Delphi

O Kai permitindo gerar código, compilar projetos e corrigir erros diretamente na IDE

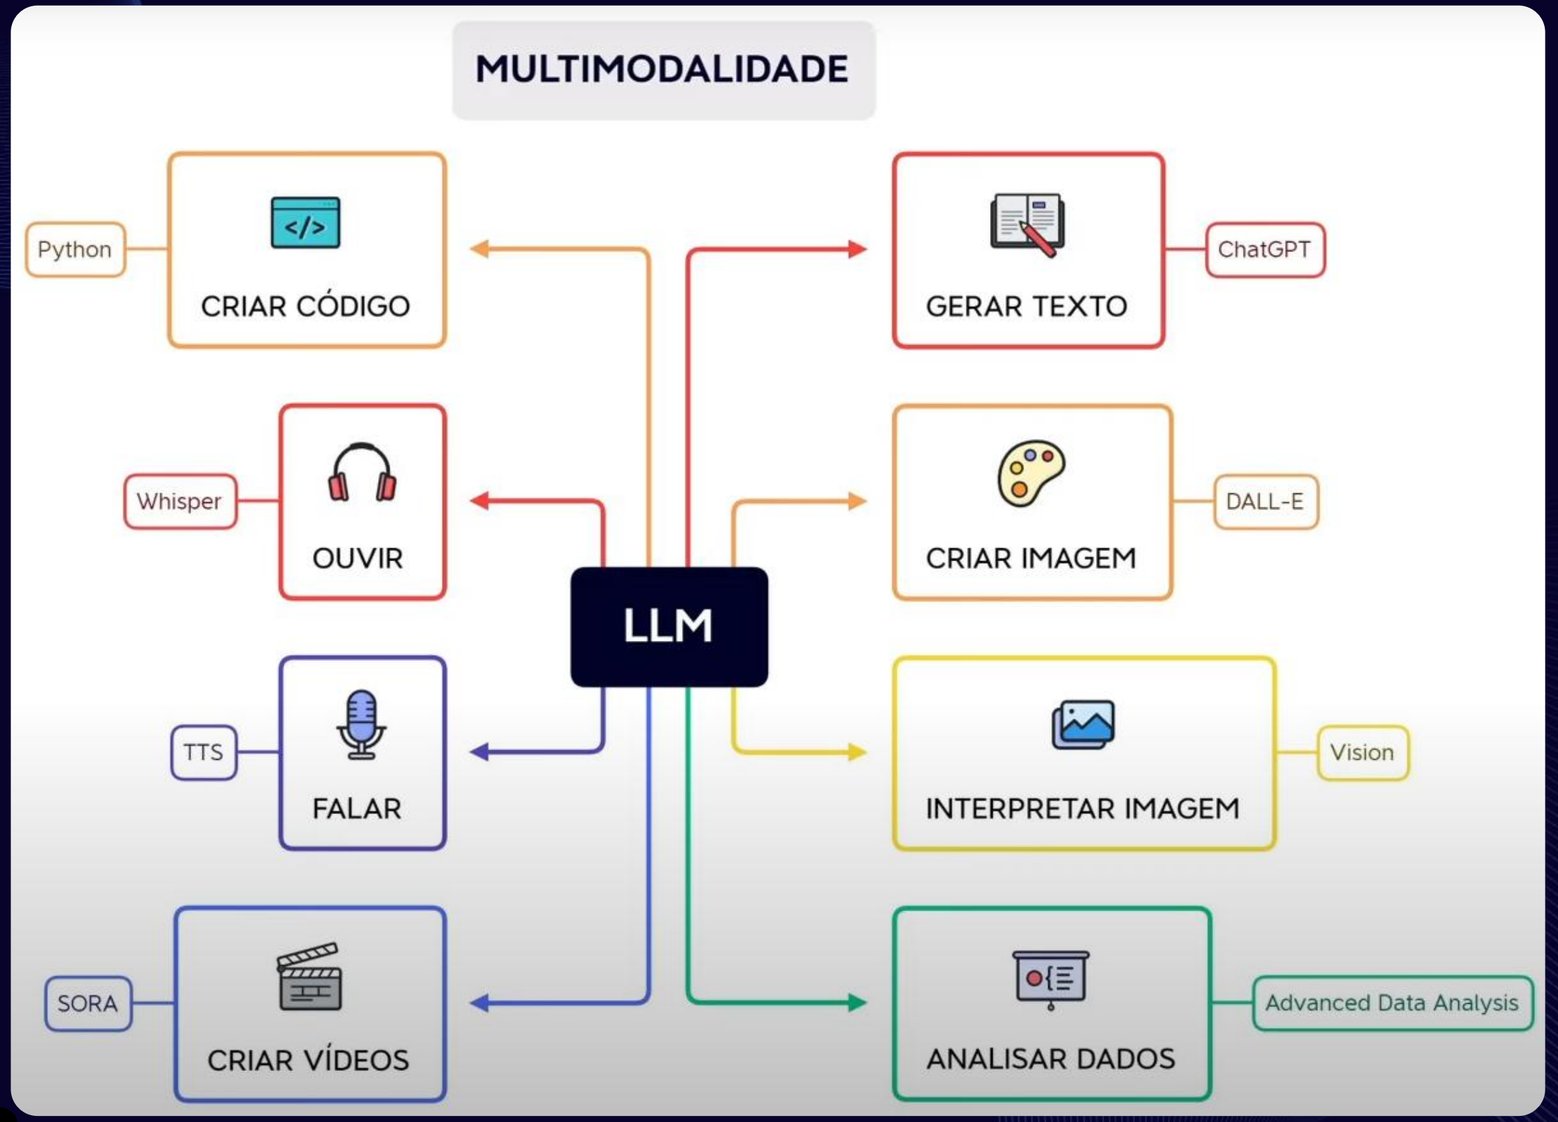
O Kai permite utilizar Subscriptions do ChatGPT, Claude Code, GitHub Copilot e outros serviços





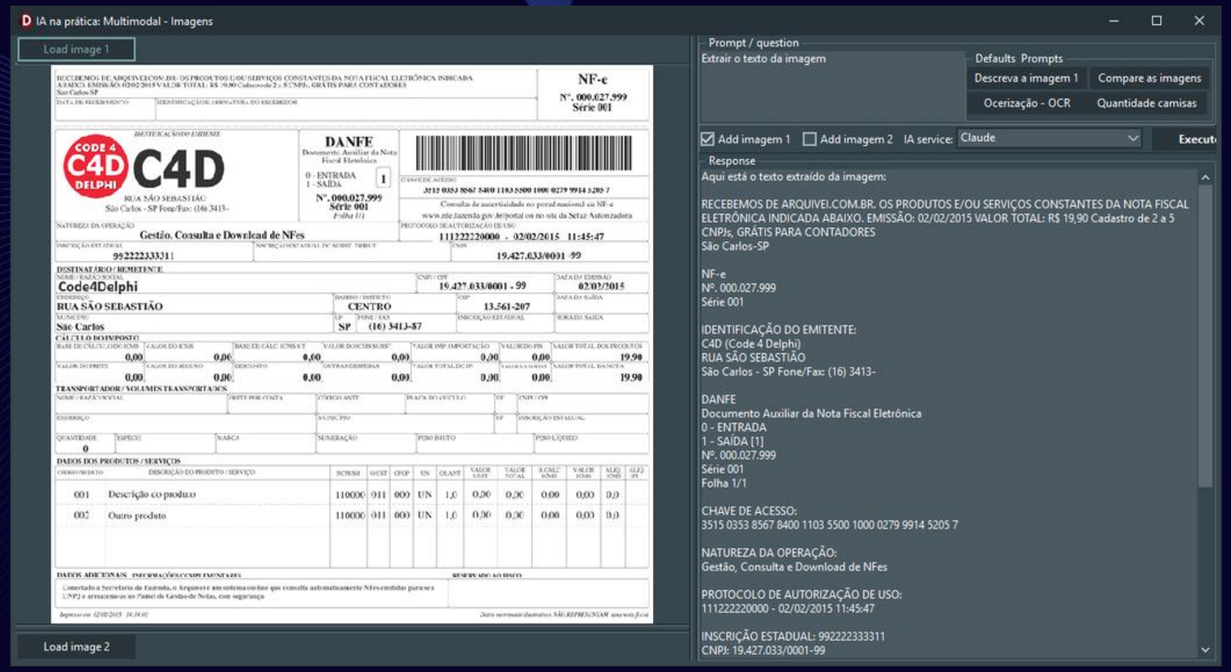
Multimodal

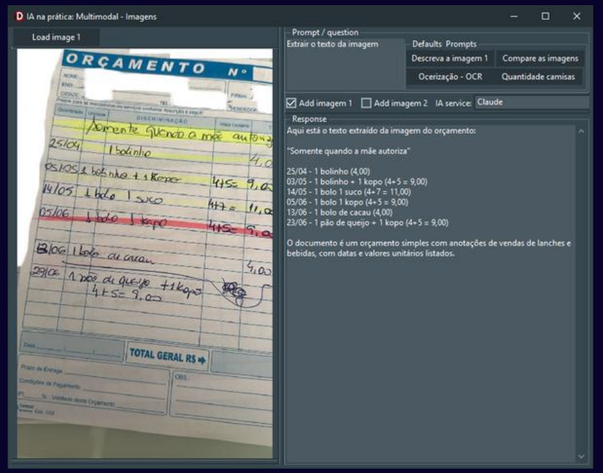
Manipulando arquivos e imagens

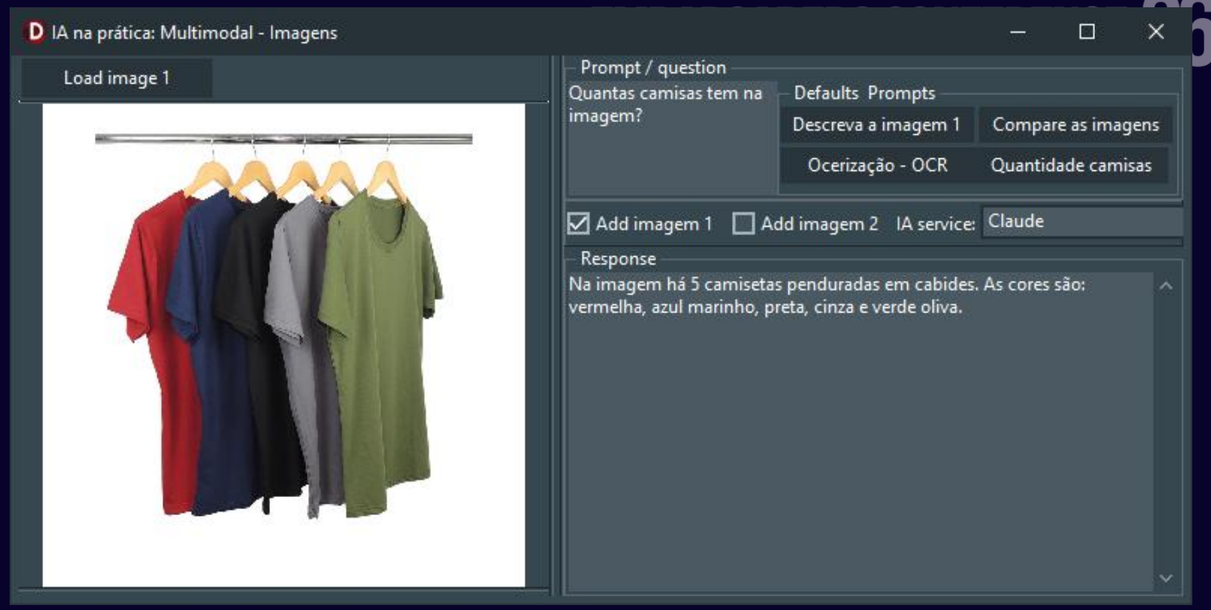


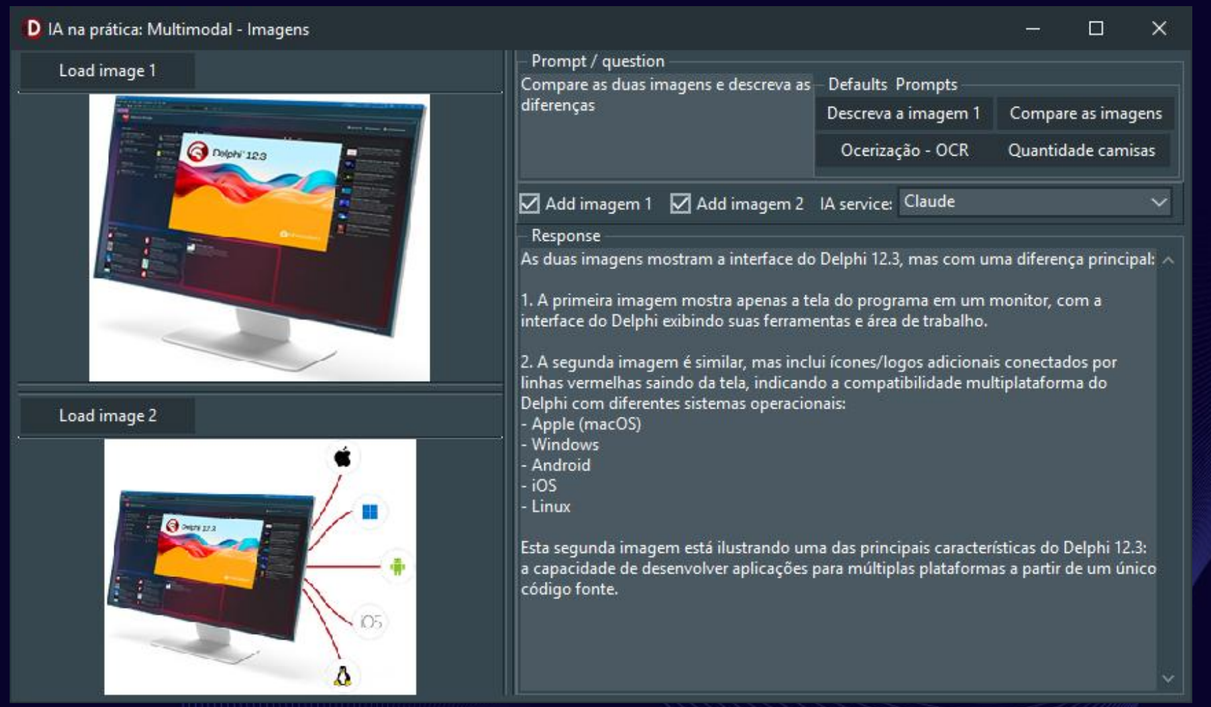
Vídeo de demonstração

Multimodal





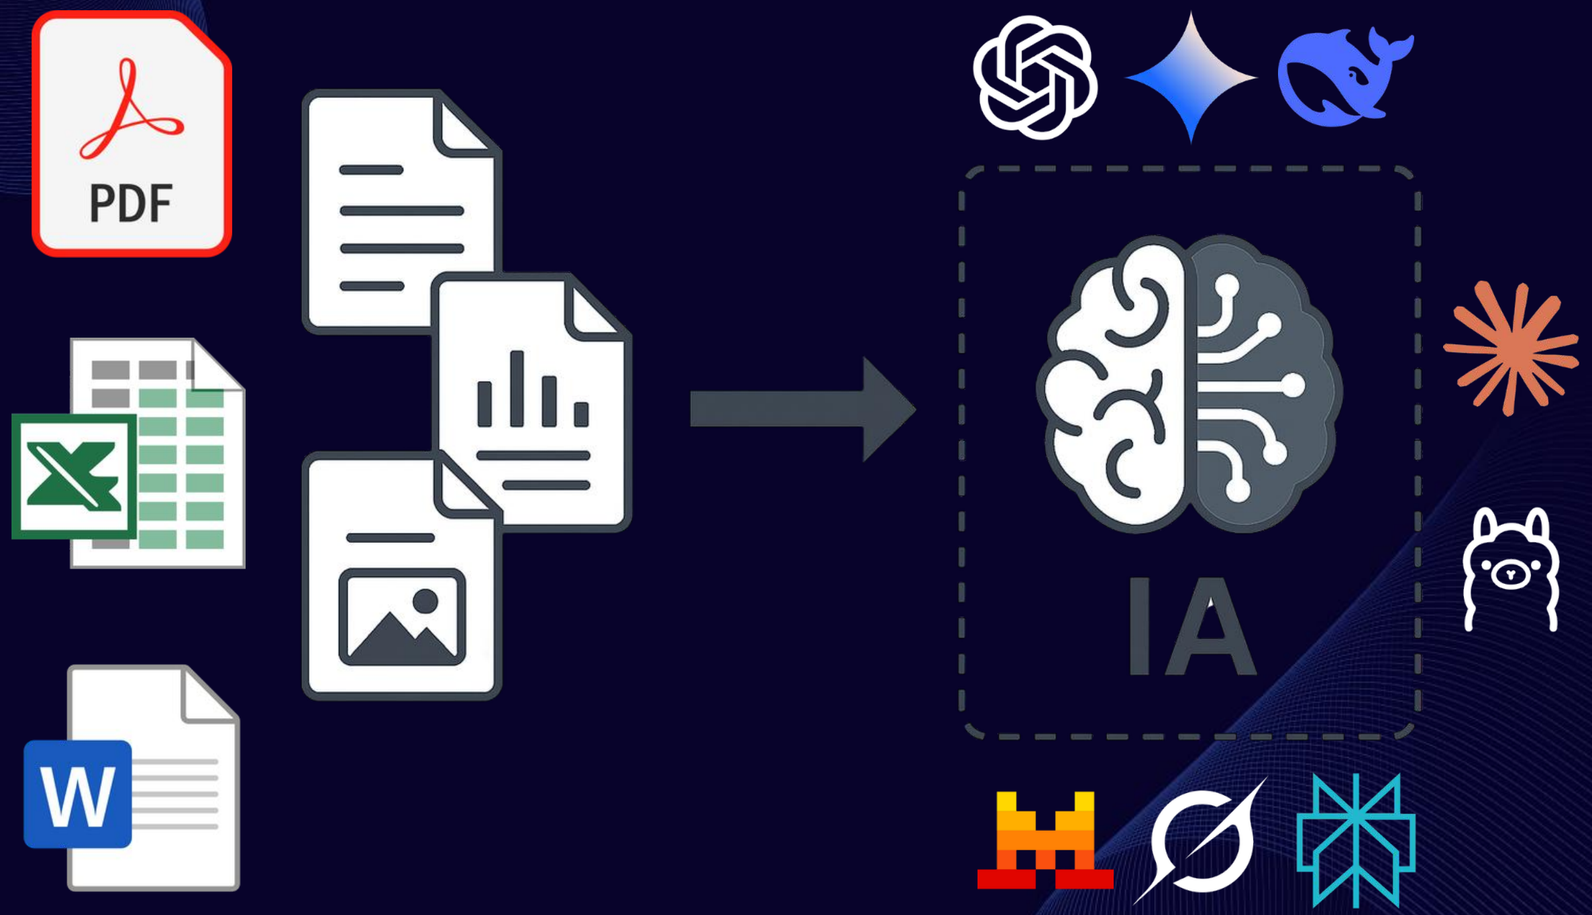




Vídeo de demonstração

RAG - Retrieval-Augmented Generation

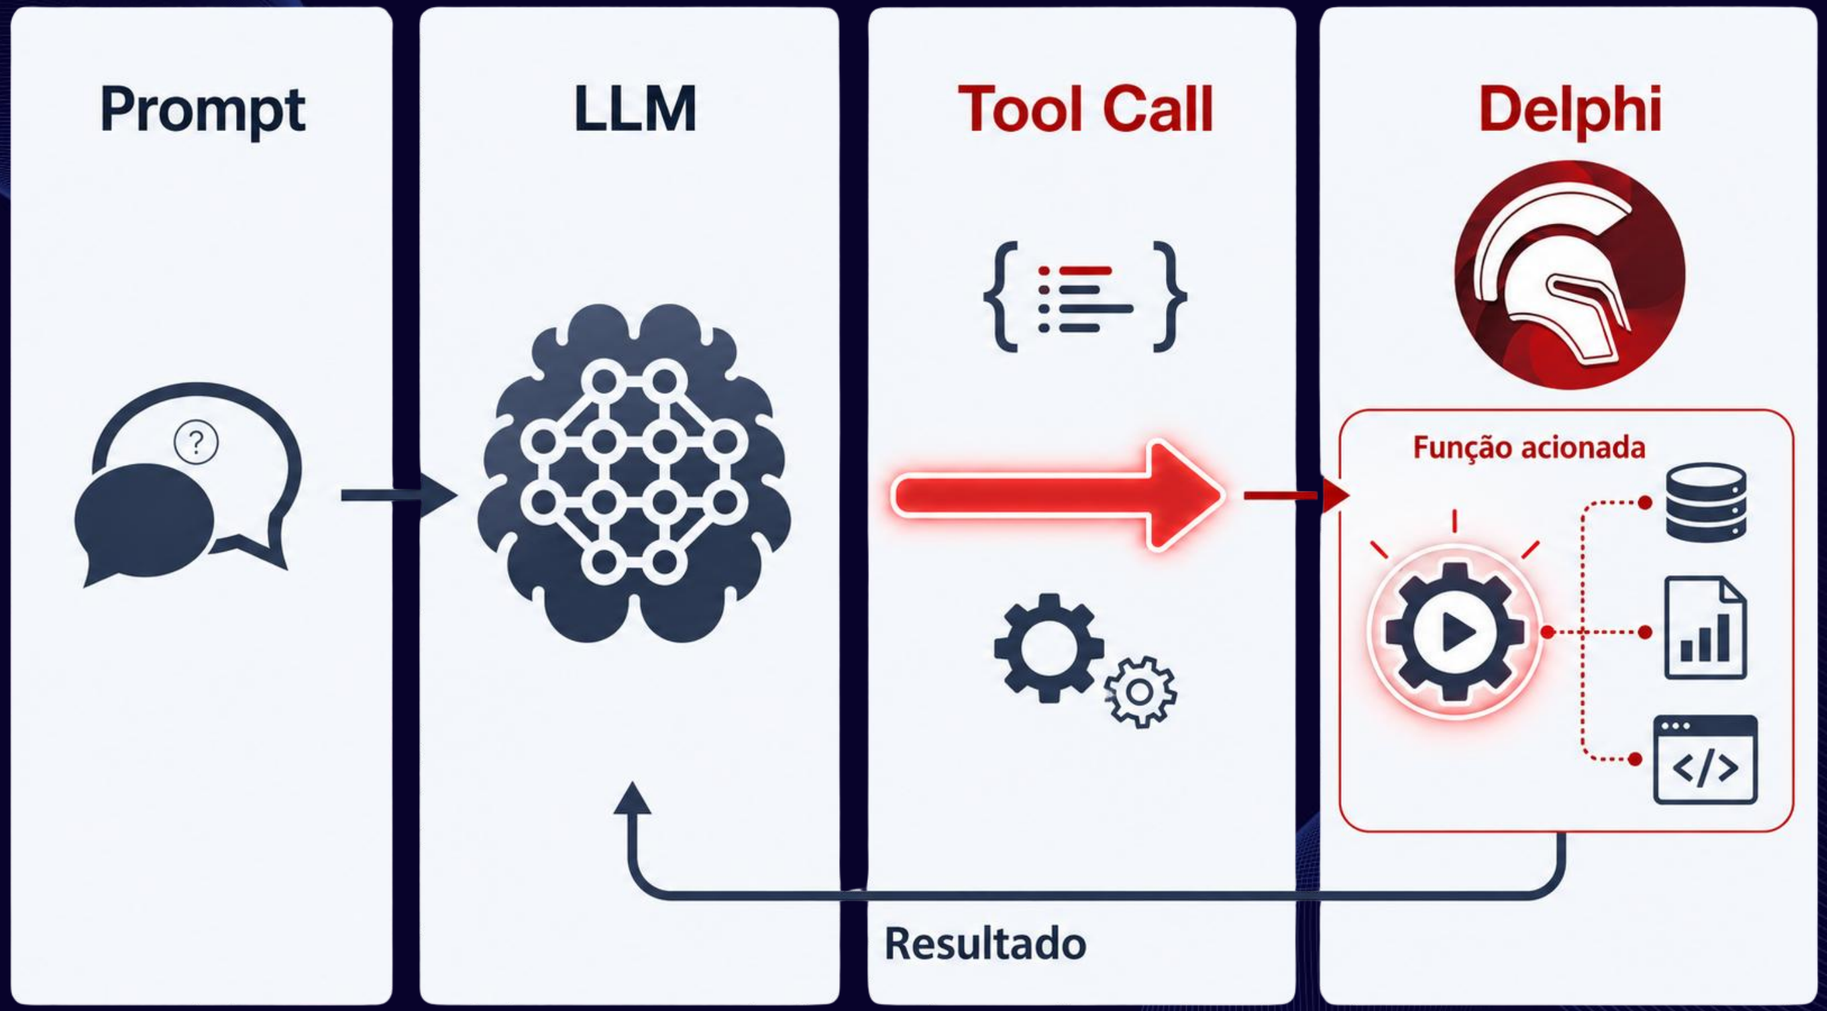
Alimente a IA com suas informações e documentos



Vídeo de demonstração

Tool Calling / Function Calling

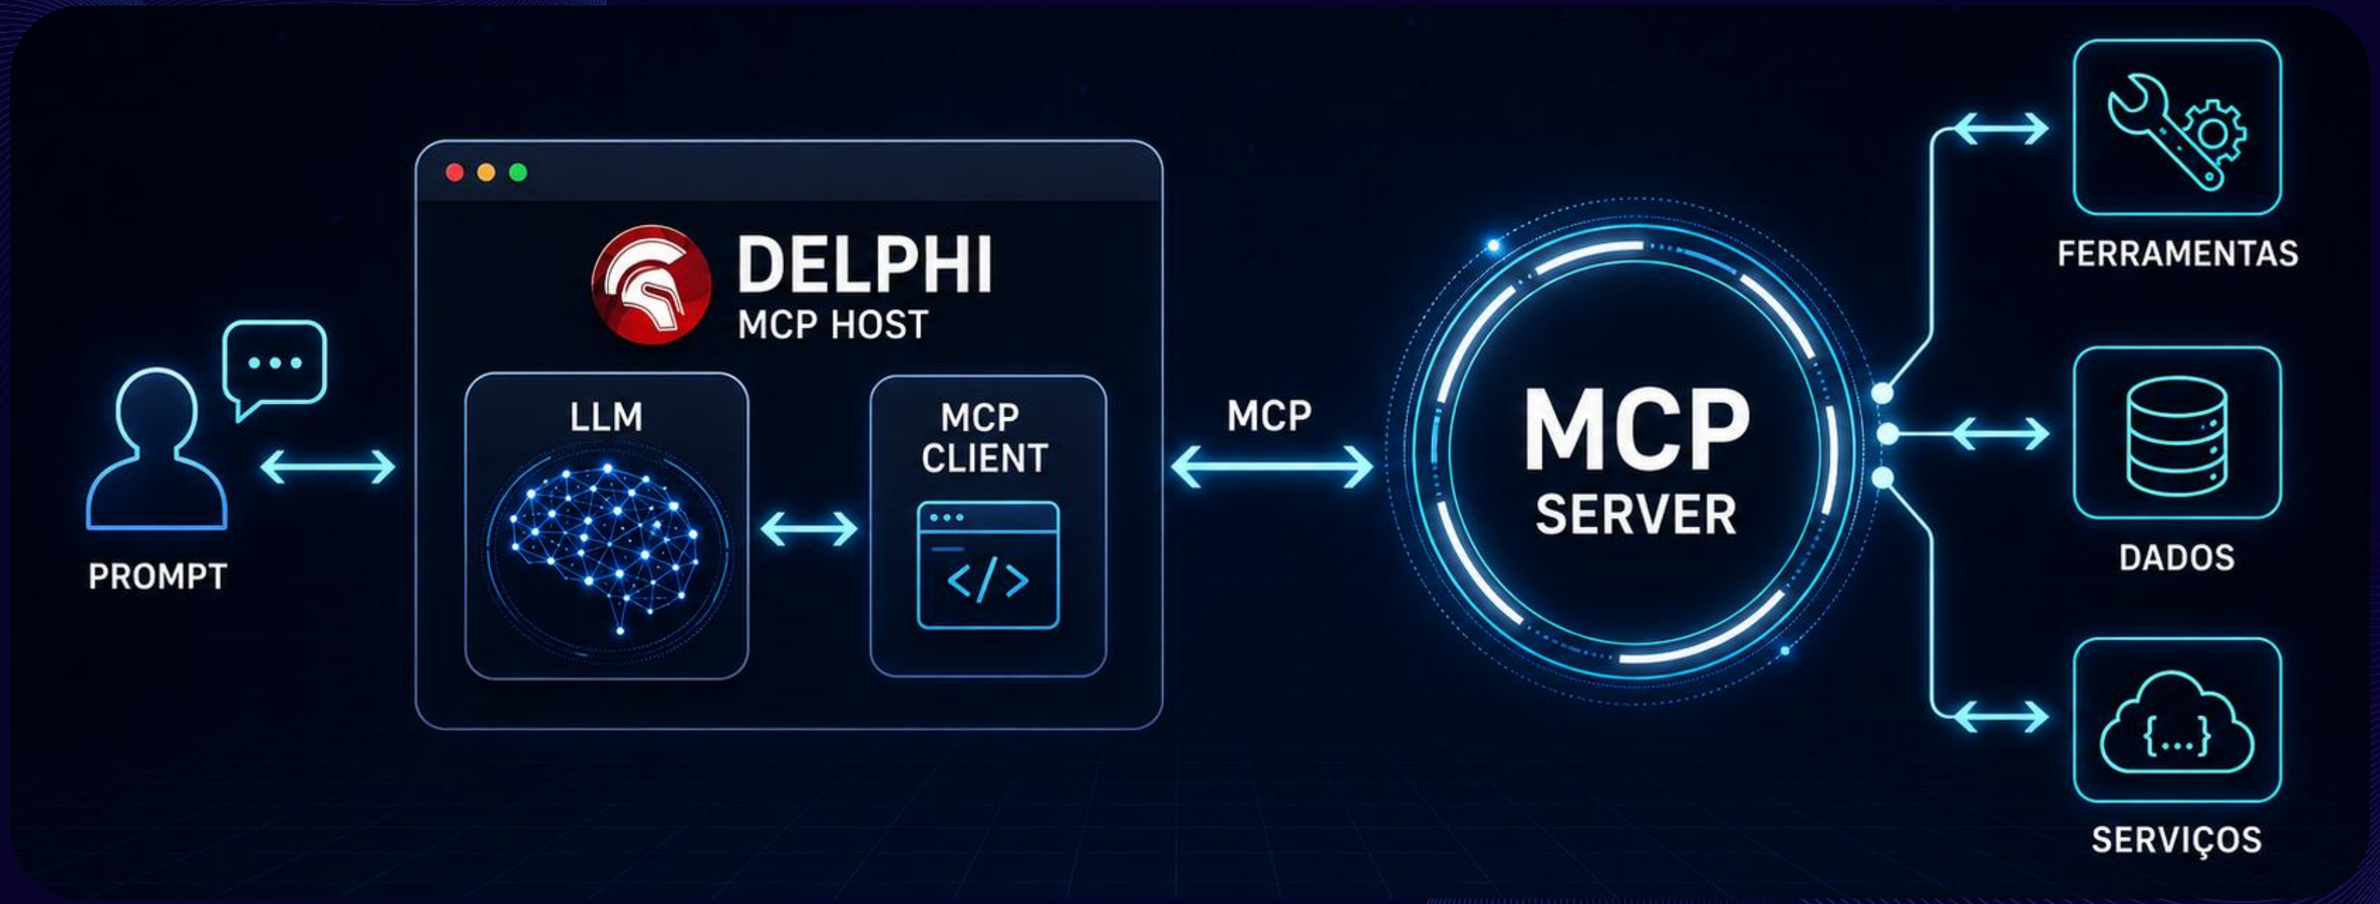
IA acionando funções do sistema



Vídeo de demonstração

MCP - Model Context Protocol

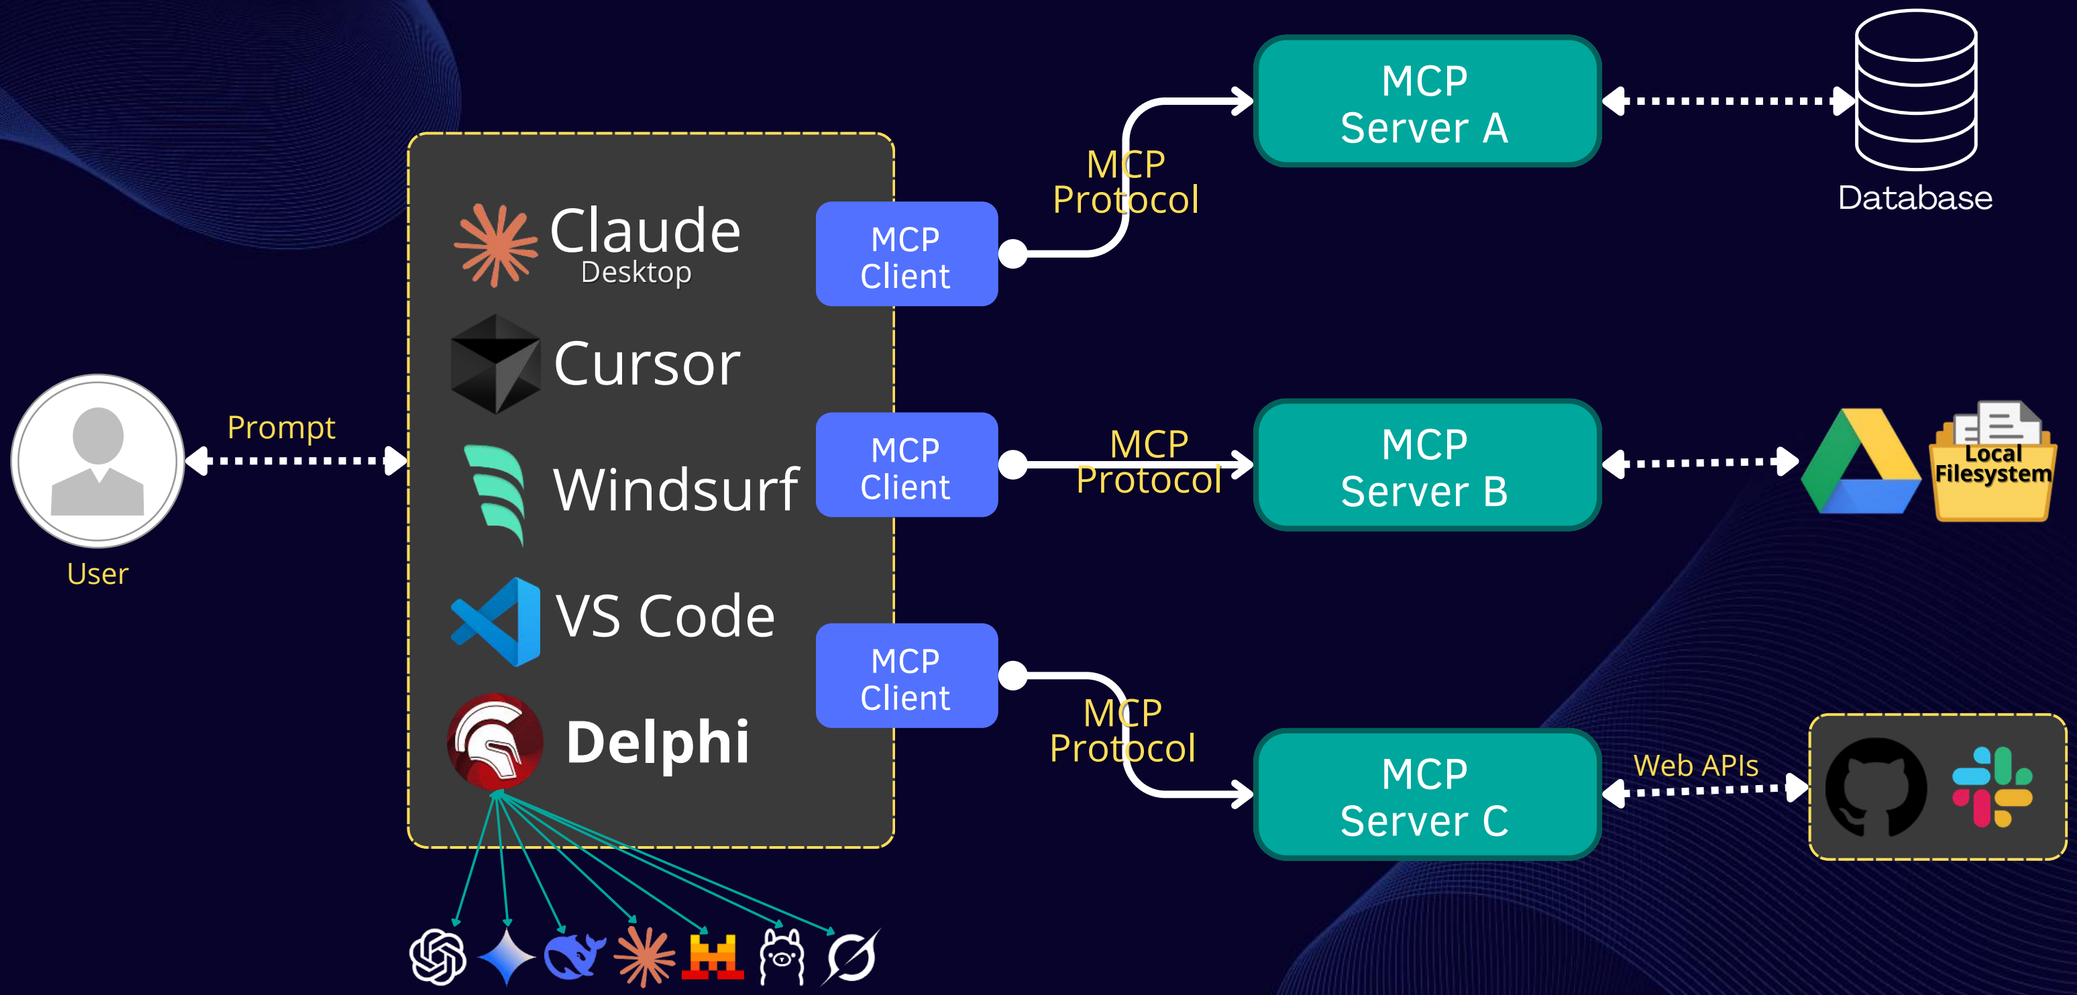
O protocolo que padroniza a conexão da IA com ferramentas, dados e sistemas



Vídeo de demonstração

MCP Server e Client

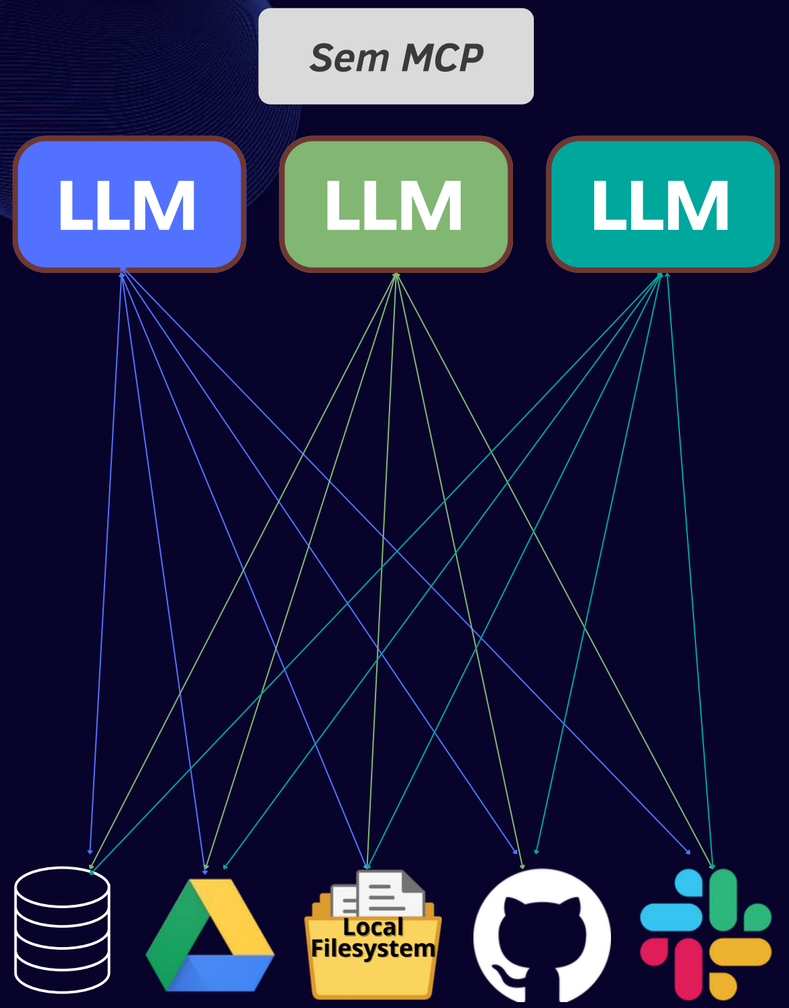
IA acionando funções do sistema

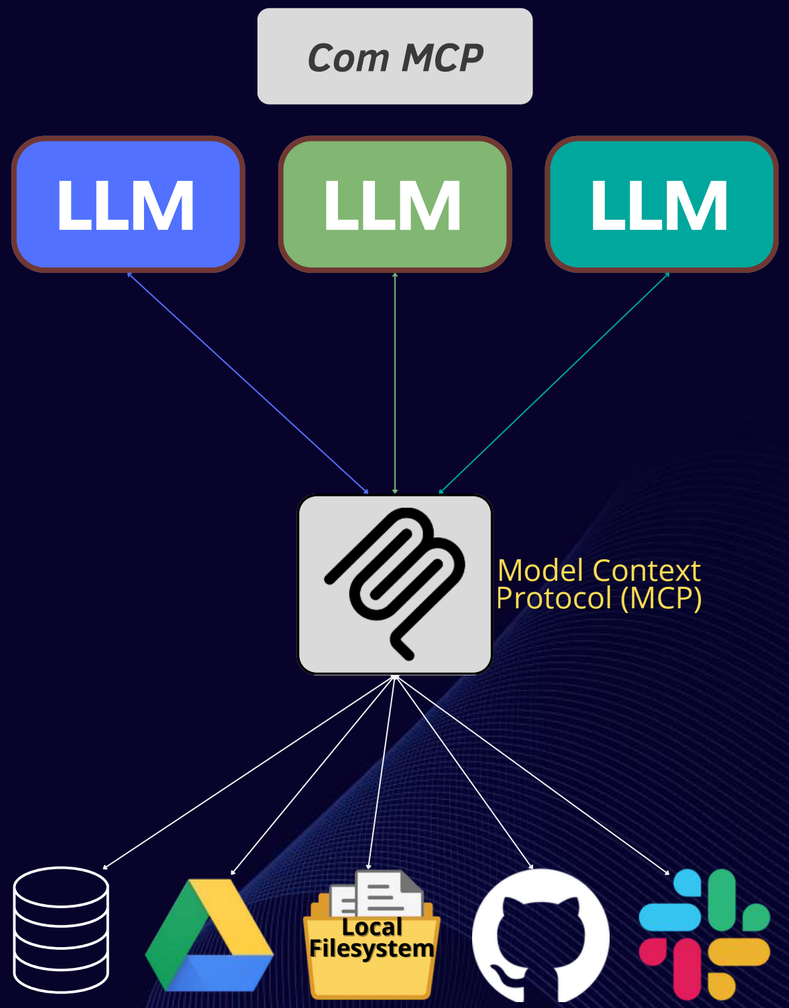


Vídeo de demonstração

MCP - Model Context Protocol

Antes e depois

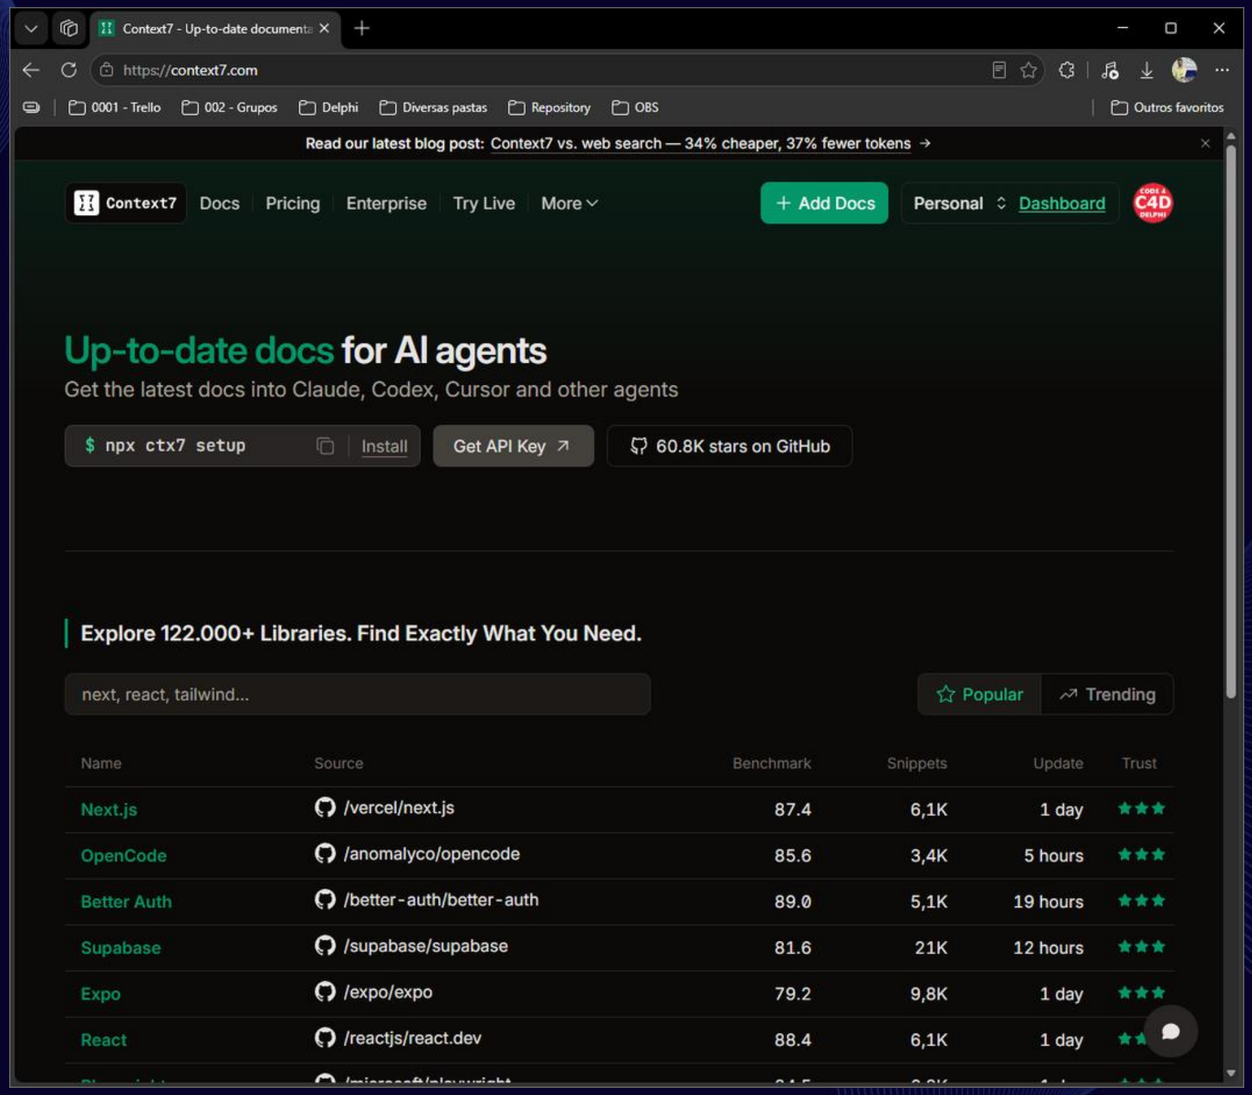




Vídeo de demonstração

context7.com

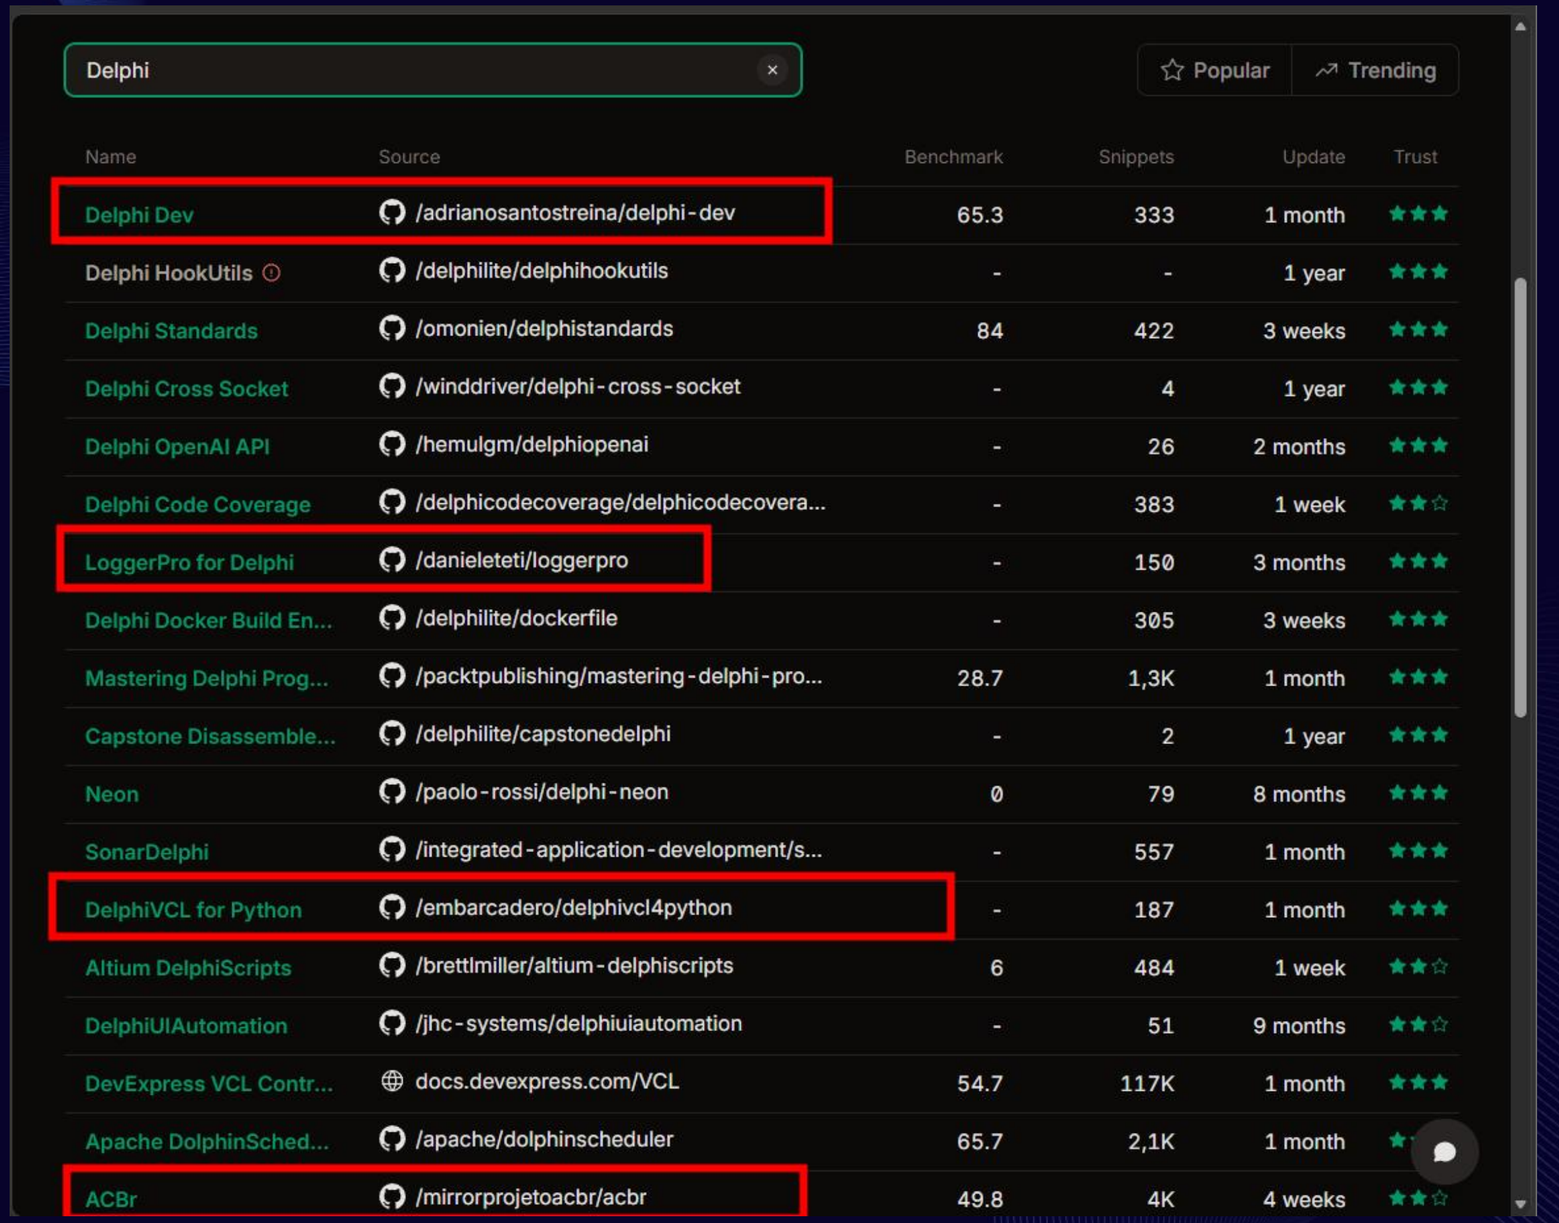
É um servidor MCP gratuito que fornece documentação atualizada e trechos de código para assistentes de programação com IA.



https://context7.com/

context7.com

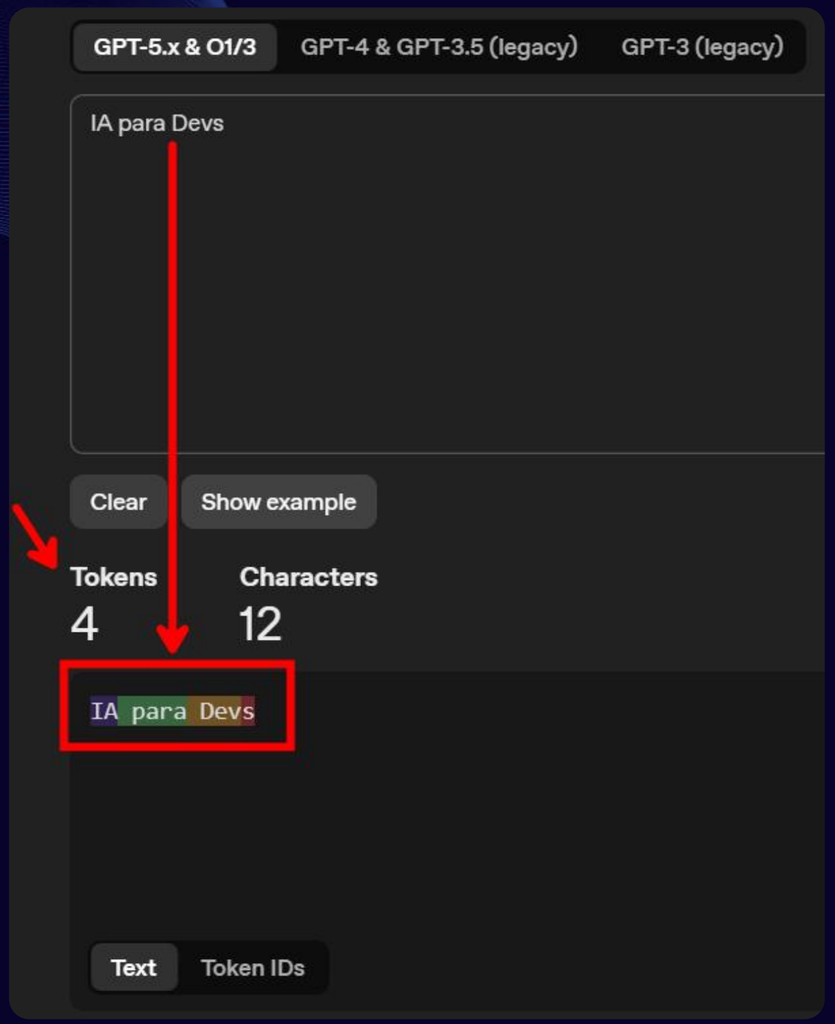
Tem Delphi?

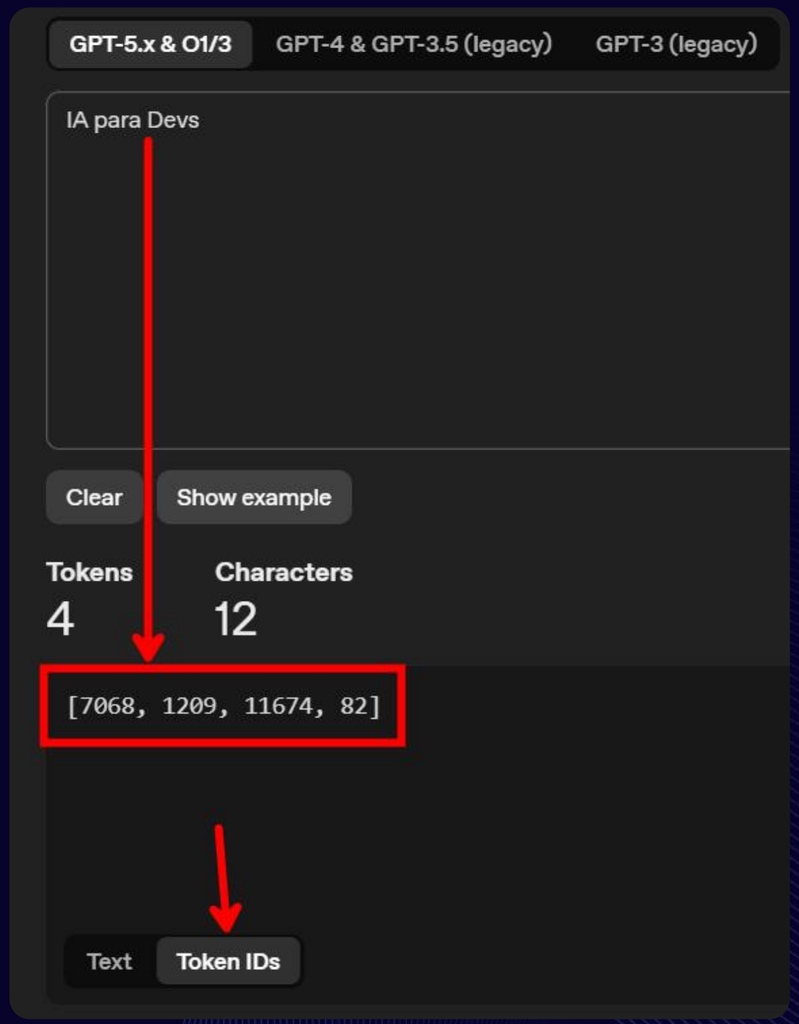


https://context7.com/

Tokens

A “unidade de medidas” das IAs





https://platform.openai.com/tokenizer

Tokens texto

Valores de referência

1 MILHÃO DE TOKENS

O que isso significa em páginas e palavras?



≈ 2.000 PÁGINAS DE TEXTO

Documento bem espaçado	Texto acadêmico ou comum	Texto mais compacto
≈ 3.000 páginas	≈ 1.875 páginas	≈ 1.500 páginas
(≈ 250 palavras/página)	(≈ 400 palavras/página)	(≈ 500 palavras/página)

1 TOKEN ≈ 0,75 PALAVRA EM INGLÊS

Em média, um token corresponde a cerca de três quartos de uma palavra em inglês.

1 PALAVRA ≈ 1,3 TOKEN EM INGLÊS

Em inglês, uma palavra costuma ser dividida em cerca de 1,3 token.

EM PORTUGUÊS 1 PALAVRA ≈ 1,4 TOKEN

Em português, devido à nossa estrutura e acentuação, uma palavra equivale a cerca de 1,4 token.

1 MILHÃO DE TOKENS ≈ 750 MIL PALAVRAS (EM INGLÊS)

Baseado na média de 0,75 palavra por token em inglês.

Em português: ≈ 714 mil palavras (usando 1 palavra ≈ 1,4 token)

EM RESUMO

1 MILHÃO DE TOKENS ≈ 2.000 PÁGINAS

750 MIL PALAVRAS (EM INGLÊS)

Esses valores são aproximações e podem variar conforme o idioma, o assunto, o estilo de escrita e a forma como o texto é tokenizado.

Doc Claude **Doc Gemini**

Tokens imagens

Como as IAs calculam os tokens de imagens?

Cada modelo usa sua própria estratégia para transformar imagens em tokens visuais



Exemplo: imagem Full HD (1920 × 1080 px)

Modelo	Como calcula	Tokens aproximados
GPT-5.6	Varia conforme o nível de detalhe	Variável
Claude (alta resolução)	Patches de 28 × 28 px	≈ 2.691
Gemini 3 (High)	Orçamento visual fixo	≈ 1.120
Gemini 3 (Ultra High)	Mais detalhes visuais	≈ 2.240

Importante: não existe um padrão universal. O consumo depende do modelo, da resolução da imagem e do nível de detalhe usado.

Uma única imagem Full HD pode consumir mais de 1.000 tokens na janela de contexto.

Doc Gemini **Doc Claude**

Tokens multimodal Gemini

COMO O GEMINI CALCULA TOKENS

IMAGENS

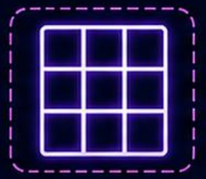


Imagens ≤ 384 px
em ambas as dimensões

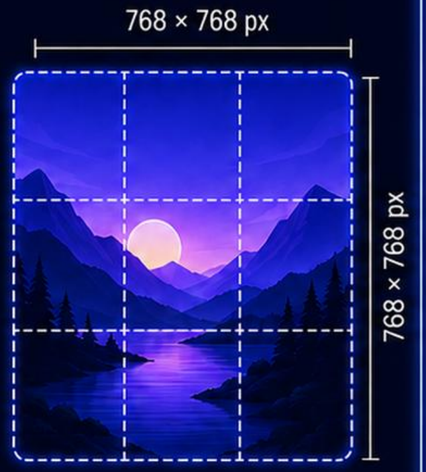
258 TOKENS

IMAGENS MAIORES

Divididas em blocos de 768 × 768 px

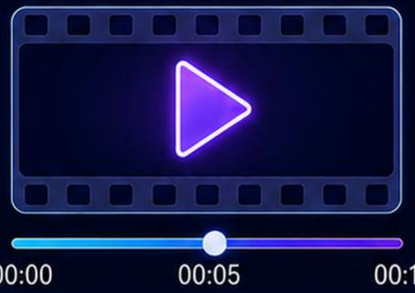


258
TOKENS
POR BLOCO



VÍDEO

263
TOKENS
POR SEGUNDO



ÁUDIO

32
TOKENS
POR SEGUNDO



EM RESUMO

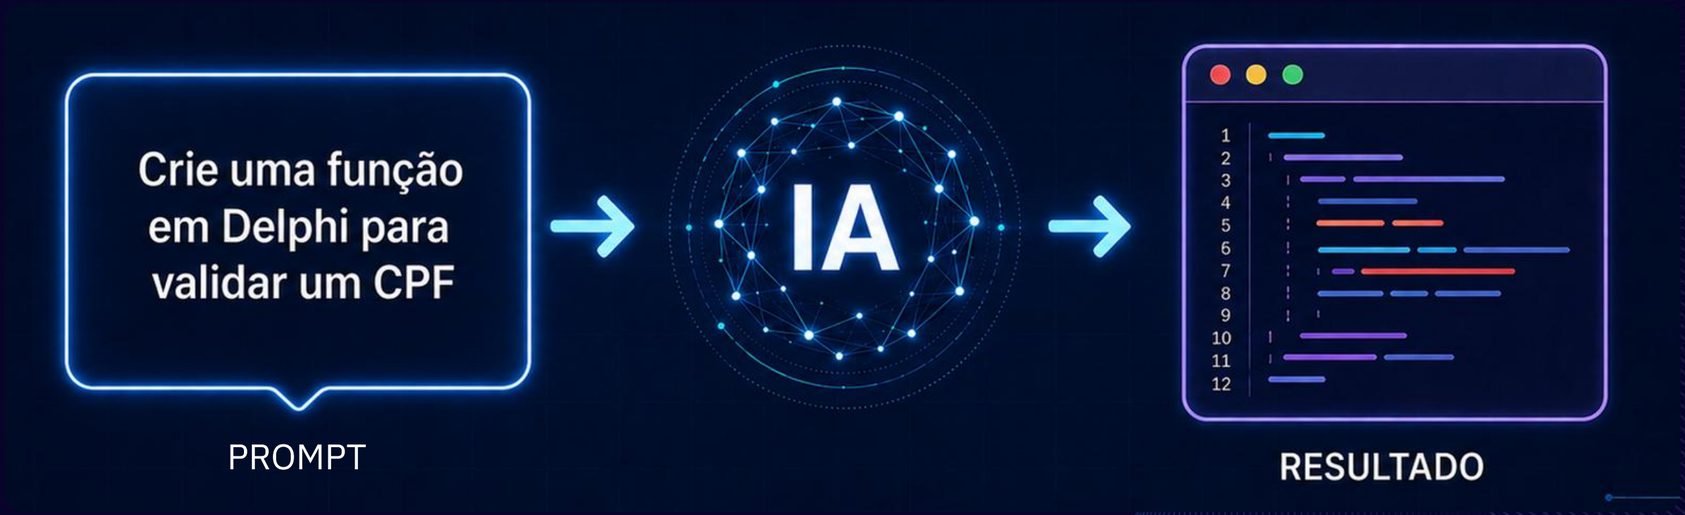
- Imagem pequena: **258** tokens
- Imagem grande: **258** tokens por bloco
- Vídeo: **263** tokens/s
- Áudio: **32** tokens/s

Doc Gemini

Prompt

É a instrução que orienta o que a IA deve fazer

É o texto em linguagem natural que enviamos para IA



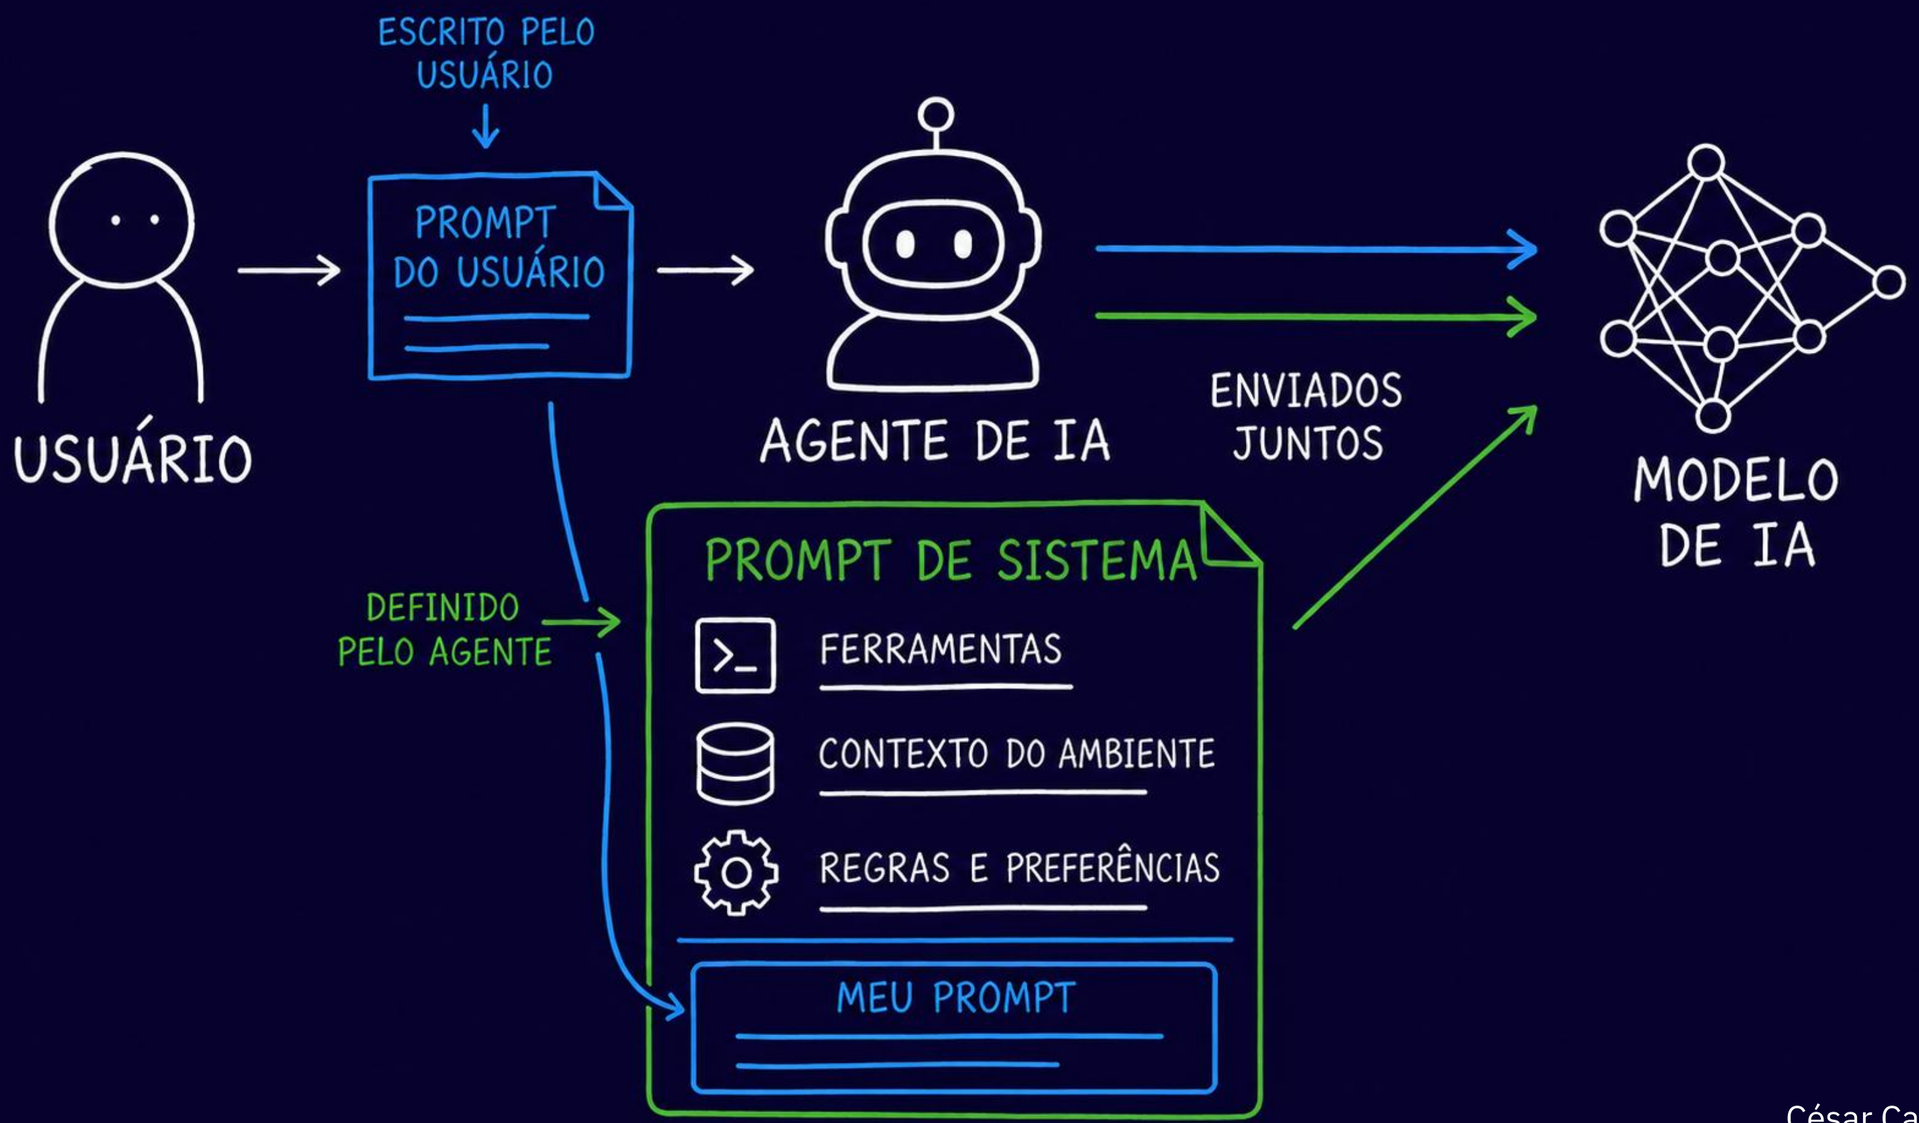
System prompt - prompt de sistema

É uma instrução oculta dada apara a IA antes de qualquer pergunta do usuário

Normalmente não alteramos diretamente o System Prompt.
Para adicionar instruções próprias e permanentes, utiliza-se principalmente o arquivo AGENTS.md

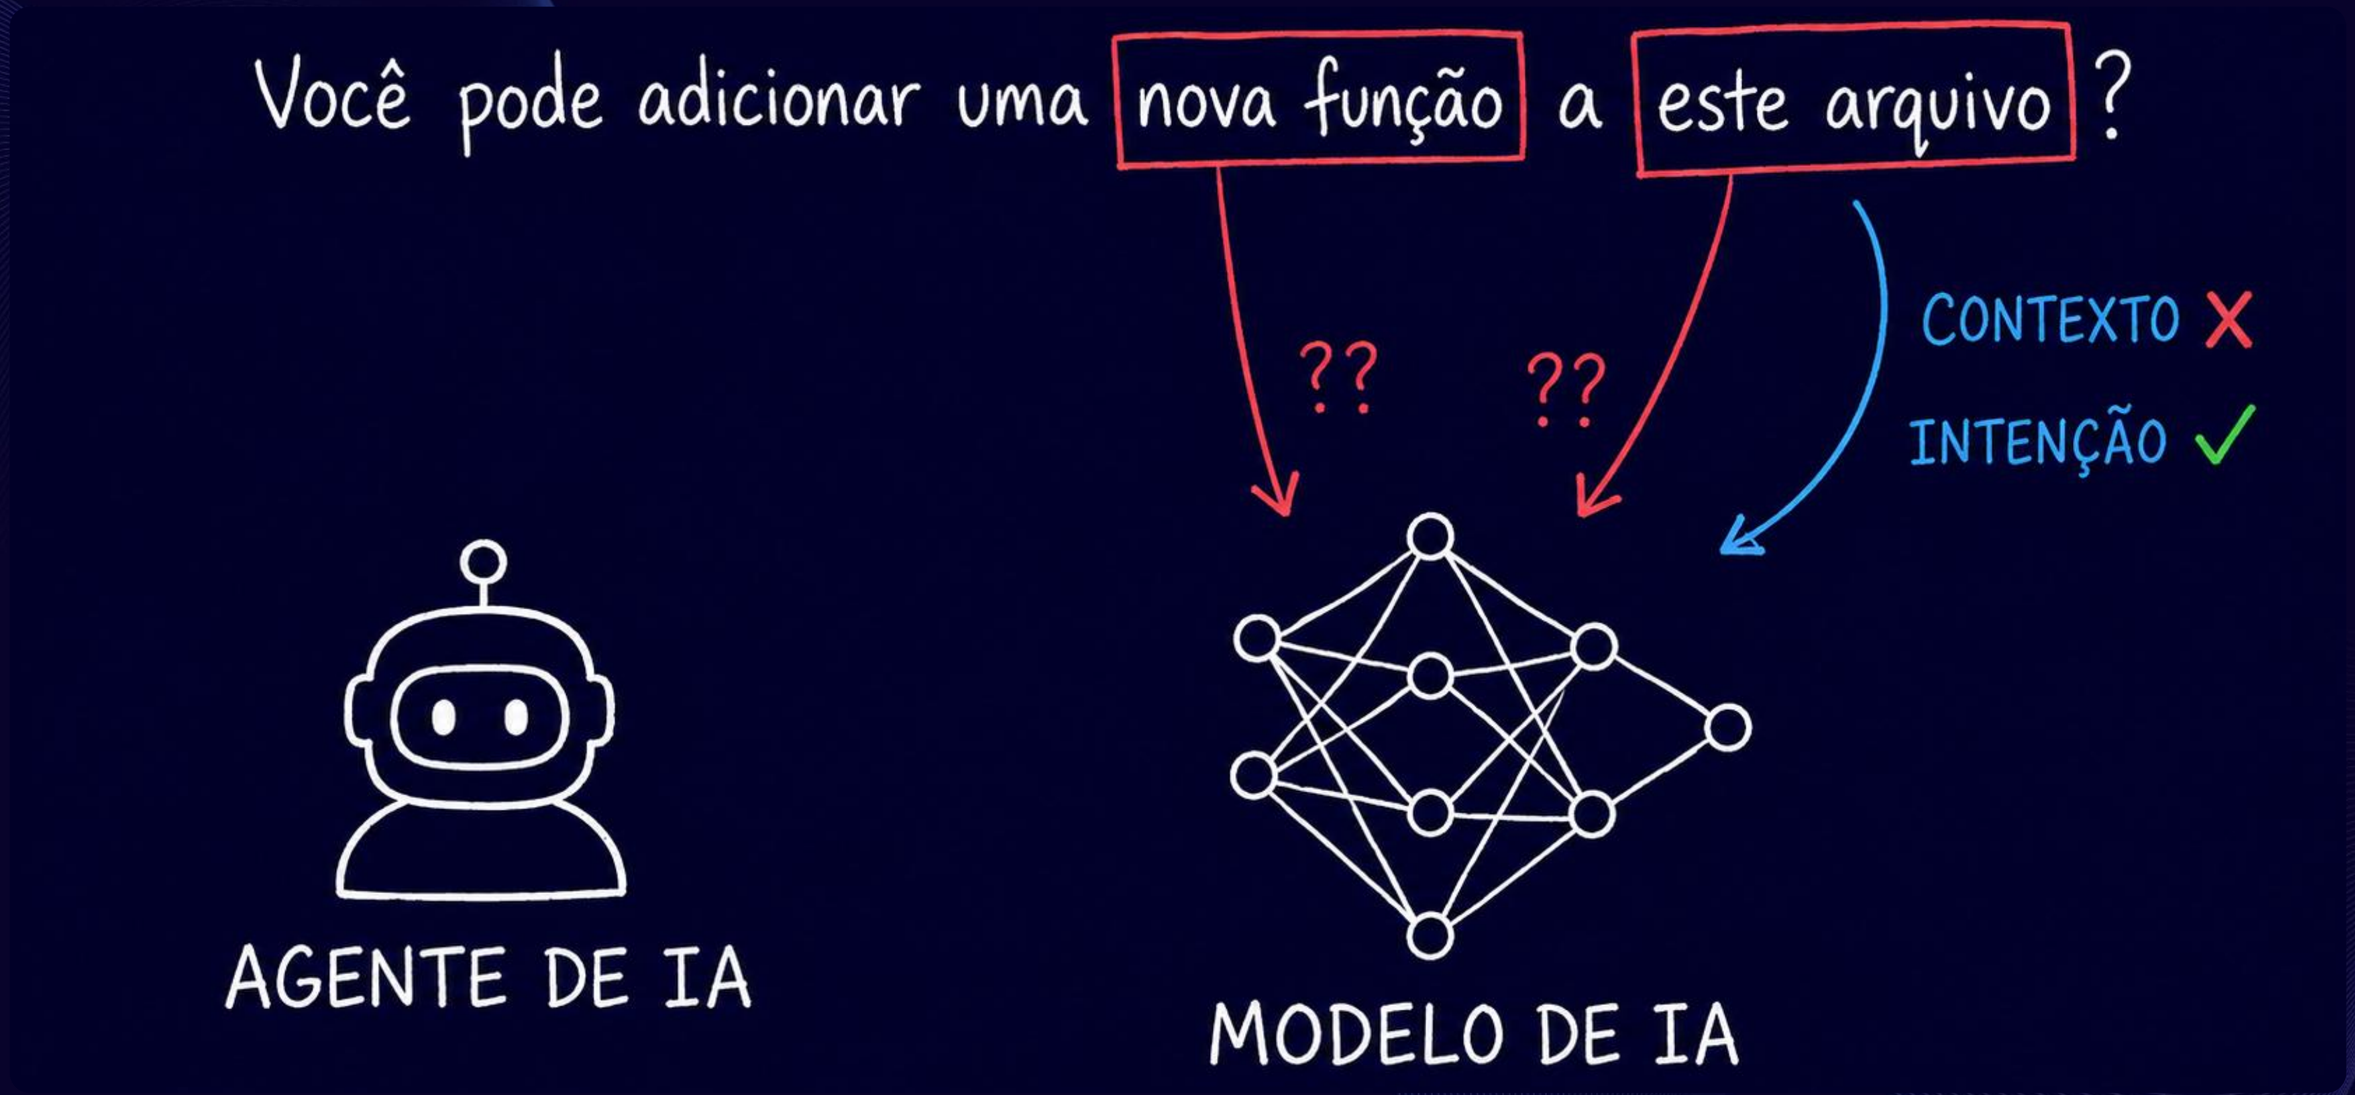
System prompt - prompt de sistema

Seu prompt é anexado ao System Prompt



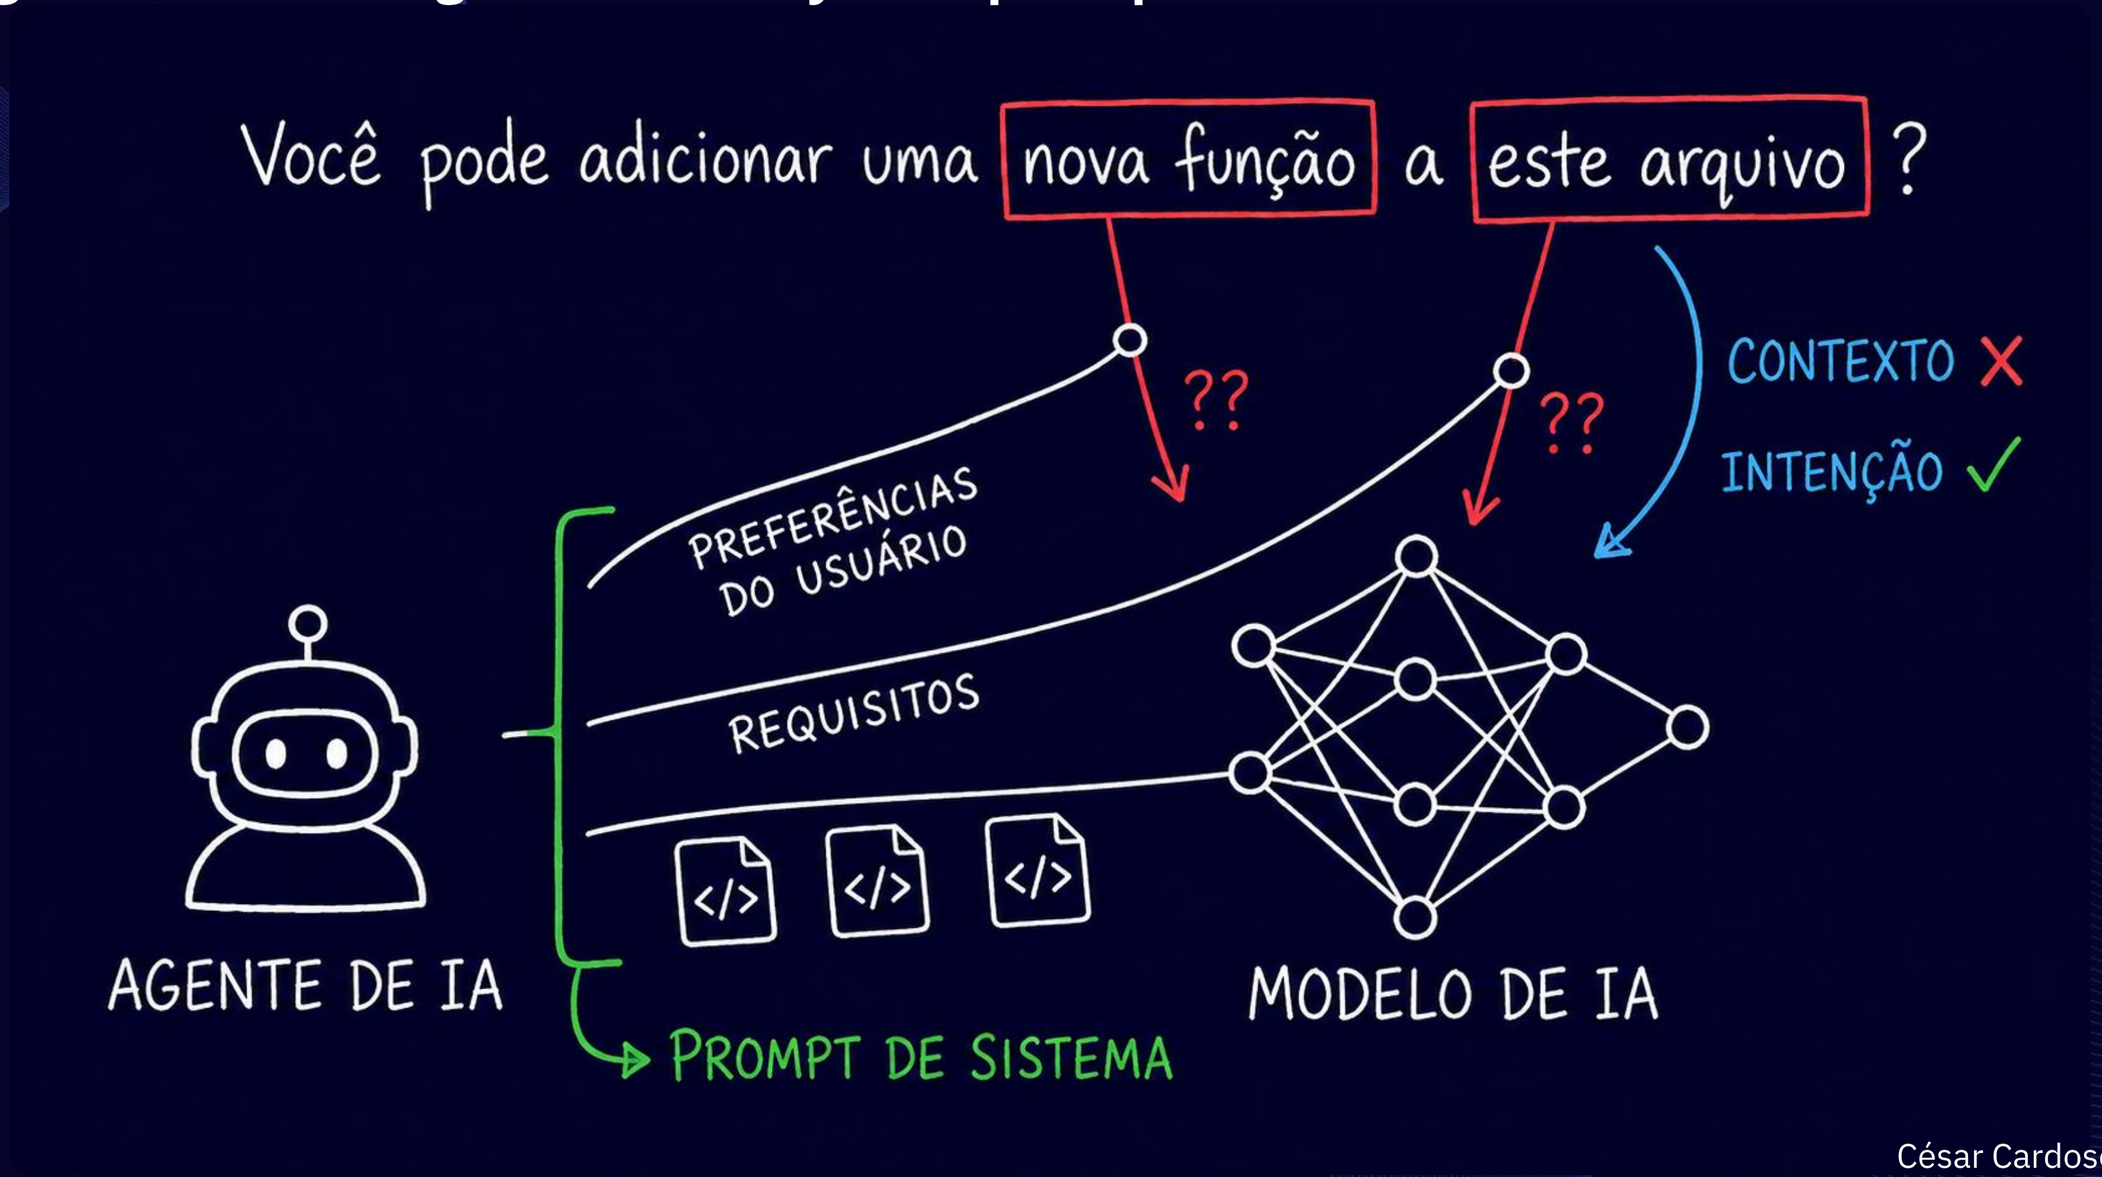
System prompt - prompt de sistema

Porque meu prompty não é envia ao LLM diretamente?



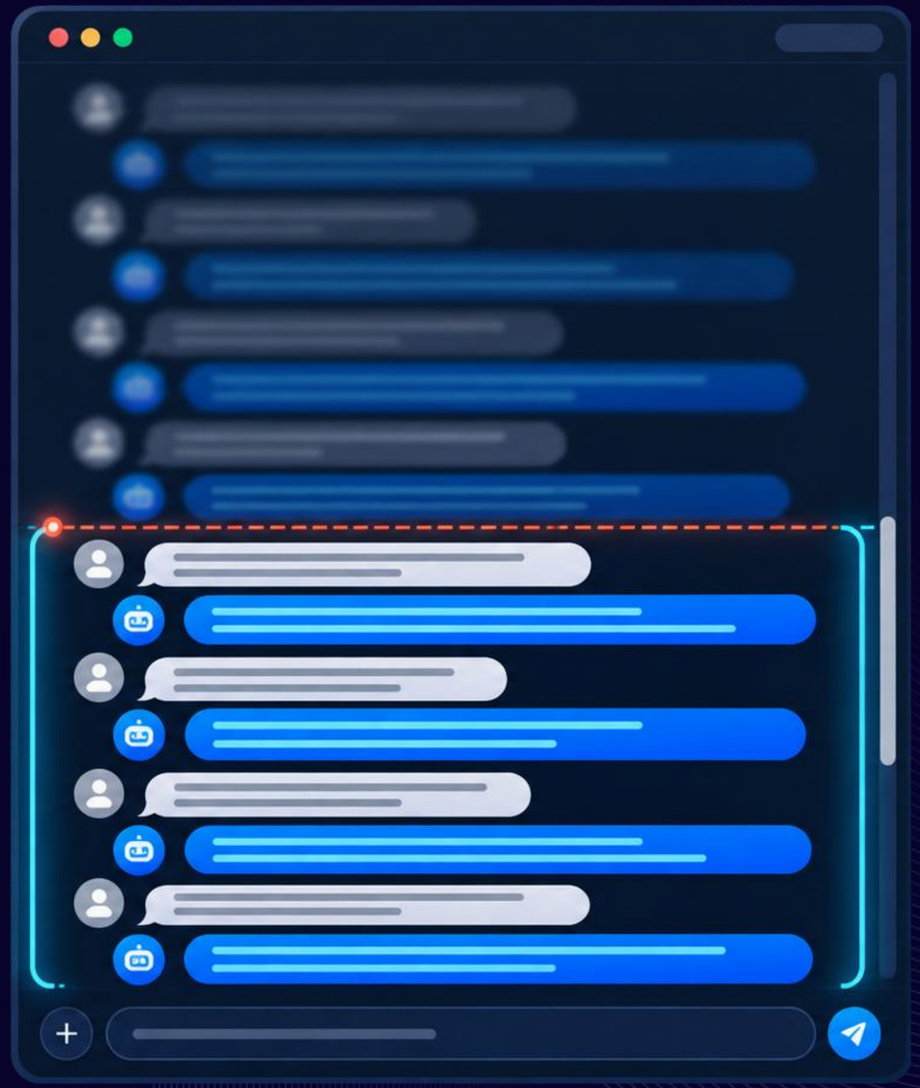
System prompt - prompt de sistema

O agente se encarrega de criar o System prompt com todo o contexto necessário



Janela de contexto / Context window / C.W.

A quantidade de tokens que um modelo consegue “lembrar”



Janela de contexto e saída máxima

Janela de contexto: Quantidade de tokens que um modelo consegue "lembrar"

Max tokens de saídas: Quanto a IA consegue escrever numa única resposta



🧠 1 milhão de tokens
📚 ≈ 2.000 páginas de texto

Janela de contexto

Composição básica



Atualmente aproximadamente de 200 mil a 1 milhão de tokens

Janela de contexto Cheia

O que acontece quando a janela de contexto enche

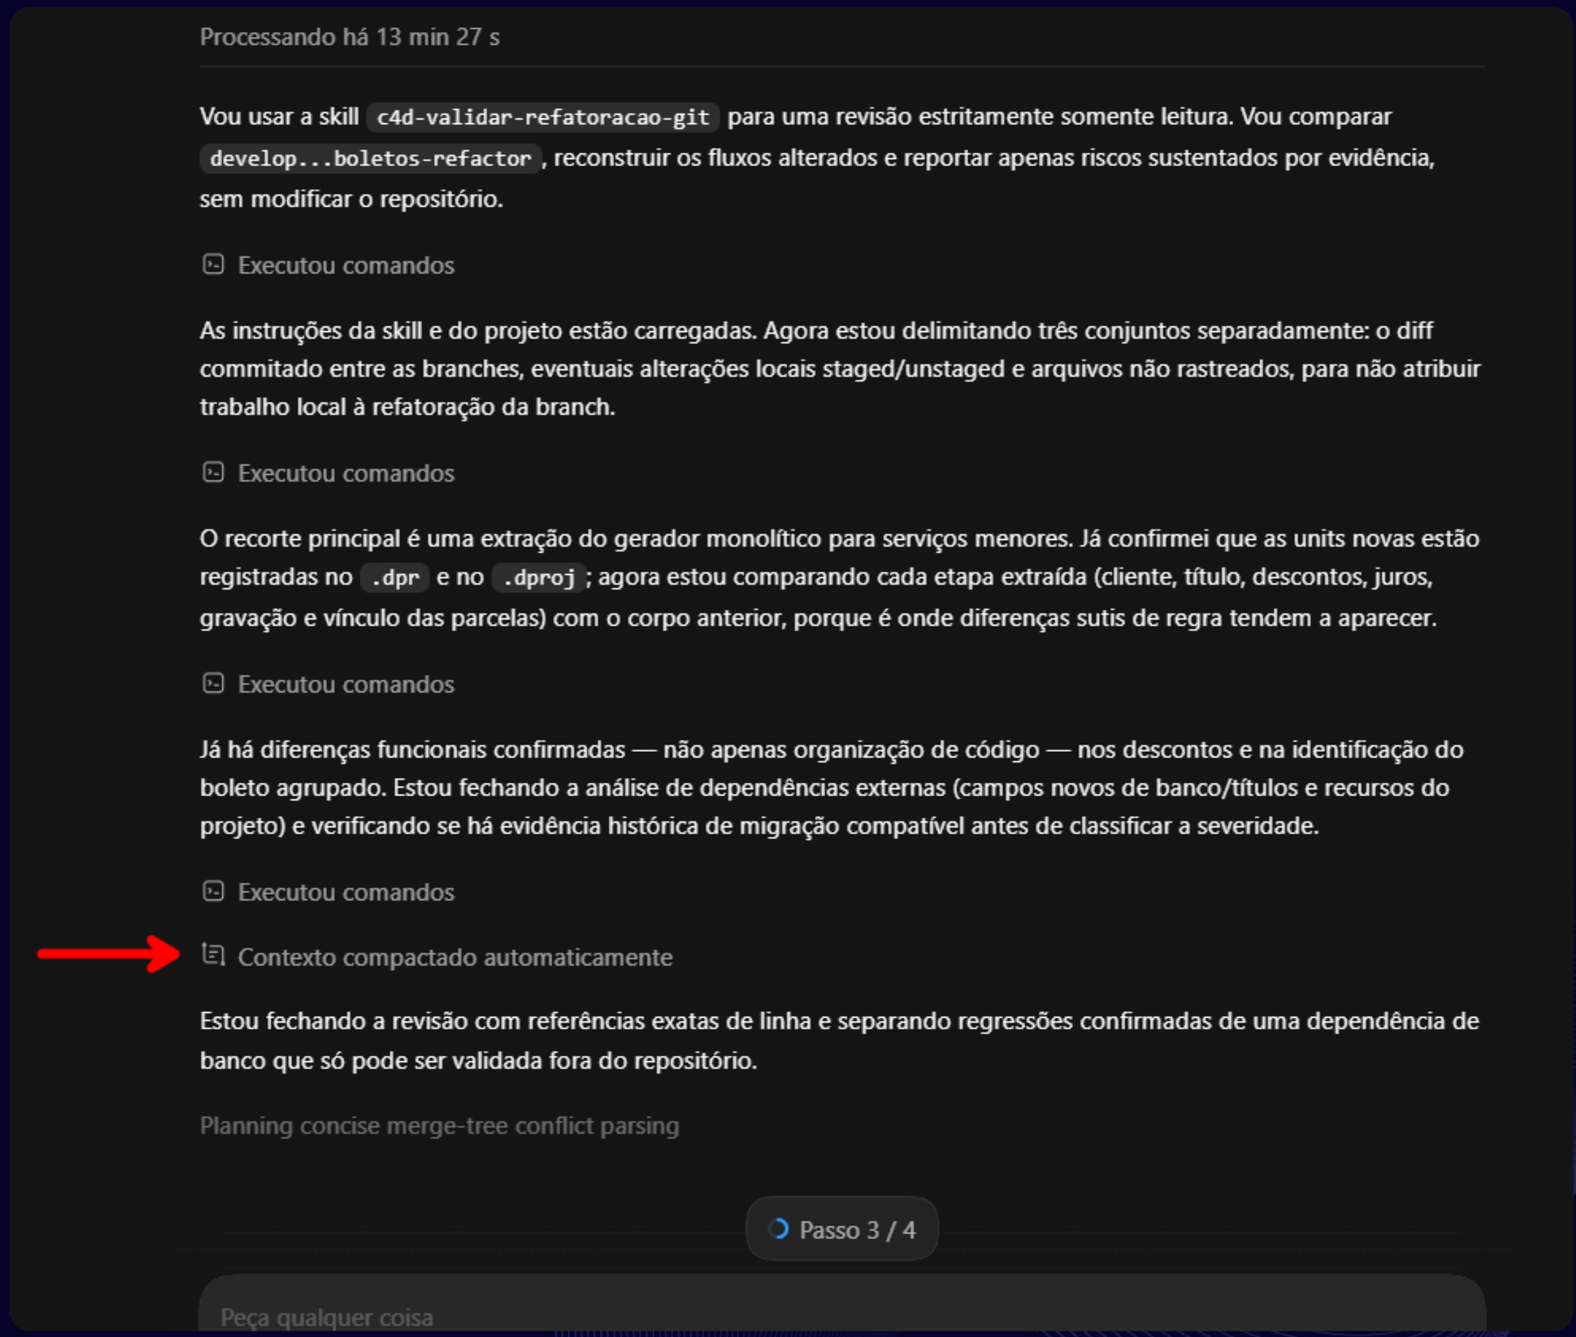


* O comando /compact pode ser usado a qualquer momento para compactar uma C. W.

Janela de contexto

Compactada automaticamente

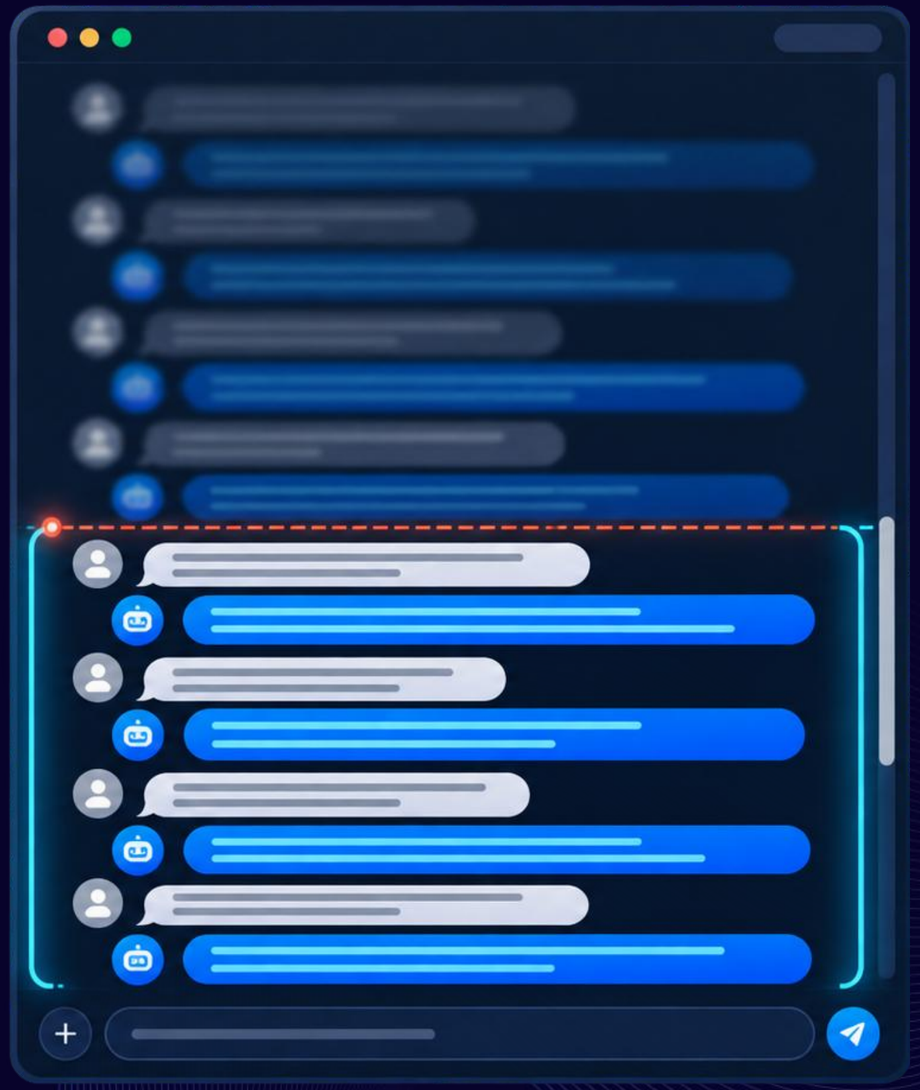
* O comando /compact pode ser usado a qualquer momento para compactar uma C. W.



Janela de contexto

Dicas

- Quanto maior o contexto, maior a chance da IA Alucinar
- Evite prompts muito longos
- A cada tarefa inicie um novo chat
- Cuidado com agents.md grandes
- Use o comando /compact
- Use /Subagentes
- Contexto grande = $ Custo grande $



AGENTS.md

É um arquivo de instruções usado para orientar agentes de IA dentro de um projeto

Exemplo de um AGENTS.md simples

```
# Instruções gerais para desenvolvimento Delphi

- O projeto utiliza Delphi 12.2
- Não altere arquivos DFM manualmente.
- Compile o projeto após modificar o código.
- Não adicione novas dependências sem autorização.
- Siga o Syle Guide do Delphi quando necessário:
https://docwiki.embarcadero.com/RADStudio/Florence/en/Delphi%E2%80%99s_Object_Pascal_Style_Guide
```

Pode haver um AGENTS.md global e vários por projeto

```
~/.codex/
└── AGENTS.md              ← regras para todos os projetos

MeuProjeto/
├── AGENTS.md              ← regras específicas do projeto
└── ModuloFinanceiro/
    └── AGENTS.md          ← regras específicas desse módulo
```

AGENTS.md

Dicas extras

- Este arquivo pode mudar a todo tempo
- Versione este arquivo juntamente com o projeto
- Use AGENTS.local.md que não será versionado

Skills - Habilidades

Uma Skill empacota instruções, metadados e recursos opcionais (scripts, templates)

Em geral é um arquivo .md que contém instruções

Documentação Skills Codex

Estrutura do arquivo Skill

```
---
name: nome-da-sua-skill
description: Breve descrição do que esta skill faz e quando utilizá-la
---

# Nome da sua Skill

## Instructions
Instruções claras e passo a passo para Claude seguir

## Examples
Exemplos concretos de uso desta Skill
```

* Campos obrigatórios: name e description

Estrutura de uma Skill

```
minha-skill/
├── SKILL.md          # contém os metadados e o fluxo principal.
├── agents/
│   └── openai.yaml   # configura nome visual, descrição curta, ícones,
│                       dependências e política de ativação
├── scripts/          # contém códigos para operações que exigem precisão e repetibilidade
├── references/       # armazena documentação, regras de negócio, APIs, schemas e
│                       conhecimentos específicos
└── assets/           # contém arquivos usados nos resultados, como logos,
                        templates, imagens, fontes e modelo
```

Skill chamada automaticamente

Configuração para impedir a ativação automática da Skill

No arquivo agents/openai.yaml, defina:

```yaml
interface:
  display_name: "Minha Skill"
  short_description: "Executa uma tarefa específica"
  default_prompt: "Use esta Skill para executar a tarefa."

policy:
  allow_implicit_invocation: false
```

Skills - Habilidades



Skills - Habilidades

Dicas

- Use Skills de fontes confiáveis
- Exija confirmação para ações críticas ou destrutivas
- Nunca inclua senhas, tokens ou chaves de API
- Crie skills gerais ou específicas para cada projeto

Slash commands - Comandos de barra

São comandos iniciados por / que acionam instruções prontas, ferramentas ou fluxos de trabalho

Exemplos

/help : Lista todos os comandos disponíveis
/status : Exibir a configuração da sessão e o uso de tokens
/clear : Limpa o contexto da sessão
/compact : Resuma a conversa
/code-review : Resumo das mudancas antes do commit

Commands - Codex Docs

Commands - Claude Code Docs

Subagentes



Documentação

Subagentes

Na prática

Aqui, pedimos que sejam adicionados dois novos forms ao projeto, e cada um será criado paralelamente por um subagente

```
- Crie 2 novos formulários para cadastro de clientes e produtos
- Cada formulário deve ter 2 labels e 2 edits para "Código" e "Nome"
- Crie cada formulário com um SUBAGENTE diferente
- Adicione o acesso a ambos no MainMenu1 na unit Main.View;
```

Subagentes

- São criados automáticamente pelo codex ou claude
- Podem ser criados e chamados sempre que preciso
- São criados em <diretorio-projeto>/.codex/agents/
- Exemplo:

<diretorio-projeto>\.codex\agents\arquivos_sem_uso.toml

Subagentes

Vantagens

- Otimização da janela de contexto principal
- Cada subagente tem sua janela de contexto
- Cada subagente pode usar um modelo diferente
- Execução de tarefas em paralelo

Harness

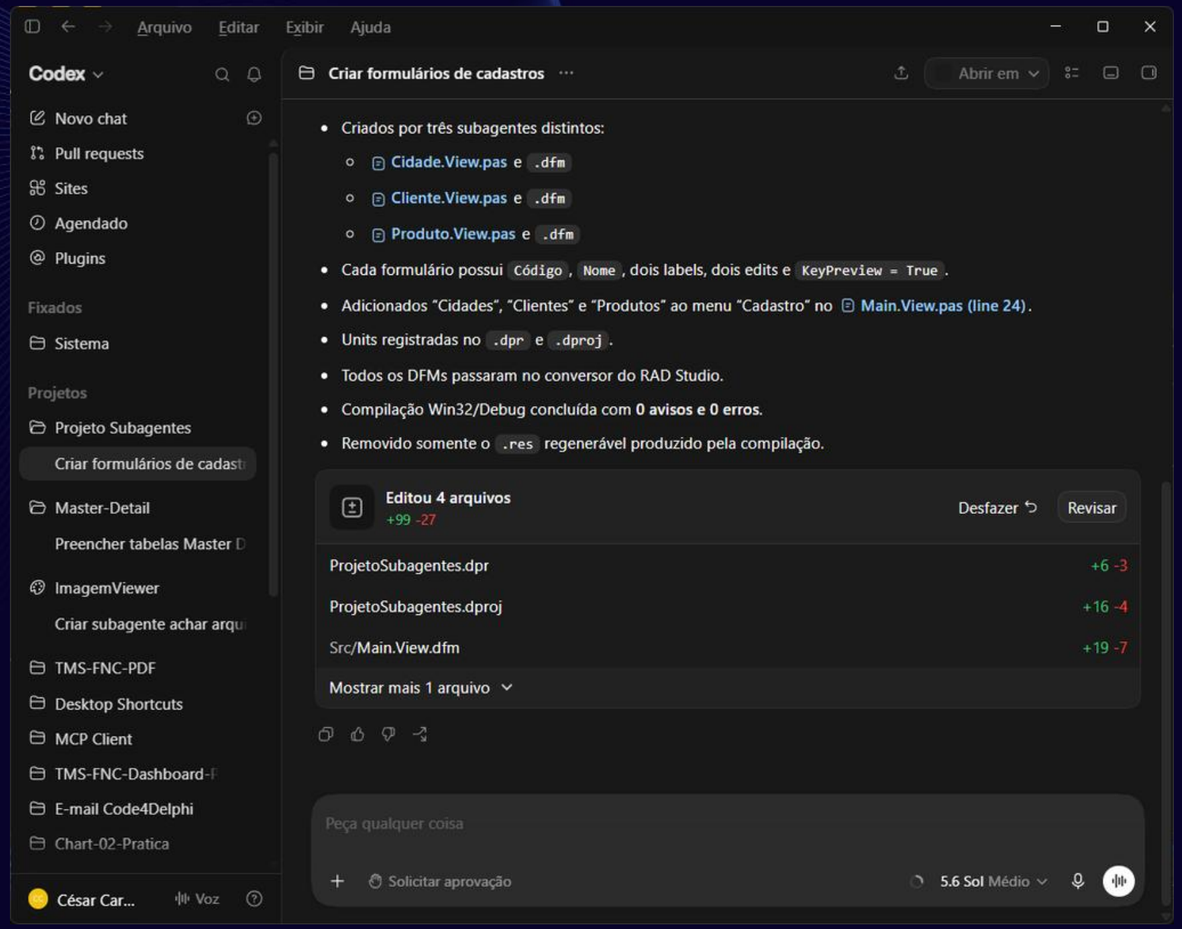
É tudo que envolve o Modelo de IA

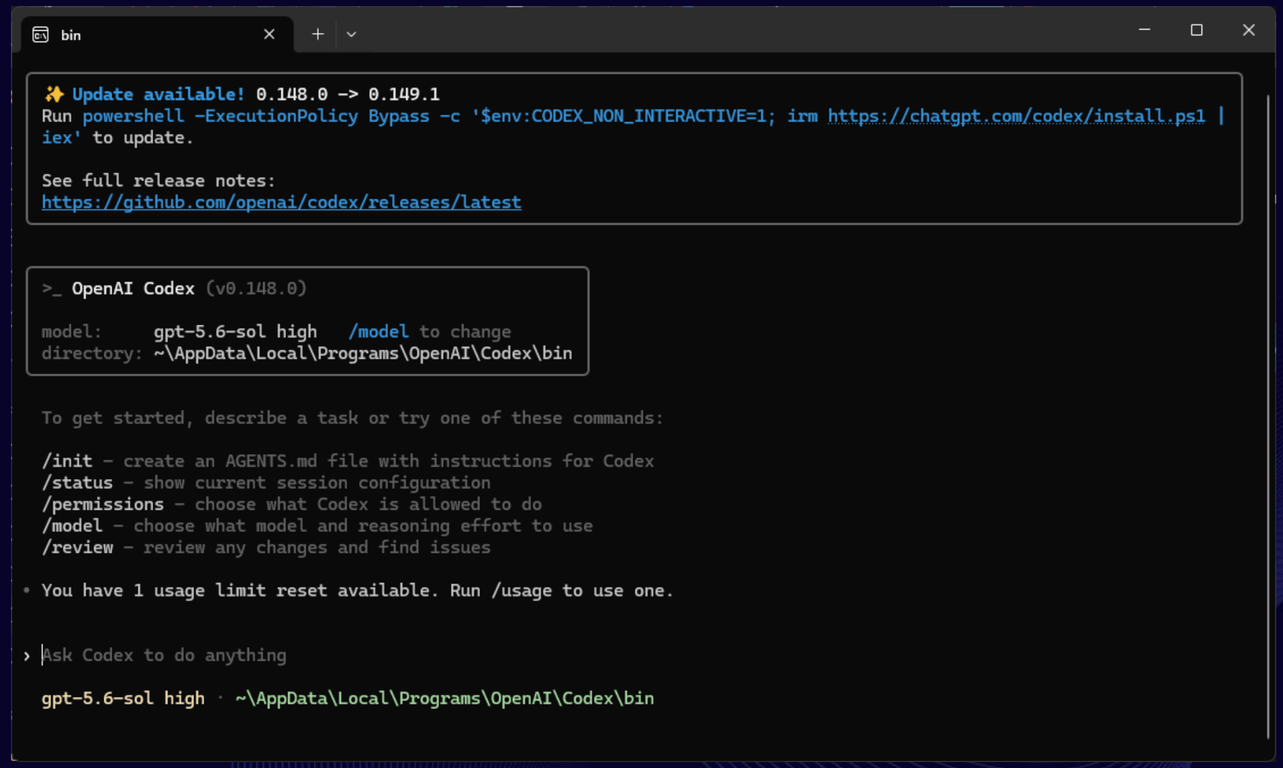
É toda a estrutura de software ao redor do modelo de IA

A estrutura que fornece contexto, ferramentas e controle para o agente executar tarefas

Harness

Codex APP e CLI são Harness?

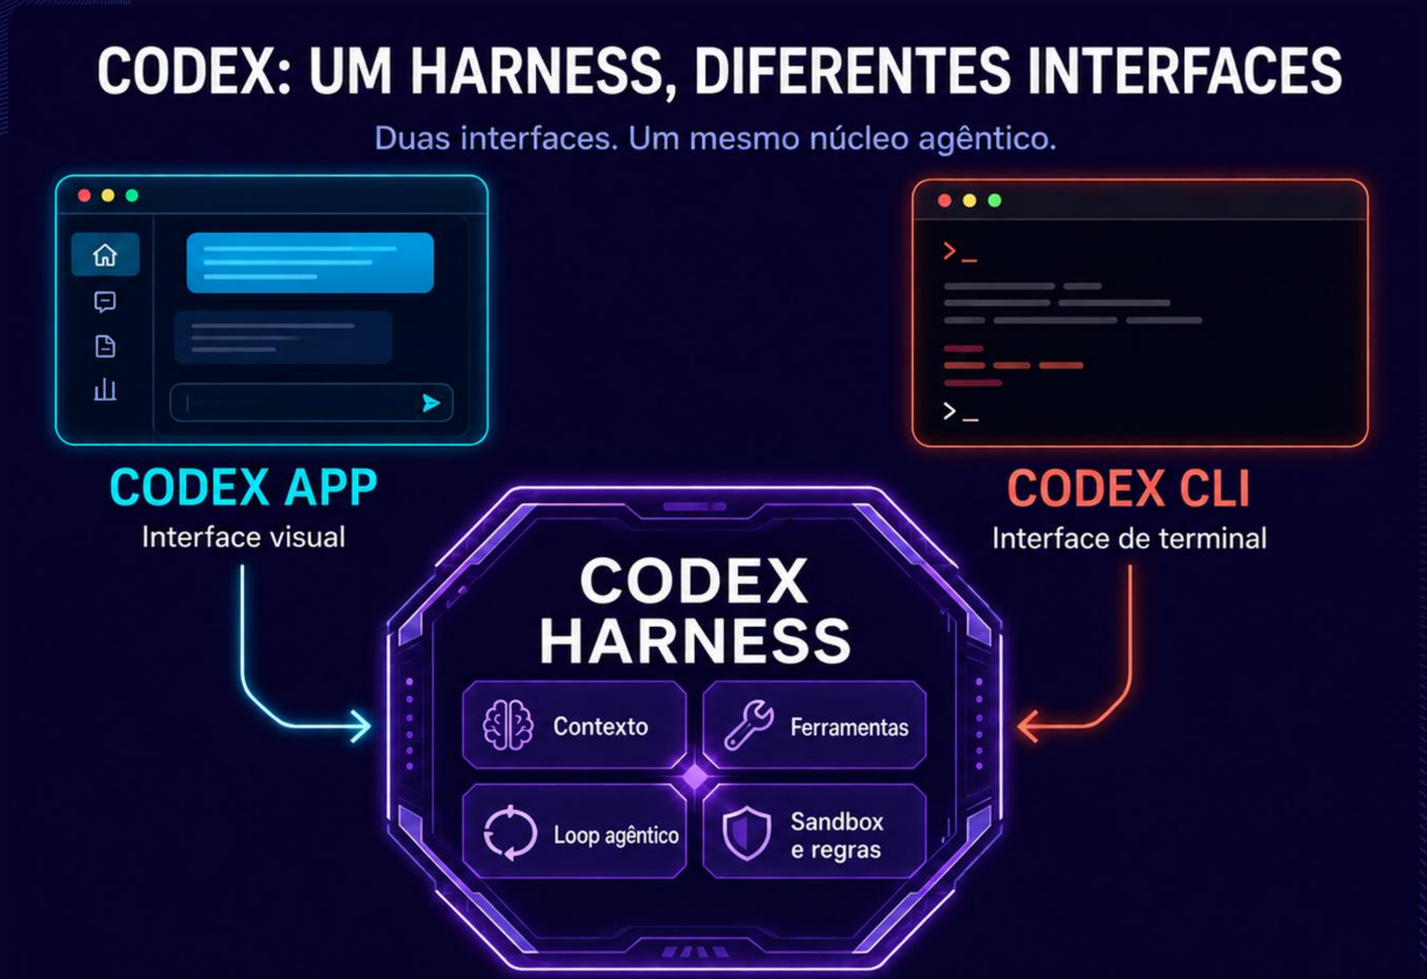




Harness

Codex APP e CLI NÃO são Harness

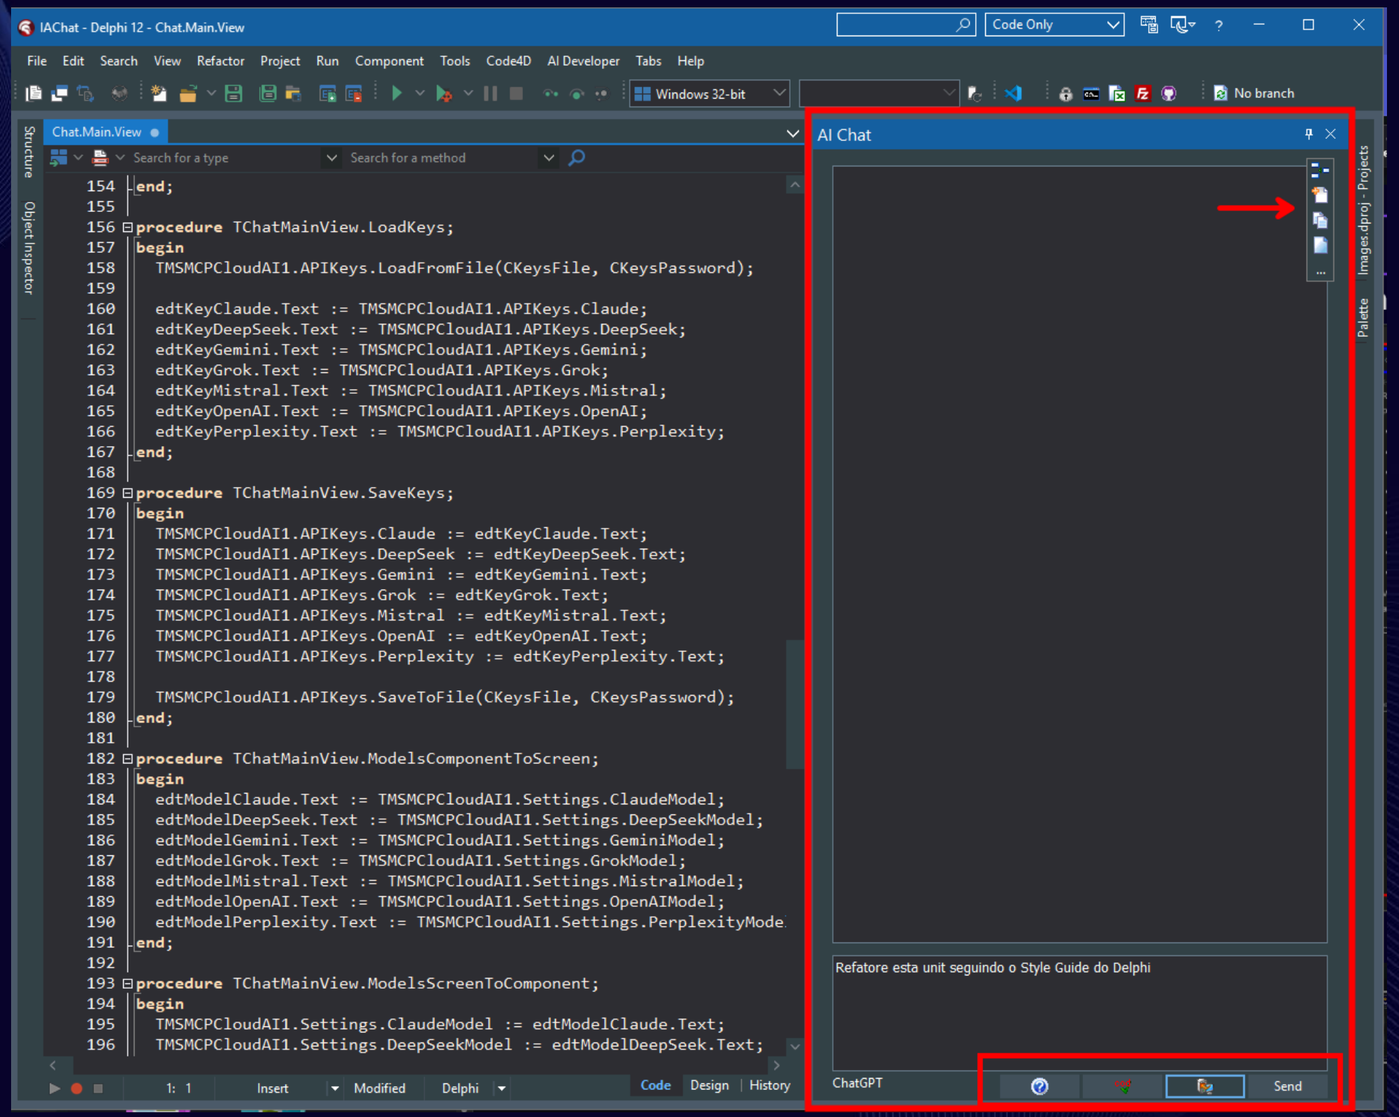
Codex App e Codex CLI são interfaces diferentes que utilizam o mesmo harness agêntico



Harness

Delphi Ai Developer é harness?

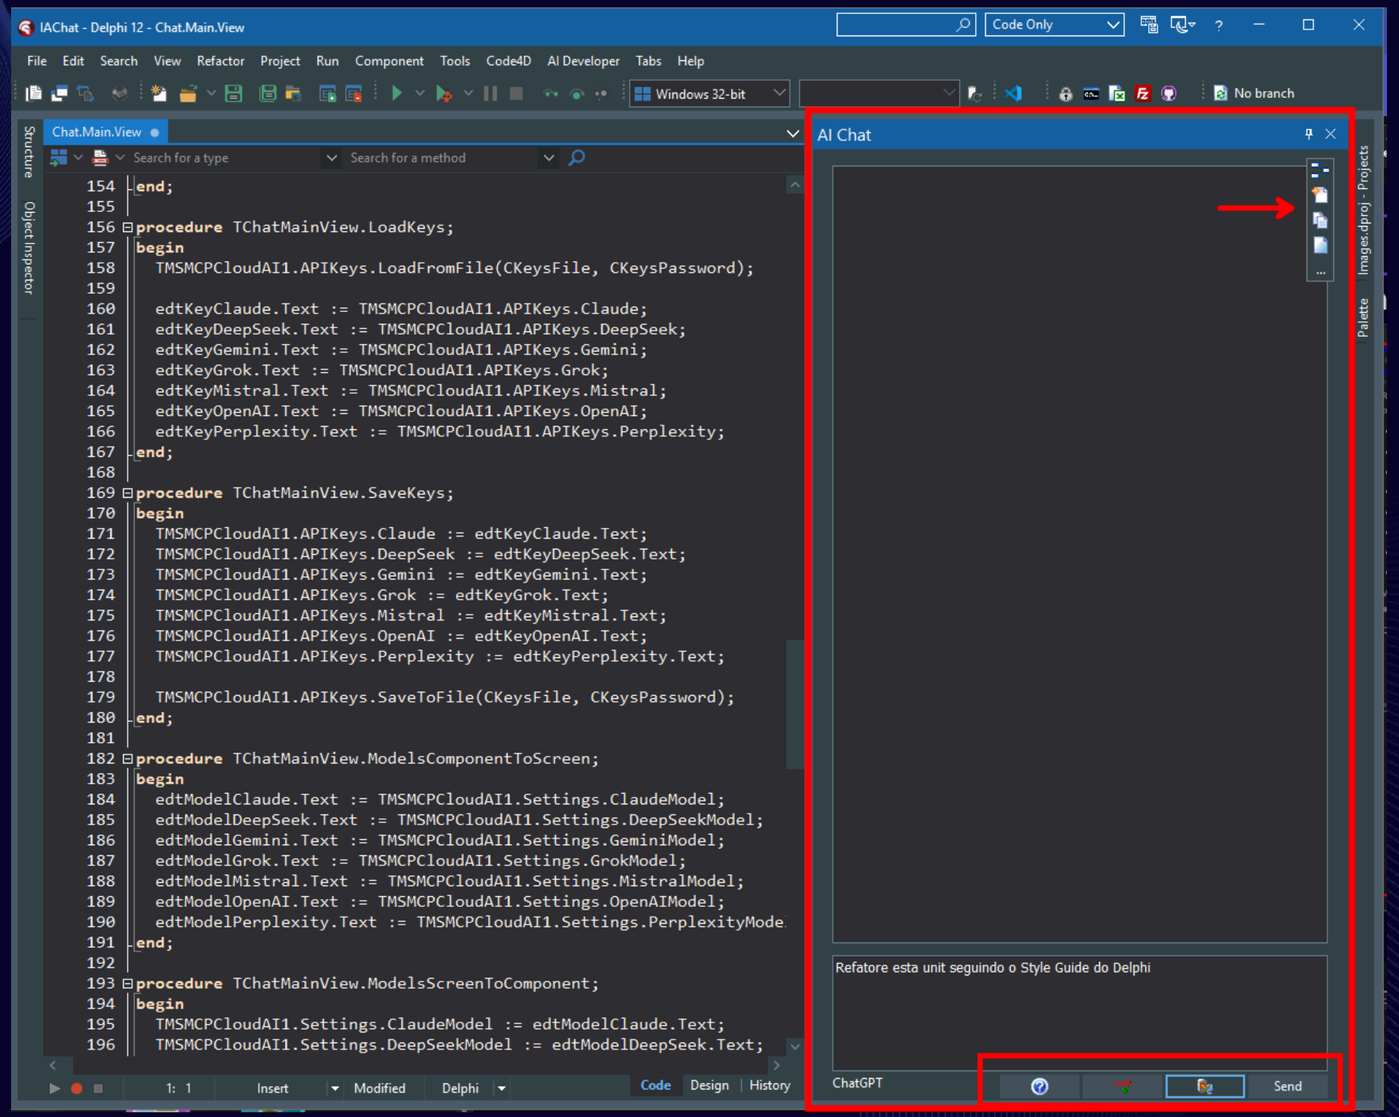




Harness

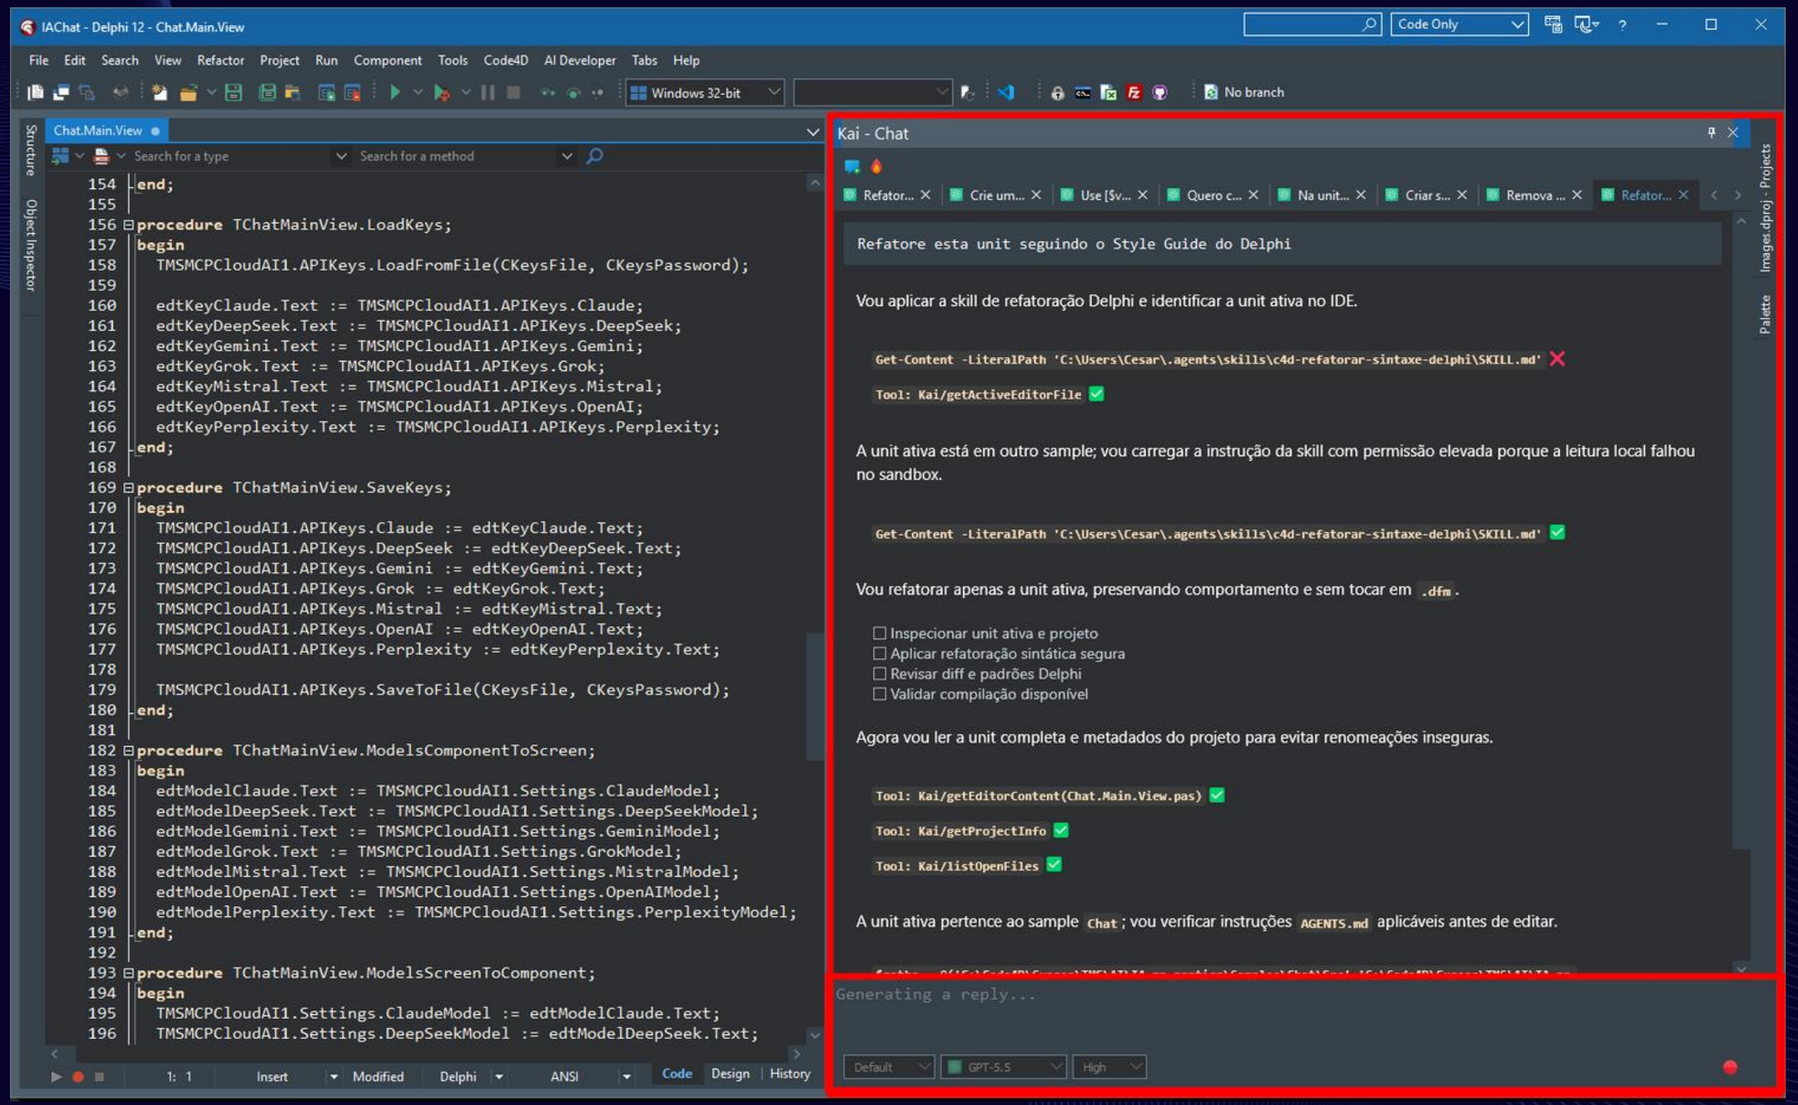
Delphi Ai Developer NÃO é um harness





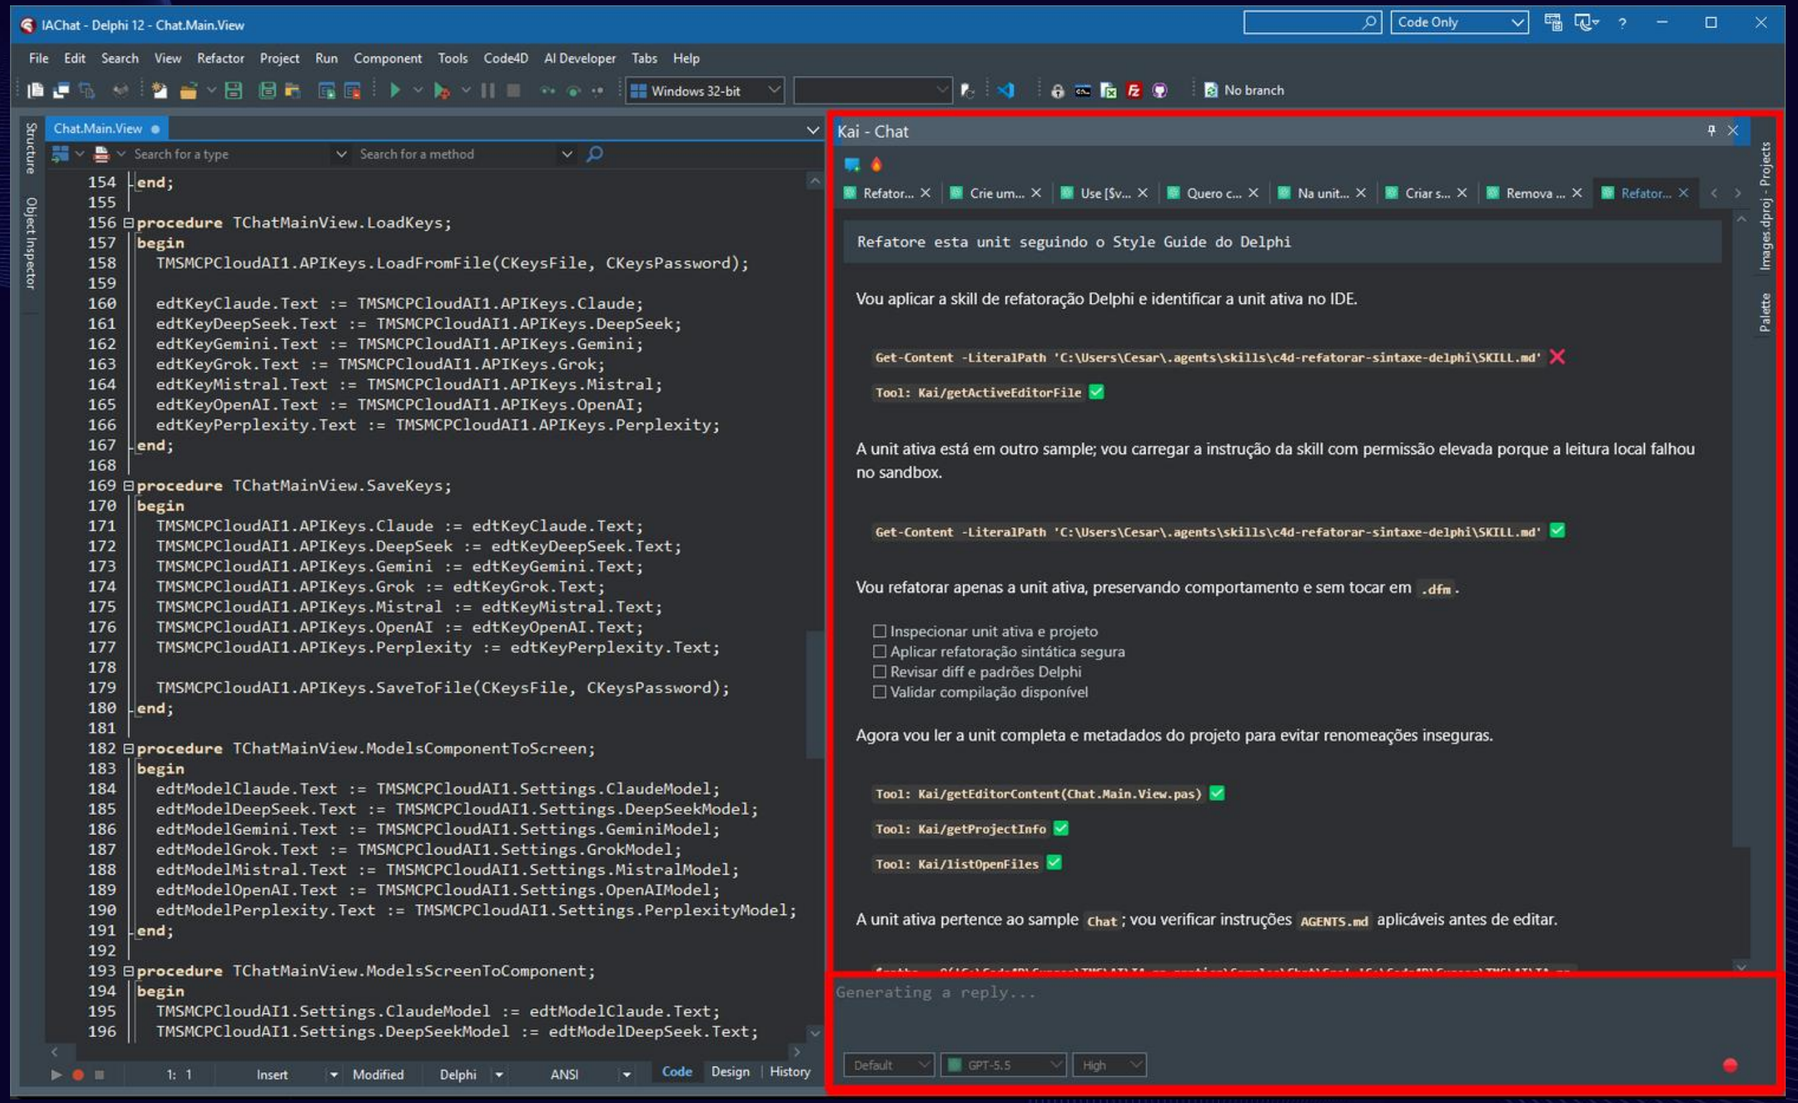
Harness

Kai é harness?



Harness

SIM Kai é um harness



Spec-Driven Development - SDD

Desenvolvimento Orientado por Especificações

É uma lista de passos que dão gatilhos em vários loops de agentes

No SDD, a especificação se torna a fonte da verdade que orienta o planejamento, o código e os testes

Não exclusivamente a IA. O conceito já existia.

Spec-Driven - Arquivos PRD

Primeiro passo do SDD

Passo 1

- PRD - Product Requirements Document
- Documento de Requisitos do Produto
- É um documento que descreve:
  - Qual problema será resolvido
  - Para quem o produto será criado
  - O que deve ser desenvolvido
  - Requisitos e funcionalidades
  - Regras, limitações e critérios de aceitação
  - Como o sucesso será medido

PRD fornece uma visão clara do produto antes que o agente comece a implementar

Spec-Driven - Arquivos PRD

Arquivos de especificações

Passo 2

- Gerar os arquivos de especificações com base no PRD
- A lógica é:
  - PRD → Funcionalidades → Especificação → Plano → Tarefas → Código

```
docs/
├──── PRD.md
└──── F01-cadastro-cidades/
      ├──── spec.md
      ├──── plan.md
      ├──── data-model.md
      ├──── tasks.md
      └──── checklist.md
```

Spec-Driven - Frameworks

Frameworks de Spec-Driven

Passo 3

Facilitam a criação dos arquivos com especificações

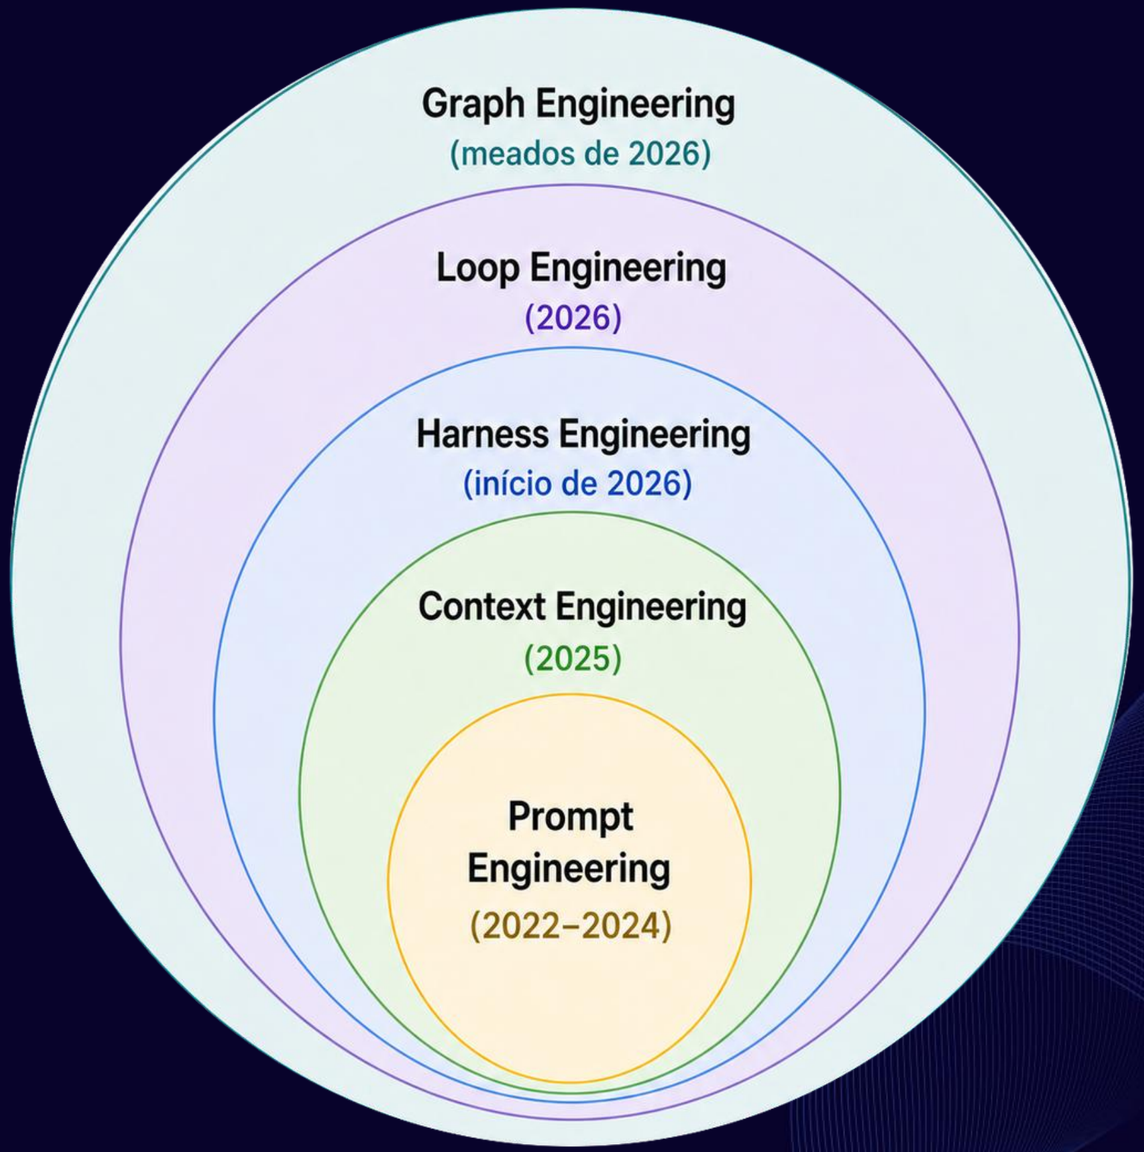
- OpenSpec
- GitHub Spec-Kit
- Superpowers
- TCL Spec-Driven

Cada semana um novo termo



Engineering?

Os muitos termo com Engineering



Evolução dos paradigmas

Os muitos termo com Engineering



https://flowtivity.ai/blog/graph

Loop Engineering

Engenharia de laços

É a prática de projetar fluxos de trabalho autônomos para os agentes

O agente executa o loop até que a tarefa seja feita ou atinja um limite

Um passo de cada vez

Se falhar volta ao passo 1



Loop Engineering

Exemplo

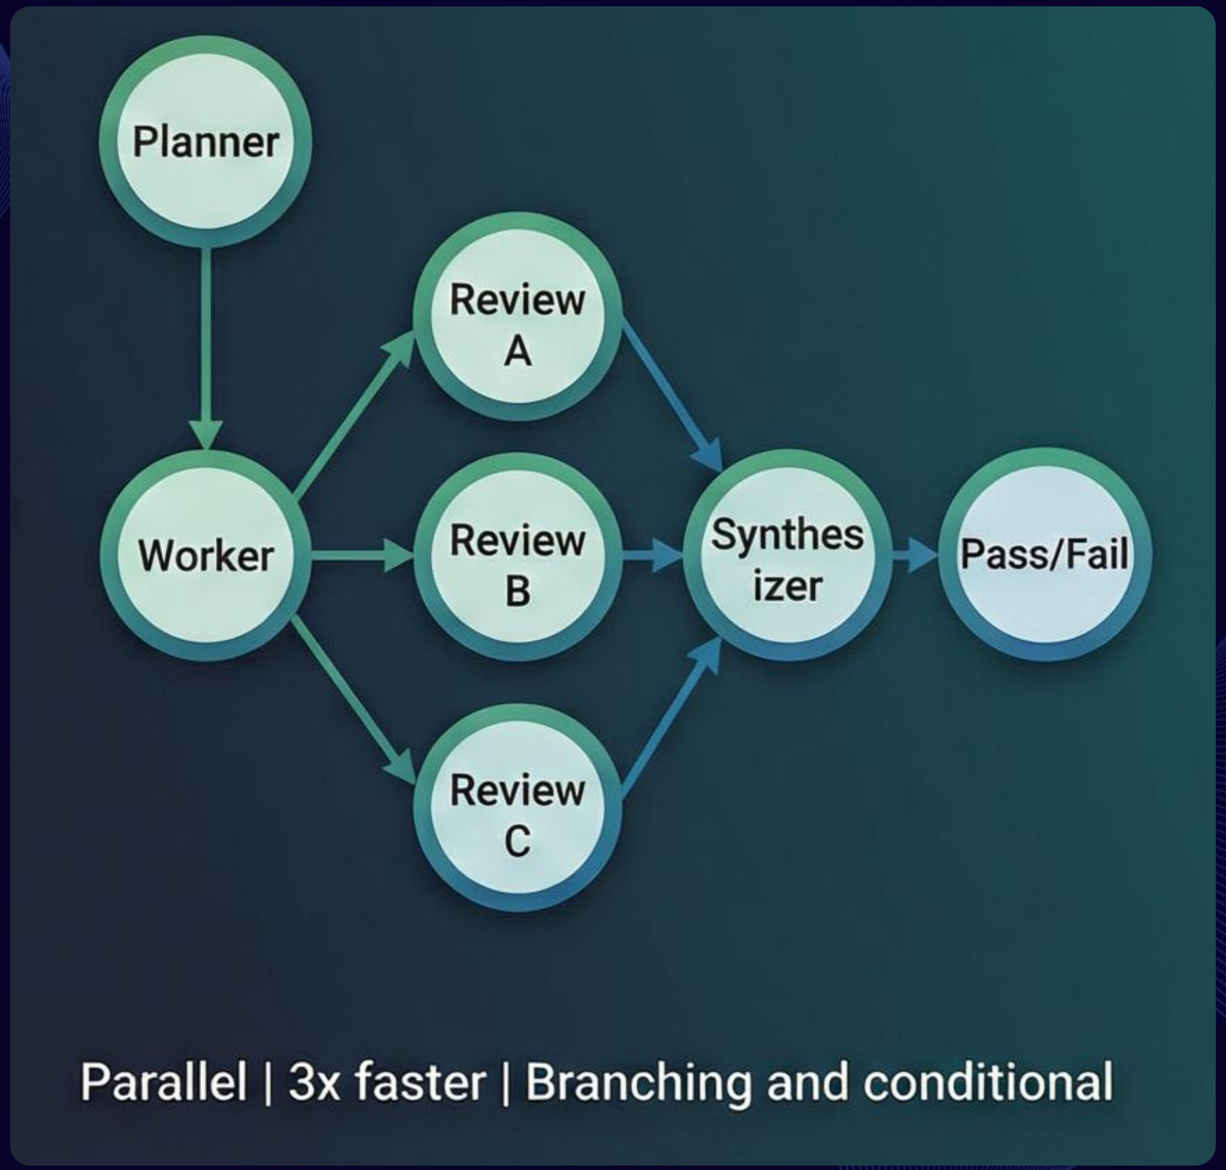
1. Entre no meu repositório
2. Busque por uma issue
3. Faça uma pequena melhoria
4. Rode os testes
5. Ajuste o que for preciso
6. Abra um pull request

Necessita de um Harness muito bem definido.

Nesse exemplo o mesmo contexto faz a implementação e a revisão, o que pode não ser muito indicado

Graph Engineering

Agentes como nós, fluxos e decisões como arestas



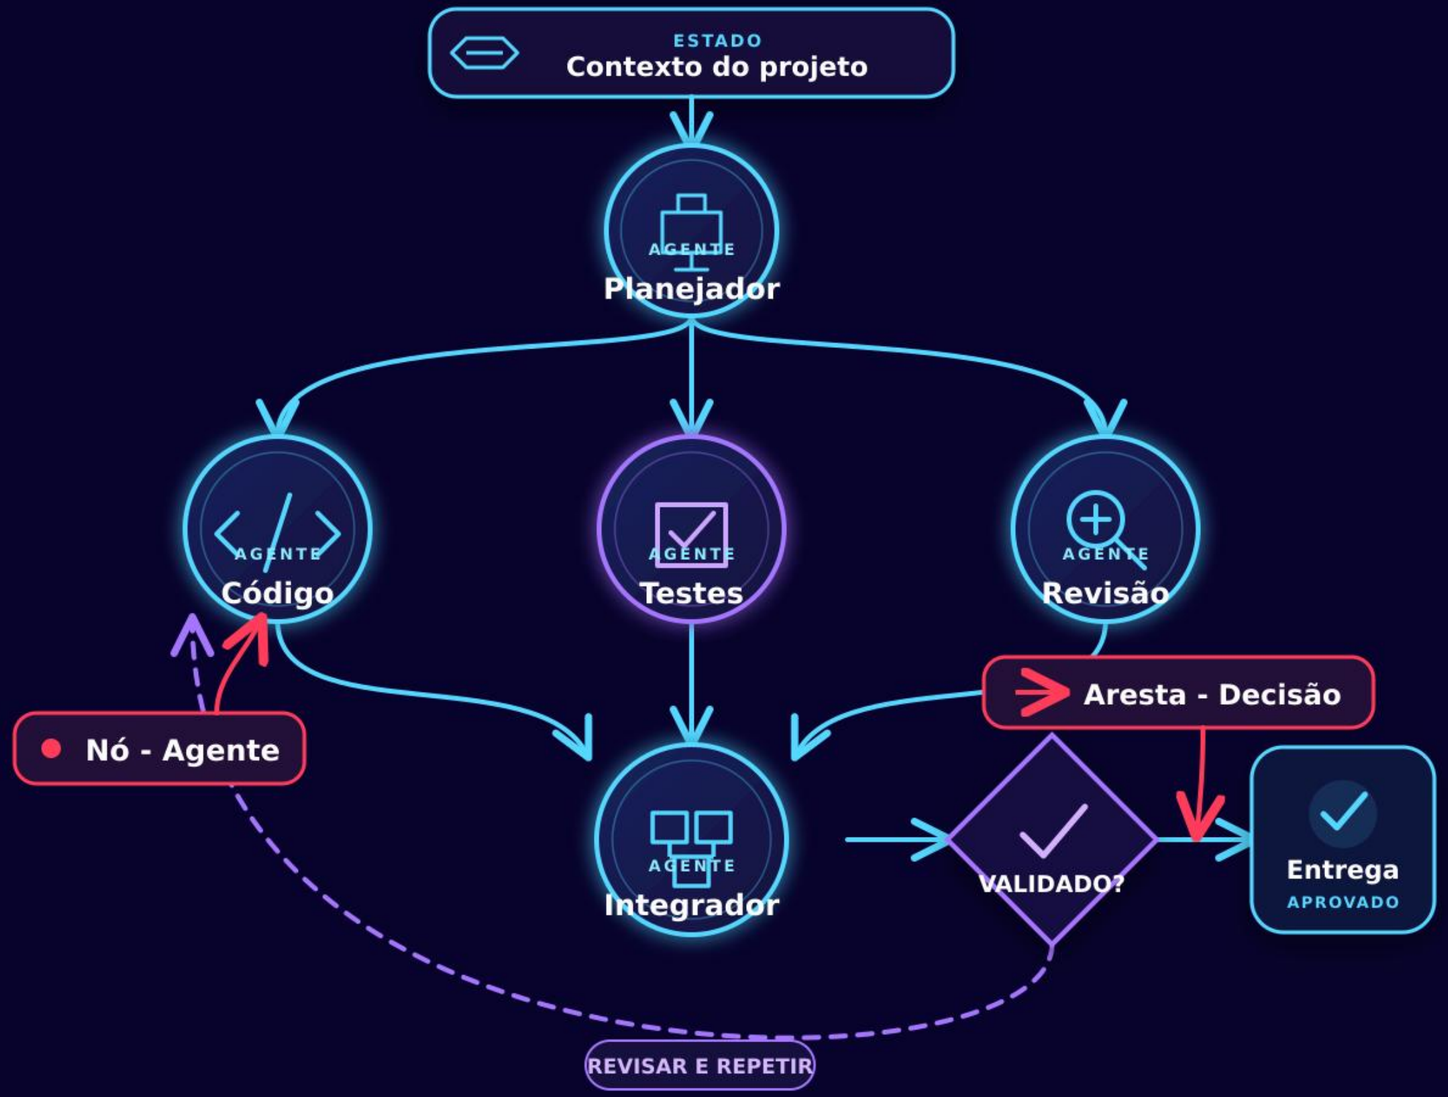
Graph Engineering

ENGENHARIA DE AGENTES

Graph Engineering

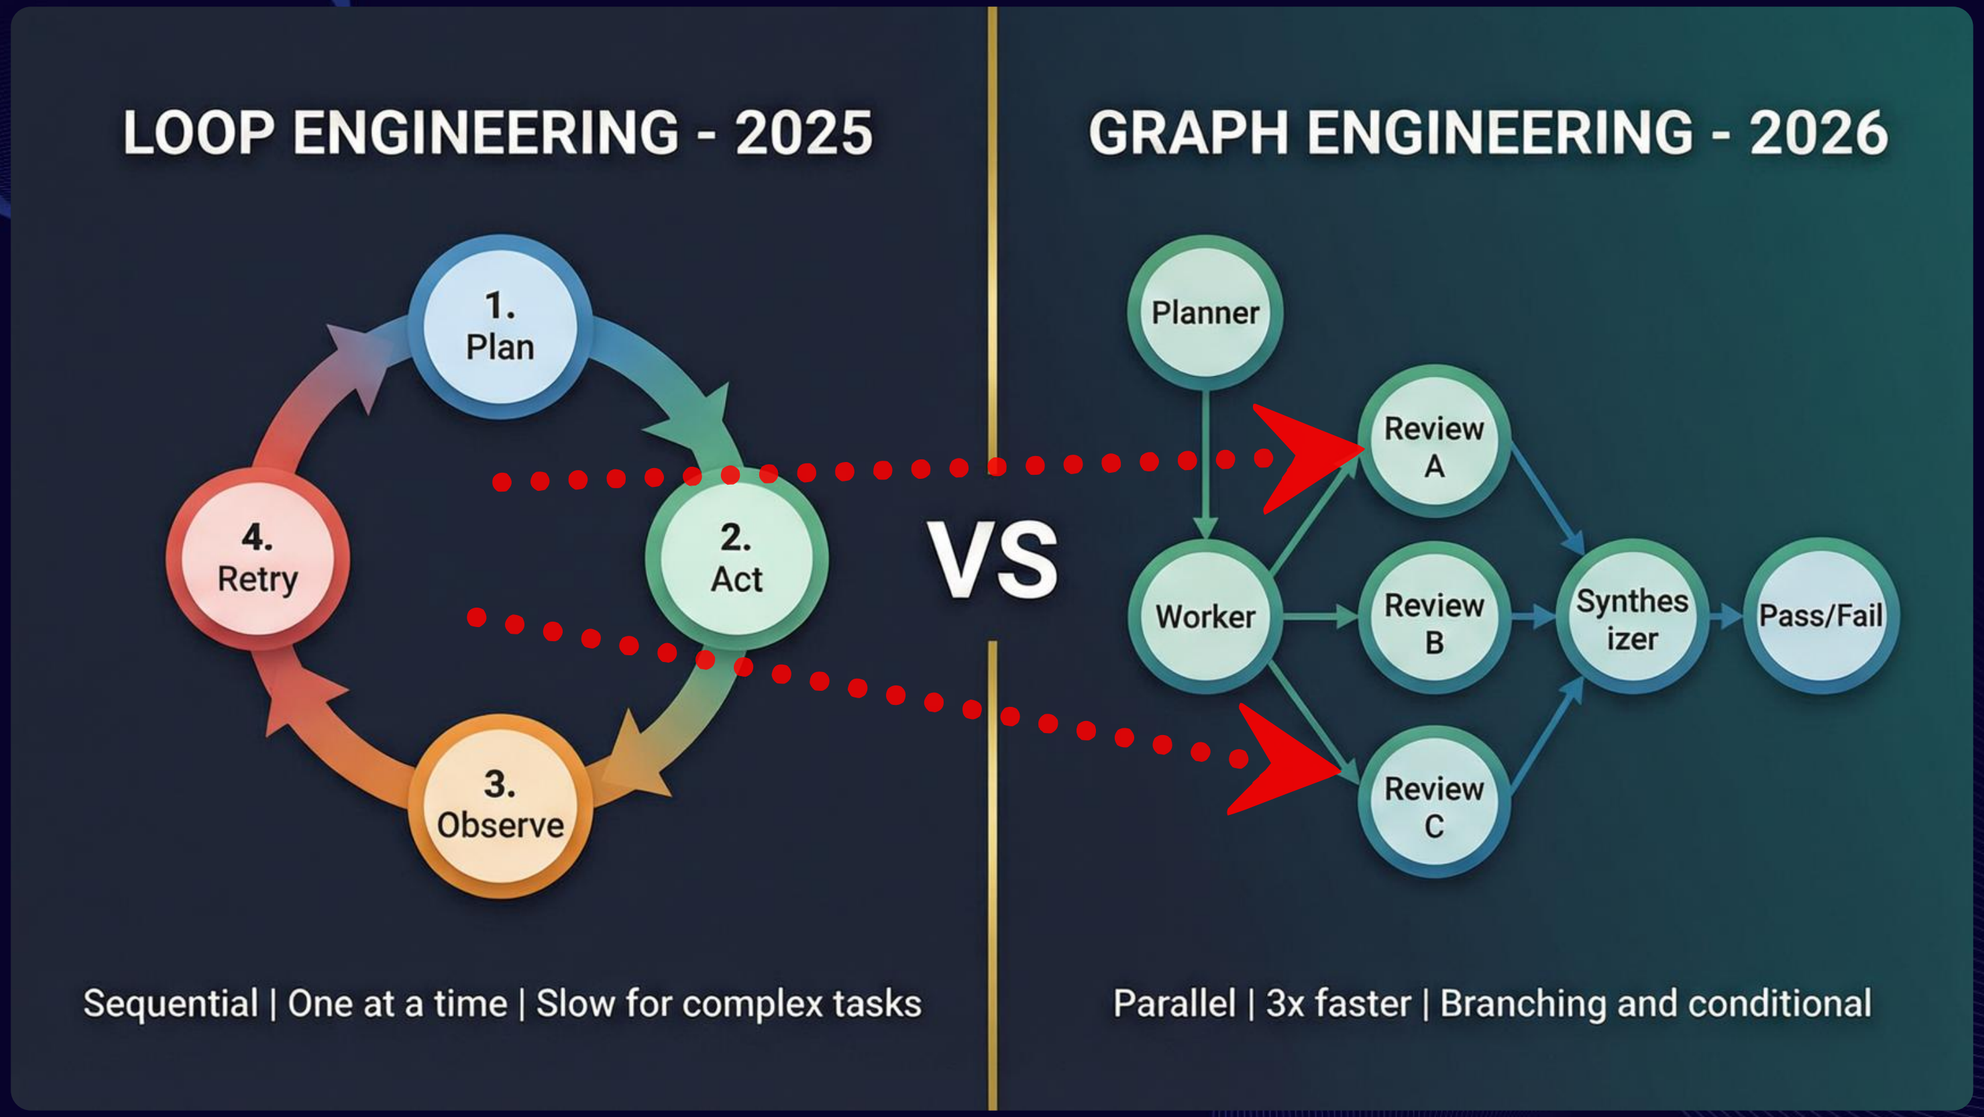
Orquestrando agentes, ferramentas e decisões em um grafo de execução.

- **Nós**
  Agentes e etapas especializadas
- **Arestas**
  Fluxos, regras e decisões
- **Estado compartilhado**
  Contexto transportado entre as etapas



Code4Delphi

Loop x Graph Engineering

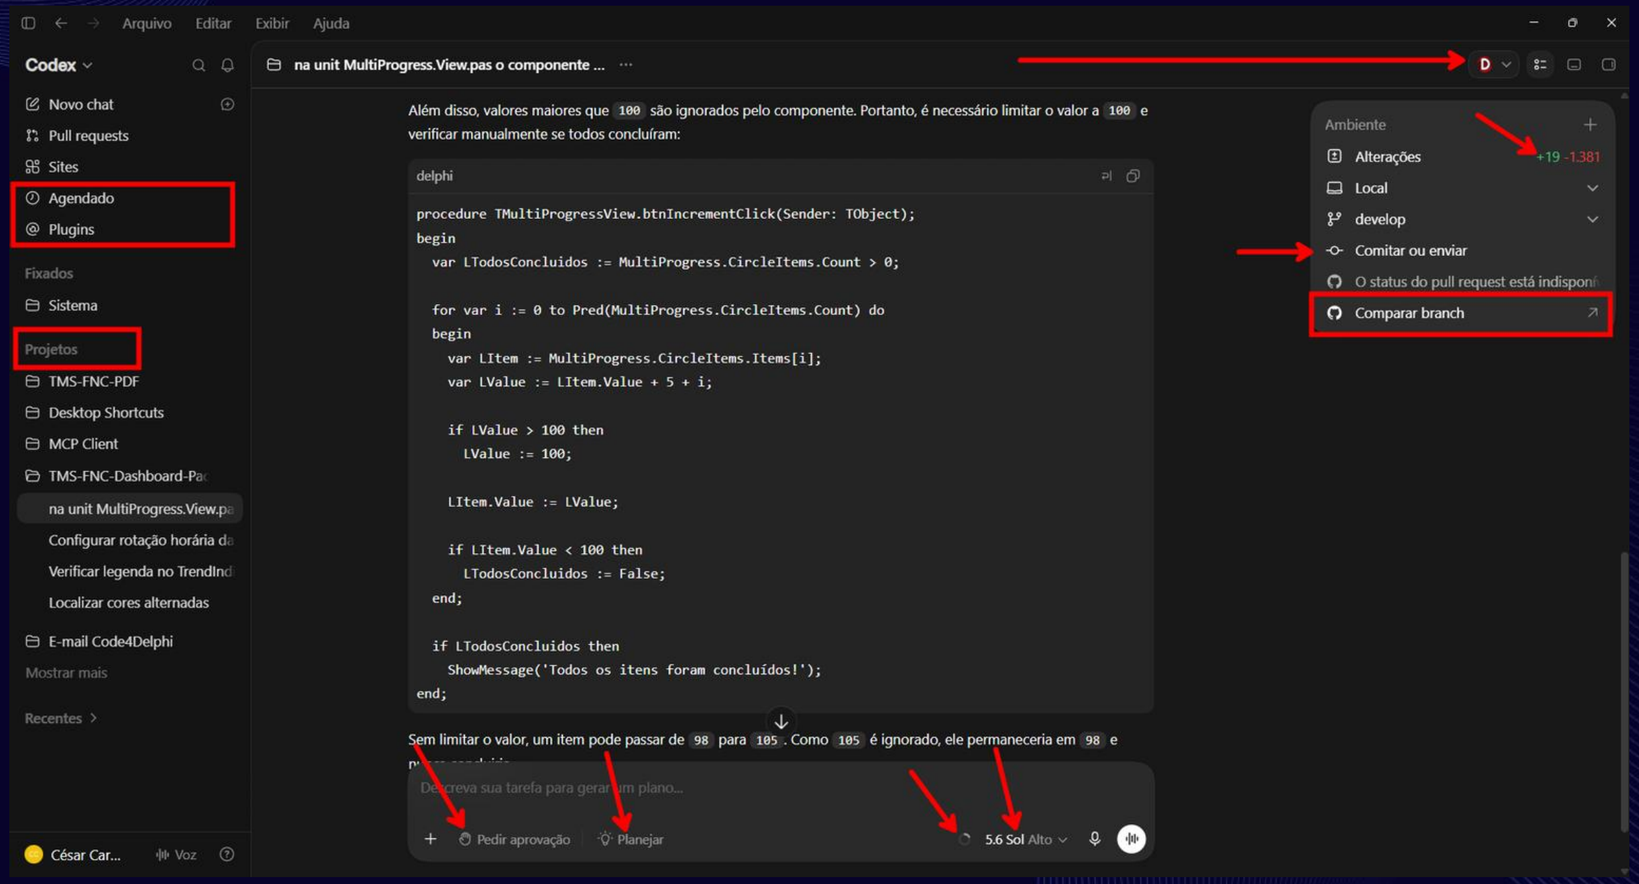


Principais ferramentas de desenvolvimento com IA

César Cardoso - @Code4Delphi

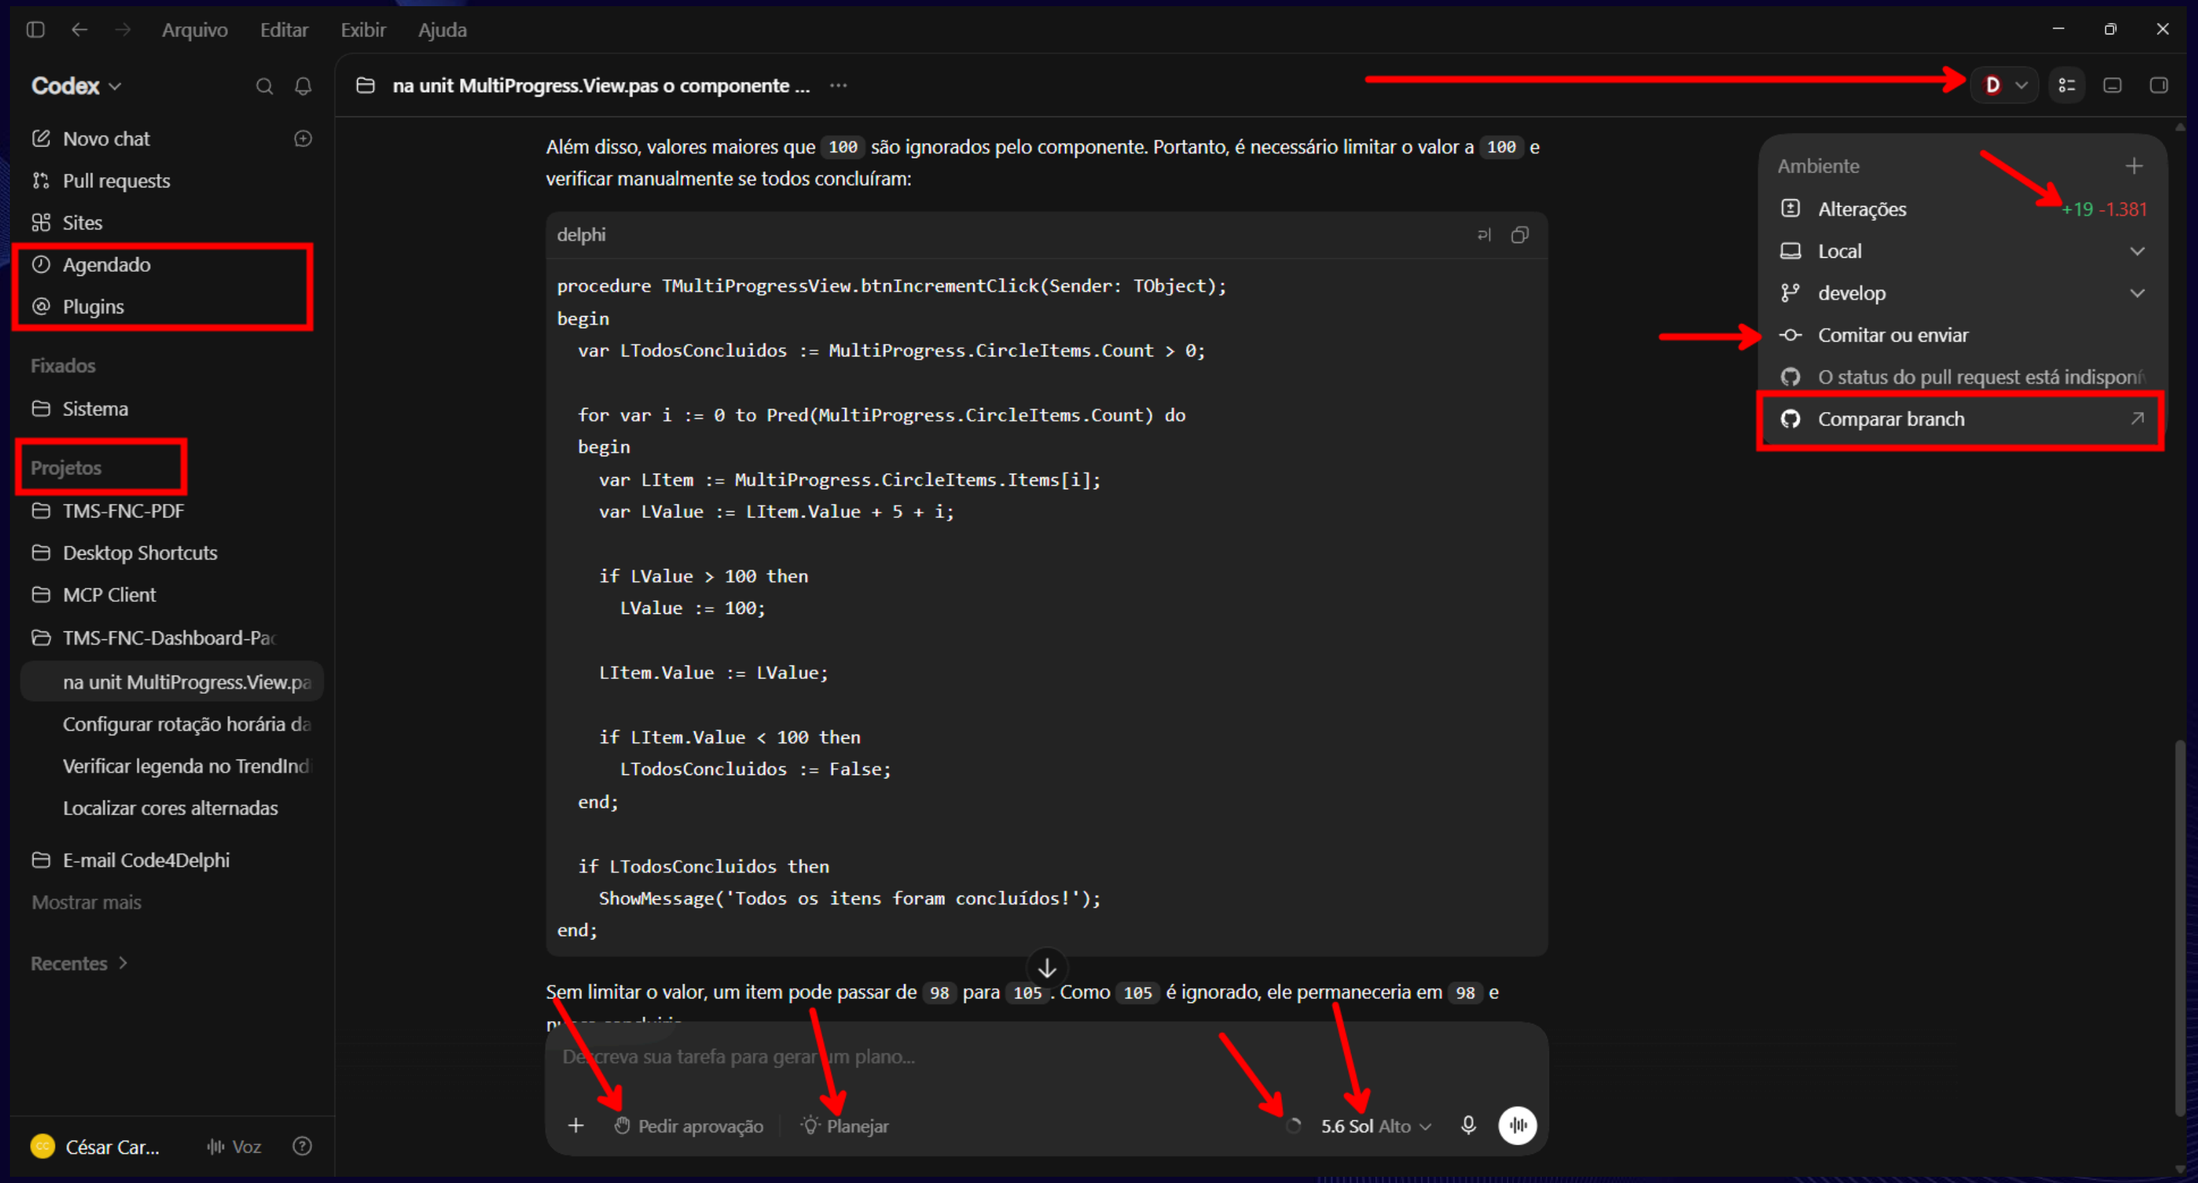
Codex

- Da OpenAI (Chat-GPT)
- Possui APP
- Via CLI
- Possui plugin para outras ferramentas
- Só funciona com modelos da OpenAI
- Models: GPT-5.5, GPT-5.6 Luna / Terra / Sol



https://openai.com/pt-BR/codex/

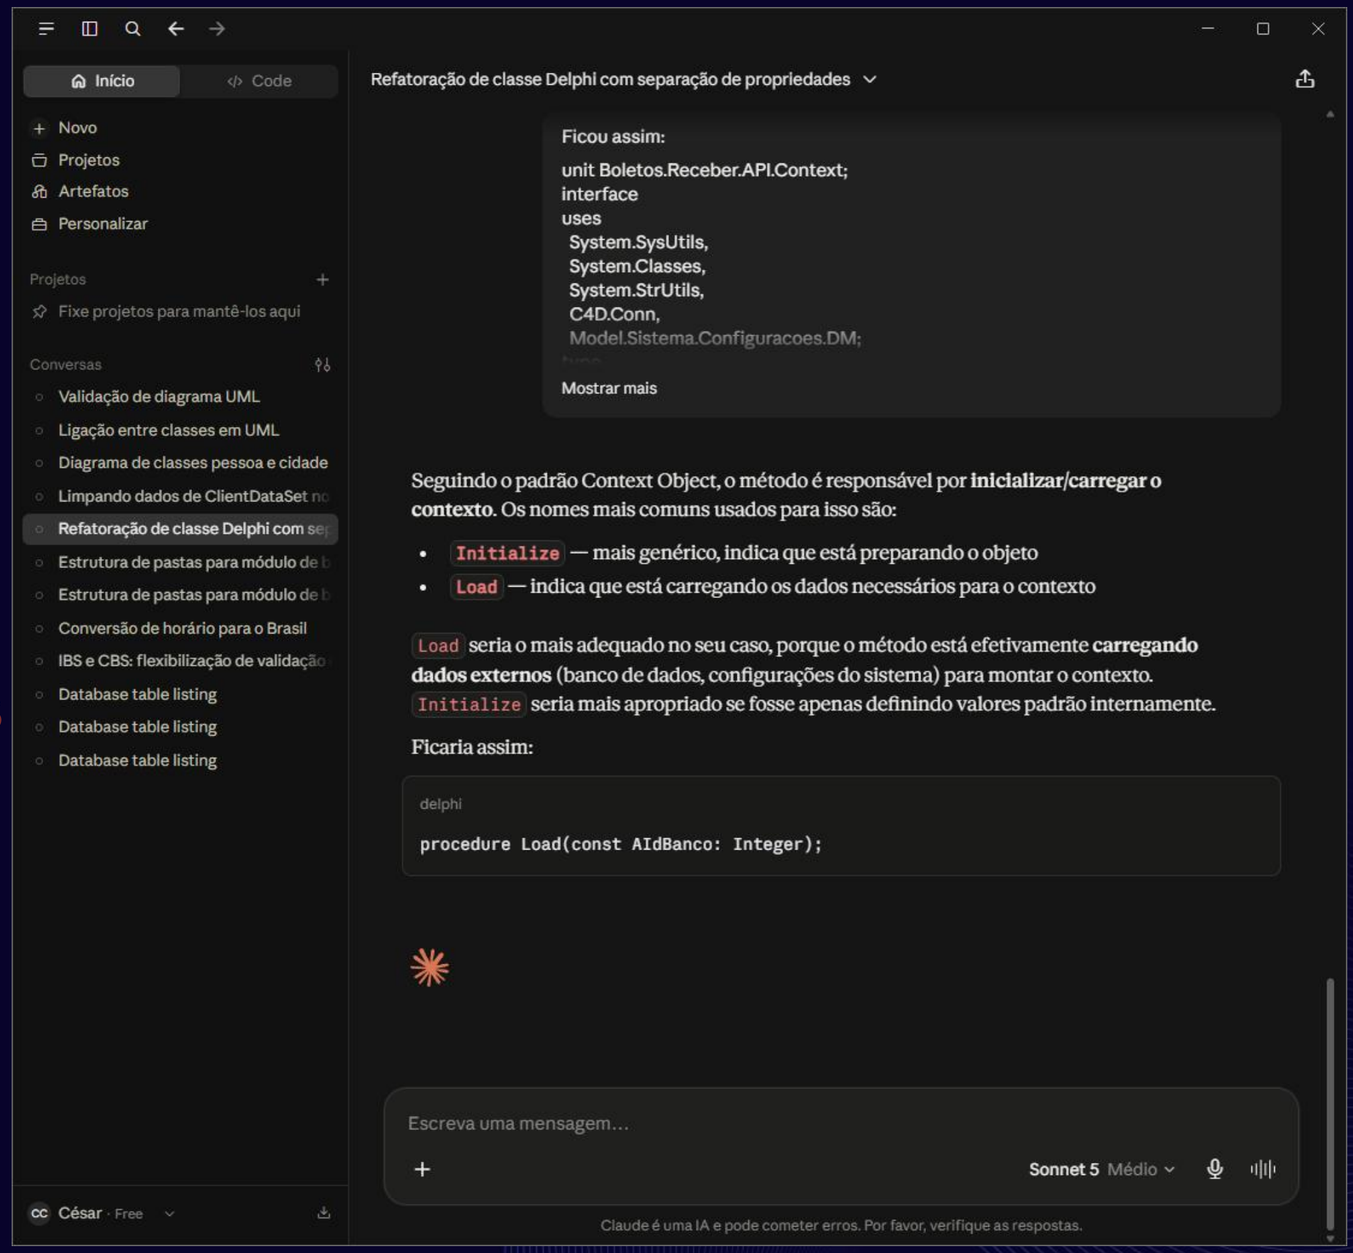
Codex



https://openai.com/pt-BR/codex/

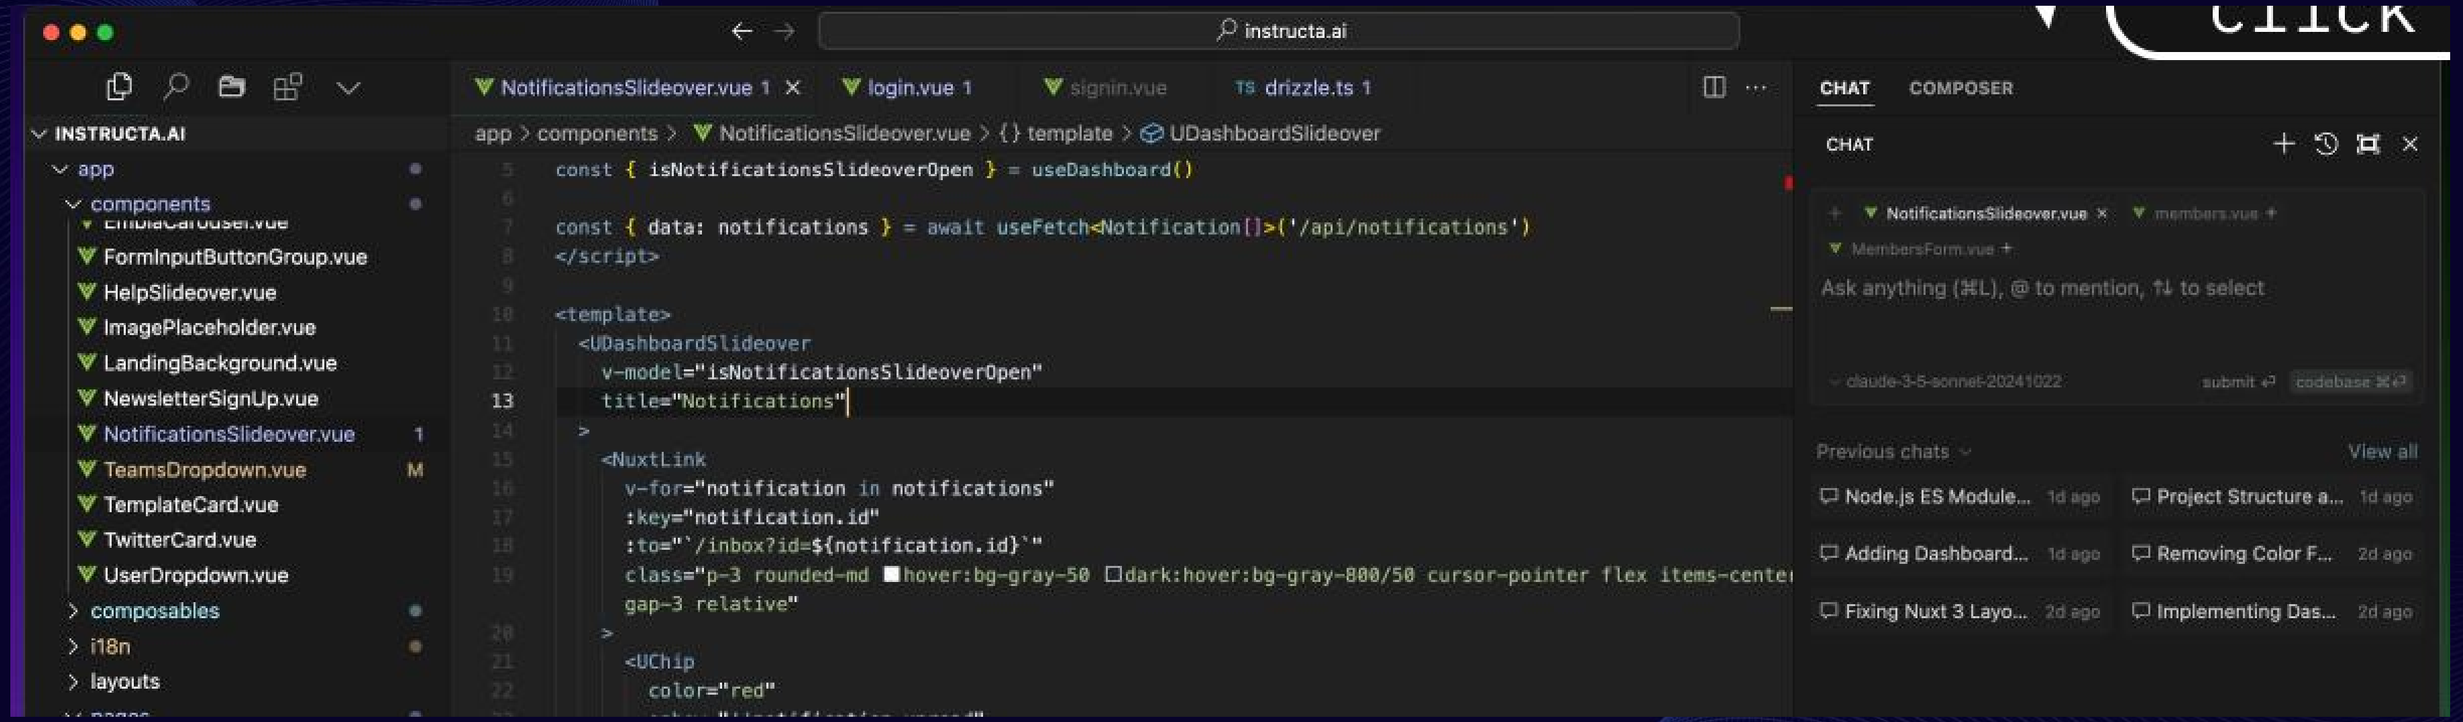
Claude Code

- Da Anthropic
- Possuí APP
- Via CLI
- Possui plugin para outras ferramentas
- Só funciona com modelos da Anthropic
- Modelos: Haiku, Sonnet, Opus, Fable ...



https://claude.com/product/claude-code

Cursor



https://cursor.com/pt-BR/home

WindSurf - Está sendo renomeado para Devin



https://devin.ai/desktop

https:/https://docs.devin.ai/pt-BR/desktop/getting-started

Open Code

Semelhante ao Codex ou Claude Code

Usado via CLI

Se integra aVS Code, Cursor ou qualquer IDE que suporte um terminal

Pode ser usado com provedores de IA pagos e gratuítos



https://opencode.ai/br

E como colocar tudo isso na Prática??

NÃO FIQUE PARA TRÁS: IA PARA DEVS JÁ É ESSENCIAL

IA PARA DESENVOLVEDORES DELPHI E LAZARUS NA PRÁTICA

Codex • Claude Code • Agentes de IA

✓ AULAS AO VIVO + ✓ ACESSO VITALÍCIO

CÉSAR CARDOSO **CODE4DELPHI**

https://code4delphi.github.io/ia-devs-delphi-lazarus/

ESCANEIE E SAIBA MAIS

ACESSE A PÁGINA DO CURSO

GARANTA SUA VAGA

Aponte a câmera do celular
para o QR Code

code4delphi.com.br/ia-devs-delphi

Code4Delphi

Cupom de desconto TMS



https://www.tmssoftware.com/

Obrigado!

github.com/Code4Delphi

youtube.com/@Code4Delphi

Code4Delphi

https://t.me/Code4Delphi

contato@code4delphi.com.br

Avalie minha apresentação