
EMBARCADERO CONFERENCE
PATROCINADOR MASTER:
embarcadero
An Idera, Inc. Company

DELPHI + OPENROUTER:
VÁRIOS LLMS, UMA BASE DE CÓDIGO E MUITAS POSSIBILIDADES

POR GABRIEL FABREGA

API unificada para centralizar centenas de provedores de IA com compatibilidade, semelhante ao Ollama.

ACESSE O QRCODE E AVALIE MINHA PALESTRA!

@fabrega_dev

EMBARCADERO CONFERENCE 2026

Gabriel Fabrega

LÍDER TÉCNICO DE INTEGRAÇÕES
AGROTIS GERENCIAL

- Formado em Gestão da TI
- Pós graduando em IA Aplicada
- Especializando em Arquitetura
- 2x Speaker na Embarcadero Conference



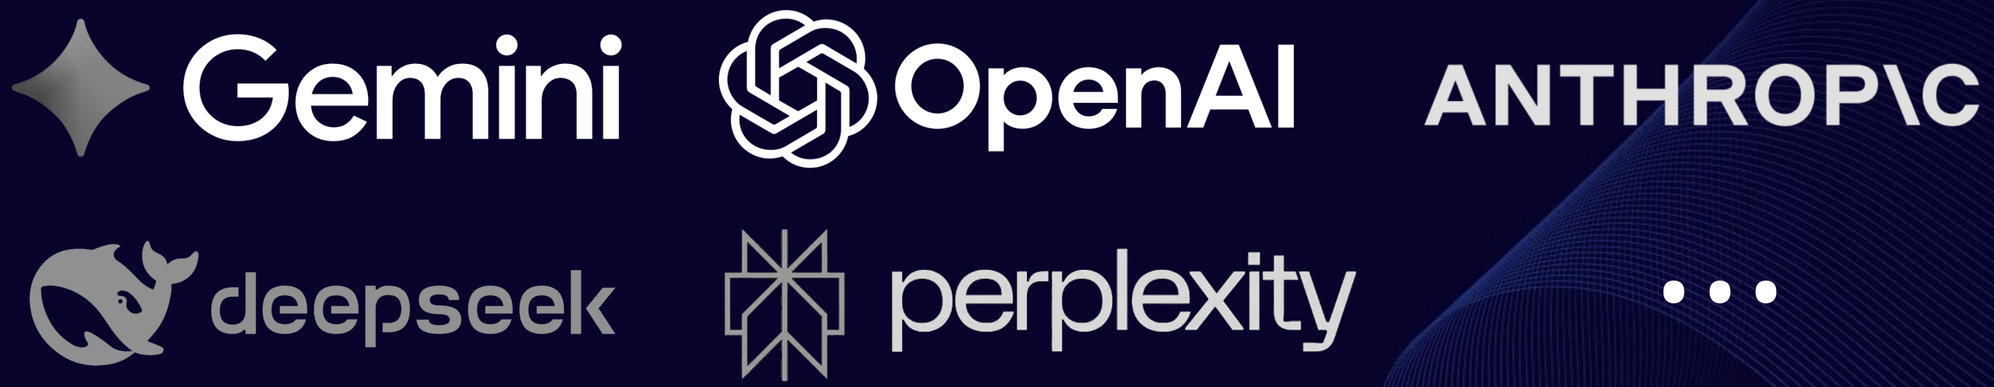
AGROTIS GERENCIAL

AGENDA

- PORQUE USAR UM GATEWAY DE LLMS
- MODELOS FREE
- MODELOS MULTIMODAIS
- COMO ESCOLHER O MELHOR MODELO
- SAFEGUARD MODELS
- STRUCTURED OUTPUTS MODELS
- BYOK

PORQUE USAR UM GATEWAY DE LLMS

- ❌ Uma API key para cada provedor
- ❌ SDKs diferentes
- ❌ Limites, formatos e erros diferentes
- ❌ Dashboard de custo espalhados



PORQUE USAR UM GATEWAY DE LLMS

- ✅ Fallback automático
- ✅ Roteamento por custo, latência, throughput
- ✅ Cobrança consolidada
- ✅ Evita vendor lock-in
- ✅ Sua aplicação fala com uma API
- ✅ O modelo passa a ser uma escolha/configuração.



MODELOS FREE

Free models

View more

The most-used models with a free endpoint.

	Model	Tokens/wk	Context
1	Nemotron 3 Ultra (free)	2.3T	1M
2	Laguna S 2.1 (free)	1.7T	262K
3	Nemotron 3 Super (free)	315.4B	262K
4	North Mini Code (free)	255.4B	256K
5	Laguna XS 2.1 (free)	171.4B	262K

MODELOS FREE

⚠️ Possuem limites
⚠️ NÃO são indicados para produção
✅ Ideal para criar projetos e MVPs
✅ Ideal para provas de conceitos

MODELOS MULTIMODAIS

- 💬 Texto: *Gera, traduz e responde em linguagem natural*
- 🖼️ Imagens: *Cria, edita e analisa imagens a partir de descrições*
- 📈 Embeddings: *Conversão em vetores para busca por similaridade*
- 📣 Audio: *Compreende e processa sons, músicas e falas*
- 🎥 Video: *Analisa ou gera vídeos a partir de descrições*
- 🗂️ Rerank: *Ordenação de resultados para busca por relevância*
- 🗣️ Speech: *Converte texto em voz natural (Text-to-speech)*
- 🎙️ Transcription: *Converte voz natural em texto (Speech-to-text)*

COMO ESCOLHER O MELHOR MODELO



Provedor	Quem publica o modelo	`openai`, `anthropic`, `google`, `meta-llama`, `mistralai`, `qwen`
Família	Linha do modelo	`gpt`, `claude`, `gemini`, `llama`, `qwen`
Versão	Geração do modelo	`3`, `3.3`, `4`, `5`, `2.5`
Tamanho	Quantidade de parâmetros	`7b`, `8b`, `32b`, `70b`, `405b`
Variante	Objetivo do modelo	`mini`, `flash`, `pro`, `nano`, `sonnet`, `haiku`, `opus`
Especialização	Ajuste específico	`instruct`, `coder`, `vision`, `reasoning`

COMO ESCOLHER O MELHOR MODELO

Weekly Tokens	Tokens de Entrada (por Milhão)	Tokens de saída (por Milhão)	Contexto	Throughput
- Quantos tokens podem ser consumidos semanalmente	- Prompt do usuário - Prompt do sistema - Histórico da conversa - Contexto adicional (RAG) - Thinking/Reasoning ("pensamento")	- A resposta em linguagem natural. - Código gerado. - JSON/XML retornado (como em *structured outputs*) - Chamadas de ferramentas (*tool calls* ou *function calls*), quando fazem parte da saída do modelo. - *Thinking/Reasoning tokens* **visíveis ou cobrados como saída**, dependendo do modelo.	- Tamanho do contexto suportado	- Taxa de geração de output tokens (tokens/s). Quanto maior, melhor.

SAFEGUARD MODELS

Modelos que analisam entradas e saídas para aplicar políticas de segurança, privacidade e conformidade.

- 🛡️ Detectar conteúdo tóxico ou ofensivo.
- 🛡️ Identificar tentativas de jailbreak.
- 🛡️ Bloquear vazamento de dados sensíveis.
- 🛡️ Aplicar políticas de uso da plataforma.
- 🛡️ Classificar o risco de uma conversa antes ou depois da geração.

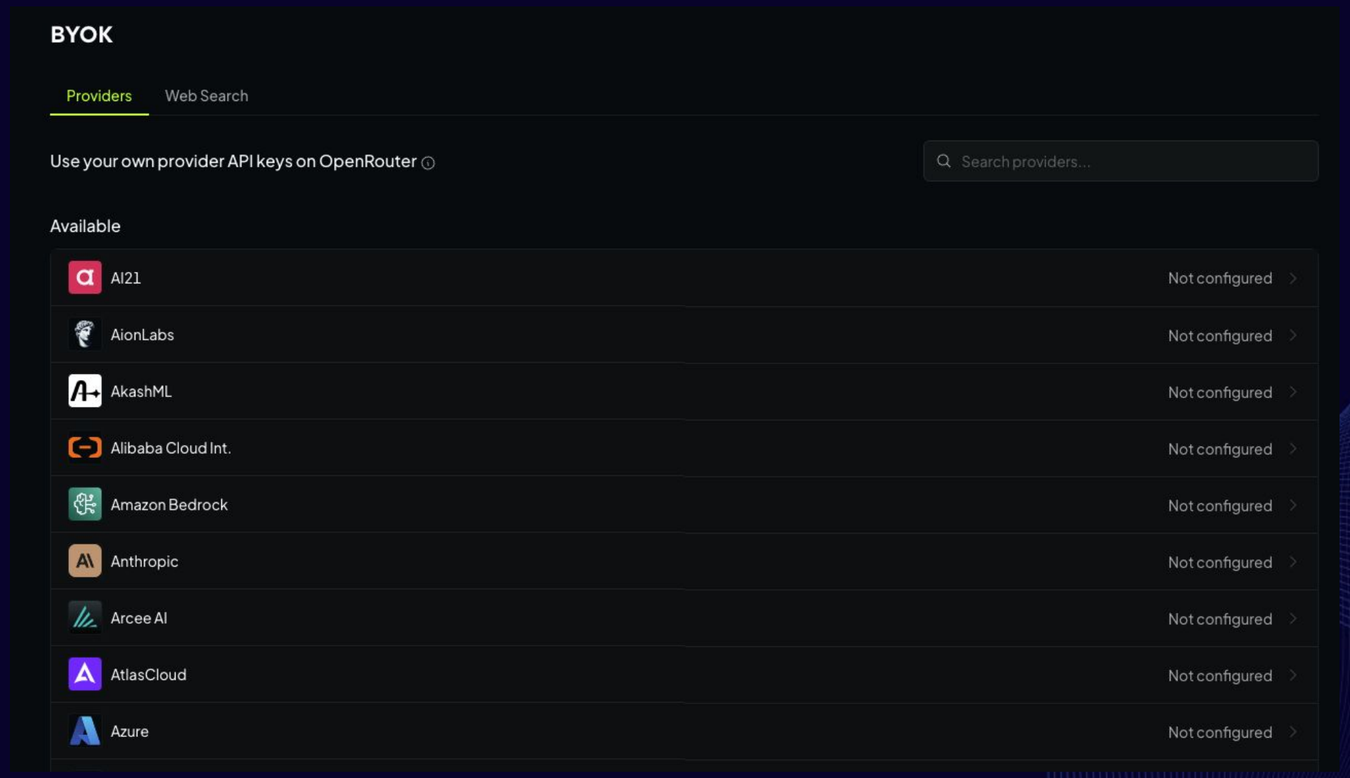


STRUCTURED OUTPUTS

Todo LLM gera texto, mas nem todo LLM consegue garantir que esse texto respeite um formato específico. A saída estruturada adiciona restrições durante a geração, garantindo que o resultado seja válido conforme um schema.

INTEGRAÇÕES BYOK (BRING YOUR KEY)

Traga sua chave de outros provedores para utilizar dentro do OpenRouter



EMBARCADERO CONFERENCE 26

PATROCINADOR MASTER: embarcadero® An Idera, Inc. Company

QUER ME VER NA #ECON27?

ACESSE O QRCODE E AVALIE MINHA PALESTRA!

GABRIEL FABREGA

@fabrega_dev

Gabriel Fabrega

glfabrega@gmail.com